Berliner Hochschule für Technik
Fachbereich VI – Informatik und Medien
Studiengang Technische Informatik

Dateneffiziente Personalisierung für webcam-basiertes Eye-Tracking mithilfe vortrainierter Bildverarbeitungsmodelle

Masterarbeit

zur Erlangung des akademischen Grades
Master of Engineering (M. Eng.)

vorgelegt von
Khaled Rafei
Matrikelnummer: 930677

Betreuer BHT:	Prof. Dr. Kristian Hildebrand
Betreuer extern:	Prof. Dr. Meysam Shamsi
Gutachter:	Prof. Dr. Robert Strzebkowski
Eingereicht:	05. 11. 2026

Kurzfassung

Webcam-basiertes Eye-Tracking ist kostengünstig und auf fast jedem Laptop verfügbar. Mit allgemeinen Modellen ist es aber oft ungenau, weil sich Personen, Kameras und Umgebungen stark unterscheiden. Diese Arbeit untersucht, wie sich ein vortrainiertes Bildverarbeitungsmodell mit wenigen Kalibrierungsdaten an eine einzelne Person anpassen lässt.

Als Feature Extractor dient ein auf ImageNet vortrainiertes ResNet-18. Es ist klein genug für eine CPU, und seine allgemeinen Bild-Features sind gut erprobt; deshalb wird es auch in der Blickschätzung häufig als Backbone verwendet. Der Backbone bleibt eingefroren, und trainiert wird nur ein kleiner Regression Head. So gibt es nur wenige trainierbare Parameter, was die Gefahr von Overfitting bei wenigen Kalibrierbildern verringert. Außerdem werden die Features jedes Bildes nur einmal berechnet, und ein Training dauert nur Sekunden. Der Head wird zuerst auf dem Datensatz GazeCapture trainiert (Basismodell) und danach mit eigenen Webcam-Aufnahmen aus 18 Sitzungen einer Person angepasst. Diese Personalisierung ist nötig, weil sich Augenform, Kopfhaltung, Kamera und Bildschirm von Person zu Person unterscheiden und ein allgemeines Modell diese Unterschiede nicht ausgleicht. Dafür genügen wenige Minuten persönlicher Daten statt eines großen eigenen Datensatzes. Als Fehlermaß dient der Diagonalfehler, also der Fehler in Prozent der Bildschirmdiagonale.

Auf den eigenen Aufnahmen ist das Basismodell nicht besser als eine konstante Schätzung der Bildschirmmitte (30,6 % gegenüber 30,3 %); es dient daher vor allem als Startpunkt. Bei einer realistischen, zeitlichen Aufteilung der Daten (Training auf dem Anfang, Test auf dem Ende einer Aufnahme) senkt die Personalisierung den Fehler von 31,8 % auf 27,9 %, also um etwa 12 %. In Sitzungen mit guten Aufnahmebedingungen ist der Gewinn deutlich größer (46 bis 47 %) und gilt auch für eine neue Aufnahme. Bei einer zufälligen Aufteilung der Bilder sinkt der Fehler auf 19,8 % (etwa ein Drittel). Dieser Wert ist aber zu optimistisch, weil fast gleiche Nachbarbilder in Training und Test liegen. Ein Trainingslauf dauert auf einer CPU nur wenige Sekunden. Ein kurzer Moving Average macht die Vorhersagen deutlich ruhiger, verbessert die Genauigkeit aber nicht. Hintergrund und Beleuchtung haben einen größeren Einfluss als die Gestaltung der Kalibrierung. Das Entfernen falsch gelabelter Bilder nach Zielsprüngen verbessert das Ergebnis nur wenig.

Die Ergebnisse zeigen: Eine dateneffiziente Personalisierung ist mit einfachen Mitteln möglich. Ihr Nutzen muss aber mit einer realistischen Aufteilung der Daten bewertet werden. Zusätzlich wurden zwei Sitzungen einer zweiten Person aufgenommen. Mit dem ganzen Kamerabild als Eingabe brachte die Personalisierung bei ihr keinen Gewinn, und

eine Kalibrierung der ersten Person ließ sich nicht auf sie übertragen. In der Web-Demo, die einen Augenausschnitt verwendet, funktionierte die Personalisierung dagegen auch bei ihr (Fehler 9,7 % statt 26,9 %). Die Eingabe ist also entscheidend dafür, ob die Personalisierung bei einer Person gelingt.

Schlagwörter: Eye-Tracking, Blickschätzung, Webcam, Personalisierung, Transfer Learning, ResNet-18, GazeCapture

Inhaltsverzeichnis

Kurzfassung I

Abbildungsverzeichnis VI

Tabellenverzeichnis VII

Abkürzungsverzeichnis VIII

1. Einleitung 1

1.1. Motivation . . . 1
1.2. Problemstellung und Ziel . . . 1
1.3. Forschungsfragen . . . 2
1.4. Beitrag der Arbeit . . . 2
1.5. Aufbau der Arbeit . . . 3

2. Stand der Technik 4

2.1. Grundlagen der erscheinungsbasierten Blickschätzung . . . 4
2.1.1. Klassische Verfahren . . . 4
2.1.2. Erste Deep-Learning-Verfahren . . . 4
2.1.3. Einteilung der Verfahren . . . 5
2.2. Webcam-basiertes Eye-Tracking: Alltag und Labor . . . 6
2.3. Große Datensätze zur Blickschätzung . . . 7
2.4. Netzarchitekturen für die Gaze Regression . . . 8
2.4.1. Convolutional Neural Networks . . . 8
2.4.2. Vision Transformer . . . 9
2.4.3. Vortrainierte Foundation-Modelle . . . 9
2.5. Vortrainierte Modelle für die Blickschätzung . . . 10
2.5.1. Eingefrorener Backbone oder vollständiges Fine-Tuning . . . 10
2.5.2. Großes MAE-Pretraining: UniGaze . . . 10
2.5.3. Bild-Text-Modelle: CLIP-Gaze und GazeCLIP . . . 12
2.6. Dateneffiziente Personalisierung . . . 13
2.6.1. Kalibrierverfahren . . . 14
2.6.2. Few-Shot-Learning und Meta-Learning: FAZE . . . 15
2.6.3. Parametereffizientes Fine-Tuning (PEFT) . . . 17

2.7. Domain Shift, Generalisierung und Evaluationsprotokolle 18
2.7.1. Evaluation mit unbekannten Personen 18
2.7.2. Domain Adaptation und Domain Generalization 18
2.7.3. Blickschätzung für mehrere Personen 19
2.7.4. Unterschiede bei Geräten und Umgebung 19
2.8. Test-Time Adaptation 20
2.8.1. TTP-GE: Self-Supervised und Weakly Supervised Adaptation . . . 20
2.8.2. Weitere labelsparende Verfahren 21
2.9. Datenqualität, falsche Labels und zeitlicher Ablauf 21
2.9.1. Datenqualität im Eye-Tracking 22
2.9.2. Reaktionszeit und Saccades 23
2.9.3. Filtern schon bei der Aufnahme 23
2.9.4. Filtern nach der Aufnahme und robuste Lernverfahren 24
2.10. Vergleich und kritische Diskussion 25
2.11. Forschungslücken und Bezug zu dieser Arbeit 27
2.11.1. Forschungslücken 27
2.11.2. Was diese Arbeit beiträgt 27

3. Methodik **29**
3.1. Datensätze 29
3.2. Aufnahme der Personalisierungsdaten 29
3.3. Vorverarbeitung 30
3.4. Modell und Training 31
3.5. Auswertung 31
3.6. Implementierung 32

4. Experimente und Ergebnisse **33**
4.1. Versuchsaufbau 33
4.1.1. Daten und Splits 33
4.1.2. Fehlermaß 34
4.1.3. Ablauf der Experimente 34
4.1.4. Normierung der Zielwerte 35
4.1.5. Baselines 36
4.2. Trainingseinstellungen 37
4.2.1. Batch Size 37
4.2.2. Learning Rate 38
4.2.3. Trainierbare Schichten 39
4.2.4. Activation am Ausgang 40
4.2.5. Datenmenge 41
4.2.6. Art des Splits 41

4.3. Räumliche Fehleranalyse und Loss Functions . . . 41
4.3.1. Einteilung des Bildschirms . . . 42
4.3.2. Fehler-Heatmaps . . . 42
4.3.3. Loss Functions . . . 43
4.3.4. Ergebnisse: Vergleich der Loss Functions . . . 44
4.4. Personalisierungssitzungen . . . 46
4.4.1. Aufbau . . . 46
4.4.2. Ergebnisse aller Sitzungen (E1) . . . 46
4.4.3. Trainingszeit einer Sitzung . . . 50
4.4.4. Bereinigung der Labels (Gen 4, E1b) . . . 50
4.4.5. Aufnahmebedingungen (Gen 4) . . . 51
4.5. Strategien zum Aufteilen der Daten (E2) . . . 52
4.6. Gestaltung der Kalibriersitzung . . . 54
4.6.1. Abdeckung des Bildschirms und Transition Frames . . . 54
4.6.2. Ergebnis der Personalisierung (E3) . . . 55
4.7. Zeitliche Glättung der Vorhersagen (E4) . . . 56
4.8. Zweite Person (E5) . . . 58
4.9. Diskussion der Ergebnisse . . . 60
4.10. Zusammenfassung der Ergebnisse . . . 61

5. Diskussion **64**
5.1. Antworten auf die Forschungsfragen . . . 64
5.2. Einordnung in den Stand der Technik . . . 66
5.3. Grenzen der Arbeit . . . 66

6. Fazit und Ausblick **68**
6.1. Fazit . . . 68
6.2. Ausblick . . . 70

Literaturverzeichnis **72**

A. Anhang **77**
A.1. Aufbau des Codes . . . 77
A.2. Befehle zum Wiederholen der Experimente . . . 77
A.3. Verzeichnis der Fachbegriffe . . . 78

Eidesstattliche Erklärung **81**

Abbildungsverzeichnis

4.1. Blickziele von GazeCapture vor und nach der Normierung 36
4.2. Testfehler einzelner Läufe mit vier Learning Rates 38
4.3. Räumlicher Fehler des Standardmodells 43
4.4. Testfehler der 18 Sitzungen nach der Personalisierung mit beiden Basismodellen, verglichen mit der Konstant-Baseline und dem unveränderten Basismodell (`norm_subject`) auf denselben Testbildern (Daten aus Tabelle 4.13). 47

Tabellenverzeichnis

2.1. Überblick über ausgewählte Datensätze zur Blickschätzung. 8
2.2. Vergleich von UniGaze und dieser Arbeit. 12
2.3. Vergleich von CLIP-Gaze, GazeCLIP und dieser Arbeit. 14
2.4. Vergleich von FAZE und dieser Arbeit. 16
2.5. Vergleich von TTP-GE und dieser Arbeit. 22
2.6. Vergleich von nachträglicher Filterung (DMRF) und Phasenprotokoll. . . 25
2.7. Vergleich der wichtigsten Arbeiten 26

4.1. Standardeinstellung der Hyperparameterstudie 34
4.2. Baseline-Fehler E_{diag} in % 37
4.3. Batch Size 37
4.4. Learning Rate 38
4.5. Trainierbare Parameter der drei Varianten (ResNet-18 mit Regression Head, insgesamt 11 603 650 Parameter). 39
4.6. Trainierbare Schichten 39
4.7. Activation am Ausgang 40
4.8. Datenmenge (Training/Test) 41
4.9. Art des Splits 41
4.10. Vergleich von L1- und sensitivem L1-Loss 44
4.11. Zusatzexperiment: räumlicher Fehler von vier Loss Functions 45
4.12. Aufnahmebedingungen der 18 Sitzungen 47
4.13. Personalisierung der 18 Sitzungen mit zwei Basismodellen 48
4.14. Bereinigung der Labels in Gen 4 50
4.15. Strategien zum Aufteilen der Daten 53
4.16. Abdeckung und Transition Frames pro Gestaltung 54
4.17. Testfehler pro Gestaltung mit zufälligem und sequenziellem Split 55
4.18. Testfehler pro Bildschirmregion 55
4.19. Zeitliche Glättung der Vorhersagen 57
4.20. Ergebnisse der zweiten Person 59
4.21. Web-Demo mit beiden Personen 60
4.22. Zusammenfassung der Ergebnisse und der gewählten Einstellung 63

Abkürzungsverzeichnis

Abkürzung	Bedeutung
AdamW	Adam-Optimierer mit entkoppeltem Weight Decay
CLIP	Contrastive Language-Image Pre-training
CNN	Convolutional Neural Network (faltendes neuronales Netz)
CPU	Central Processing Unit (Hauptprozessor)
CI	Confidence Interval (Konfidenzintervall)
DA	Domain Adaptation (Domänenadaption)
DG	Domain Generalization (Domänengeneralisierung)
DINOv2	Self-Distillation with No Labels, Version 2
FC	Fully Connected (vollständig verbundene Schicht)
fps	Frames per Second (Bilder pro Sekunde)
L1	Loss aus dem mittleren absoluten Fehler (L1-Verlust)
LoRA	Low-Rank Adaptation
MAE	Masked Autoencoder
MAML	Model-Agnostic Meta-Learning
MLP	Multi-Layer Perceptron (mehrschichtiges Perzeptron)
PEFT	Parameter-Efficient Fine-Tuning (parametereffizientes Fine-Tuning)
PoR	Point of Regard (Blickpunkt auf dem Bildschirm)
ReLU	Rectified Linear Unit
RMSE	Root Mean Squared Error (Wurzel des mittleren quadratischen Fehlers)
SD	Standardabweichung
SVR	Support-Vector-Regression
TTA	Test-Time Adaptation (Anpassung zur Testzeit)
ViT	Vision Transformer
Formelzeichen	
E_{diag}	Diagonalfehler: euklidischer RMSE in Prozent der Bildschirmdiagonale

1. Einleitung

1.1. Motivation

Eye-Tracking misst, wohin ein Mensch schaut. Diese Information ist für viele Anwendungen nützlich: für die Bedienung von Computern ohne Hände, zum Beispiel für Menschen mit körperlichen Einschränkungen, für Studien zur Benutzerfreundlichkeit von Webseiten, für Lernplattformen oder für die Forschung in Psychologie und Medizin. Professionelle Eye-Tracker arbeiten mit Infrarotlicht und speziellen Kameras. Sie sind sehr genau, aber teuer und nicht überall verfügbar.

Eine normale Webcam ist dagegen in fast jedem Laptop eingebaut. Wenn man den Blick mit einer Webcam schätzen könnte, wäre Eye-Tracking für sehr viele Menschen ohne zusätzliche Hardware möglich. Das ist aber schwierig. Die Bilder haben eine niedrige Auflösung, und die Augen sind darin nur wenige Pixel groß. Das Licht ändert sich, der Kopf bewegt sich, viele Menschen tragen eine Brille, und jede Person hat eine andere Augen- und Gesichtsform. Ein allgemeines Modell, das auf vielen Personen trainiert wurde, passt deshalb oft schlecht zu einer neuen Person.

1.2. Problemstellung und Ziel

Ein Ausweg ist die *Personalisierung*: Man nimmt ein vortrainiertes Modell und passt es mit wenigen Daten an eine Person an. Die Person schaut dazu kurz auf einen Punkt, der sich über den Bildschirm bewegt (Kalibrierung). Die Kalibrierung soll aber kurz sein, denn niemand möchte vor jeder Nutzung mehrere Minuten lang kalibrieren. Die Personalisierung muss also *dateneffizient* sein.

Das Ziel dieser Arbeit ist es, zu untersuchen, wie gut ein vortrainiertes Bildverarbeitungsmodell mit einer kurzen Webcam-Kalibrierung an eine Person angepasst werden kann. Als Modell dient ein auf ImageNet vortrainiertes ResNet-18. Sein Backbone bleibt eingefroren, und nur ein kleiner Regression Head wird trainiert. Der Head wird zuerst auf dem Datensatz GazeCapture trainiert und danach mit eigenen Aufnahmen personalisiert.

1.3. Forschungsfragen

Die Arbeit beantwortet vier Forschungsfragen (FF):

FF1 Wie stark senkt eine kurze Personalisierung den Fehler gegenüber einem allgemeinen Modell und gegenüber einer einfachen Schätzung, die immer denselben Punkt ausgibt?

FF2 Welche Trainingseinstellung eignet sich für den Regression Head (trainierbare Schichten, Activation, Loss Function, Learning Rate, Batch Size)?

FF3 Wie beeinflussen die Aufteilung der Daten (zufällig, zeitlich, zwei Videos), die Gestaltung der Kalibrierung (Bewegung des Ziels, Entfernen von Transition Frames) und eine zeitliche Glättung der Vorhersagen das Ergebnis?

FF4 Welchen Einfluss haben die Aufnahmebedingungen (Licht, Hintergrund, Brille, Dauer, Gerät bzw. Webcam)?

1.4. Beitrag der Arbeit

Die Arbeit liefert folgende Beiträge:

- **Eigene Aufnahmen:** 27 Kalibriersitzungen von Person A (dem Autor) mit zwei Laptop-Webcams, davon 18 ausgewertet, und zwei Sitzungen einer zweiten Person (Person B) als Vergleich. Die Sitzungen unterscheiden sich in der Bewegung des Ziels, im Licht, im Hintergrund, in der Brille und in der Dauer. Die neueste Generation speichert für jedes Bild die Phase des Ziels (`WAIT` oder `MOVE`).
- **Reproduzierbare Pipeline:** feste Seeds, eingefrorener Backbone, gespeicherte Features (Feature-Cache) und gespeicherte Vorhersagen. Ein Personalisierungslauf dauert damit etwa zwei Sekunden auf einer CPU.
- **Korrigiertes Fehlermaß:** Ein Fehler im Auswertungscode wurde gefunden und behoben. Baselines werden immer auf denselben Daten wie das Modell berechnet.
- **Systematische Studie:** Hyperparameter mit fünf Wiederholungen und Confidence Intervals, räumliche Analyse des Fehlers, ein Vergleich von Datenaufteilungen und Kalibriergestaltungen sowie eine Untersuchung der zeitlichen Glättung der Vorhersagen.
- **Web-Demo:** Eine Demo im Browser zeigt die Personalisierung live: Kalibrierung, Blickverfolgung und Auswertung (Kapitel 6).

1.5. Aufbau der Arbeit

Kapitel 2 beschreibt den Stand der Technik. Kapitel 3 erklärt Daten, Modell und Vorgehen. Kapitel 4 zeigt die Experimente und Ergebnisse. Kapitel 5 beantwortet die Forschungsfragen und nennt die Grenzen der Arbeit. Kapitel 6 fasst die Arbeit zusammen und gibt einen Ausblick.

In dieser Arbeit werden die üblichen englischen Fachbegriffe verwendet, zum Beispiel Overfitting, Feature oder Loss. Ihre deutsche Übersetzung steht im Verzeichnis der Fachbegriffe im Anhang (Anhang A.3).

2. Stand der Technik

Dieses Kapitel gibt einen Überblick über die Blickschätzung mit normalen RGB-Kameras. Zuerst erkläre ich die Grundlagen (Abschnitt 2.1) und die besonderen Probleme von Webcams (Abschnitt 2.2). Danach stelle ich wichtige Datensätze (Abschnitt 2.3), Netzarchitekturen (Abschnitt 2.4) und vortrainierte Modelle (Abschnitt 2.5) vor. Anschließend geht es um Personalisierung, Domain Shift, Test-Time Adaptation und Datenqualität. Am Ende leite ich die Forschungslücken ab, die diese Arbeit bearbeitet.

2.1. Grundlagen der erscheinungsbasierten Blickschätzung

Eye-Tracking bestimmt aus Bildern der Augen oder des Gesichts, wohin eine Person schaut. Es gibt zwei Arten von Ausgaben: die dreidimensionale Blickrichtung (meist zwei Winkel, Pitch und Yaw) oder den zweidimensionalen *Point of Regard* (PoR). Der PoR ist der Punkt auf dem Bildschirm, auf den die Person schaut. Diese Arbeit schätzt den 2D-PoR aus Bildern einer normalen Webcam.

2.1.1. Klassische Verfahren

Erscheinungsbasierte Verfahren lernen direkt eine Abbildung vom Bild zum Blickziel. Sie brauchen kein geometrisches Modell des Auges. Frühe Verfahren haben von Hand entworfene Bild-Features verwendet, zum Beispiel Local Binary Patterns (LBP), Histograms of Oriented Gradients (HoG) oder SIFT. Diese Features wurden mit einfachen Regressoren kombiniert, etwa mit linearer Regression, Random Forests oder Support-Vector-Regression (SVR). Solche Verfahren rechnen schnell. Bei Kopfbewegungen und wechselndem Licht werden sie aber deutlich ungenauer, weil die Features diese Änderungen nicht gut von der Blickinformation trennen.

2.1.2. Erste Deep-Learning-Verfahren

Mit Convolutional Neural Networks (CNNs) kann man Gesichts- und Augenbilder direkt auf Bildschirmpositionen abbilden. Krafka et al. [1] haben mit *iTracker* eines der ersten CNNs für mobiles Eye-Tracking ohne zusätzliche Hardware vorgestellt. Das Modell verarbeitet vier Eingaben in getrennten Zweigen: das linke Auge, das rechte Auge, das Gesicht

und ein binäres *Face Grid* (wo das Gesicht im Bild liegt). Danach werden die Features zusammengeführt. Ohne Kalibrierung liegt der Fehler bei 1,71 cm auf Smartphones und bei 2,53 cm auf Tablets. Für die Personalisierung trainieren die Autoren eine SVR pro Nutzer auf den Features der Schicht `fc1`. Dafür nutzen sie Aufnahmen von bis zu 13 festen Kalibrierpunkten. Mit allen 13 Punkten sinkt der Fehler auf 1,34 cm bzw. 2,12 cm. Mit sehr wenigen Punkten kommt es bei der SVR aber leicht zu *Overfitting* (dt. Überanpassung): Das Modell lernt die wenigen Trainingsdaten fast auswendig und wird dadurch auf neuen Bildern schlechter. Das Modell läuft in Echtzeit auf mobilen Geräten.

Ein wichtiger Beitrag dieser Arbeit ist der Datensatz GazeCapture (Abschnitt 2.3). Er wurde per *Crowdsourcing* auf Smartphones und Tablets unter Alltagsbedingungen gesammelt: Viele Freiwillige haben die Daten selbst mit einer App auf ihrem eigenen Gerät aufgenommen. Er dient bis heute als Benchmark und als Quelle für das Pretraining.

Bedeutung für diese Arbeit. iTracker hat drei Ideen eingeführt, die bis heute wichtig sind: (1) den Datensatz GazeCapture, (2) die Personalisierung mit Kalibrierdaten und (3) das Zusammenführen von Features aus mehreren Bildbereichen. Diese Arbeit nutzt dieselben Daten. Statt AlexNet und SVR verwendet sie aber ein ResNet-18 [2] mit einem Regression Head und L1-Loss. Der Regression Head ist hier ein Multi-Layer Perceptron (MLP), also ein kleines Netz aus vollständig verbundenen Schichten, das aus den Bild-Features des ResNet-18 die Koordinaten (x, y) auf dem Bildschirm berechnet. Außerdem bewertet sie die Basismodelle mit einem personendisjunkten Split (`norm_subject`) und nicht nur mit einer zufälligen Aufteilung (`norm_random`). Falsche Labels behandelt sie schon bei der Aufnahme: Das Aufnahmeprogramm speichert für jedes Bild die Phase des Ziels (`WAIT` oder `MOVE`).

2.1.3. Einteilung der Verfahren

Man kann Verfahren zur Blickschätzung in drei Klassen einteilen:

1. **Modellbasierte (geometrische) Verfahren** nutzen ein 3D-Modell des Augapfels, Pupillenellipsen und Lichtreflexe auf der Hornhaut. Sie brauchen meist hochaufgelöste Bilder und Infrarotlicht. Bei normalem Tageslicht machen sie oft Fehler.

2. **Feature-basierte Verfahren** suchen geometrische Punkte im Gesicht, zum Beispiel Augenwinkel oder die Mitte der Iris. Daraus berechnen sie den Blick.

3. **Erscheinungsbasierte Verfahren** verwenden das Augen- oder Gesichtsbild selbst als Eingabe. Ein tiefes neuronales Netz sagt direkt 2D-Koordinaten oder 3D-Winkel vorher.

Durch den Fortschritt im Deep Learning sind erscheinungsbasierte Verfahren heute der Standard unter *Unconstrained Conditions* (dt. uneingeschränkte Bedingungen), also bei freier Kopfhaltung, wechselndem Licht und beliebigem Abstand zur Kamera.

Cheng et al. [3] teilen Verfahren mit *Remote Camera* (dt. entfernte Kamera: Die Kamera steht vor der Person und wird nicht am Kopf getragen) ebenfalls in drei Gruppen ein: Verfahren mit einem rekonstruierten 3D-Augenmodell (der Augapfel wird geometrisch nachgebildet, und der Blick wird aus Pupille und Lichtreflexen berechnet), Regression auf 2D-Augen-Features und erscheinungsbasierte Verfahren. Deep-Learning-Ansätze ordnen sie nach vier Gesichtspunkten: Feature Extraction, Netzarchitektur, persönliche Kalibrierung sowie Geräte und Plattformen. Ein wichtiger Beitrag ist ein Benchmark. Er vereinheitlicht die Vorverarbeitung (Gesichts- und Augenerkennung, Normalisierung der Daten) und die Nachverarbeitung (Umrechnung zwischen 2D-Blickpunkt und 3D-Blickvektor). So kann man Verfahren fair vergleichen. Bei kurzem Abstand zur Kamera oder hoher Auflösung erreichen erscheinungsbasierte Verfahren laut Benchmark etwa 5°. Bei großem Abstand und niedriger Auflösung (zum Beispiel Gaze360 und RT-GENE) sind die Fehler deutlich größer. Als offene Themen nennen die Autoren: (1) robustere Features, die nicht von der Umgebung abhängen, (2) hohe Genauigkeit mit schneller und einfacher Kalibrierung – hier gibt es einen Zielkonflikt zwischen Kalibrierdauer und Genauigkeit – und (3) die Erklärbarkeit der gelernten Features.

Weitere Übersichtsarbeiten geben zusätzlichen Hintergrund. Liu et al. [4] beschreiben den Weg von klassischen Verfahren zu Deep Learning; ich nutze diese Arbeit vor allem als historische Referenz. Pathirana et al. [5] behandeln Deep-Learning-Verfahren für einen und für mehrere Nutzer. Sie vergleichen CNN-Architekturen, von denen einige auf ImageNet vortrainiert sind. Neuere vortrainierte Modelle wie DINOv2, CLIP oder MAE stehen in diesen Übersichten aber nicht im Mittelpunkt. Für Vergleiche mit Benchmarks nutze ich daher vor allem Cheng et al. [3].

2.2. Webcam-basiertes Eye-Tracking: Alltag und Labor

Webcams sind billig und fast überall vorhanden: in Laptops, an Desktop-Rechnern und in Smartphones. Man braucht keine zusätzliche Hardware. Dafür sind die Bedingungen viel schwieriger als bei speziellen Eye-Trackern mit Infrarotlicht:

- **Infrarot-Systeme** nutzen hochauflösende Kameras, Infrarotlicht und Reflexe auf der Hornhaut. Liu et al. [4] nennen für solche Verfahren typische Genauigkeiten von 0,5° bis 2°. Kommerzielle Geräte arbeiten in festen Abständen (zum Beispiel 50 cm bis 80 cm) und erreichen unter optimalen Bedingungen 0,3° bis 0,5°.

- **Webcams im Alltag** liefern Bilder mit niedriger Auflösung und ohne kontrolliertes Licht. Das Umgebungslicht ändert sich, die Lage von Kamera und Bildschirm ist bei jedem Gerät anders, und Abstand und Kopfhaltung sind frei. Liu et al. [4] nennen für erscheinungsbasierte Verfahren typische Fehler über 3°. Der Benchmark von Cheng et al. [3] zeigt etwa 5° bei kurzem Abstand und deutlich mehr bei großem Abstand und niedriger Auflösung.

Zwei bekannte Arbeiten zeigen trotzdem, dass Webcam-Eye-Tracking praktisch nutzbar ist. Papoutsaki et al. [6] stellen *WebGazer* vor, einen Open-Source-Eye-Tracker, der komplett im Browser läuft. WebGazer braucht keine eigene Kalibrierung. Er lernt mit *Ridge Regression* laufend aus Mausklicks und Mausbewegungen, welche Augen-Features zu welcher Bildschirmposition gehören. Ridge Regression ist eine lineare Regression mit einer Strafe für große Gewichte (L2-Regularisierung); dadurch bleibt das Modell auch bei wenigen und verrauschten Daten stabil. Die Genauigkeit reicht, um grob den betrachteten Bereich zu erkennen, aber nicht für genaue Analysen. Valliappan et al. [7] trainieren dagegen ein CNN auf GazeCapture vor, passen es mit Kalibrierdaten an und ergänzen ein kleines Regressionsmodell pro Person. Auf Smartphones bei 25 cm bis 40 cm Abstand erreichen sie 0,6° bis 1°. Etwa 30 Sekunden Kalibrierung senken den Fehler von 1,92 cm auf 0,46 cm. Laut den Autoren ist das so genau wie viel teurere mobile Eye-Tracker. Die Bedingungen waren aber günstig (Kopf fast frontal, kurzer Abstand). Beide Arbeiten zeigen: Ohne spezielle Hardware ist die Personalisierung der wichtigste Faktor für die Genauigkeit.

Auch Eigenschaften der Person beeinflussen die Genauigkeit, zum Beispiel Augenform, Gesichtsform, Brille und die gewohnte Kopfhaltung. Allgemeine Modelle haben deshalb bei neuen Personen oft einen systematischen Versatz. Aus diesem Grund ist die Personalisierung ein zentrales Forschungsthema (Abschnitt 2.6). Diese Arbeit untersucht genau solche Bedingungen, unter anderem zwei Geräte mit verschiedenen Webcams, Brillen und Hintergründe.

2.3. Große Datensätze zur Blickschätzung

Moderne erscheinungsbasierte Verfahren brauchen große und vielfältige Datensätze. Tabelle 2.1 fasst die für diese Arbeit wichtigen Datensätze zusammen.

- **MPIIGaze** [8] ist einer der ersten standardisierten Datensätze aus dem Alltag. Er enthält 213 659 Gesichtsbilder von 15 Personen. Sie wurden über mehrere Monate bei der normalen Arbeit am Laptop aufgenommen [9]. Die Variante MPIIFaceGaze mit Gesichtsbildern wird meist mit Leave-one-subject-out ausgewertet (jede Person ist einmal die Testperson).

- **GazeCapture** [1] enthält 2 445 504 Bilder von 1474 Personen, aufgenommen per Crowdsourcing auf iPhones und iPads. Licht und Kopfhaltung sind sehr verschieden. GazeCapture ist die Datengrundlage der Basismodelle dieser Arbeit. Gründe für diese Wahl: Es ist einer der größten und vielfältigsten Datensätze (viele Personen, Geräte und Umgebungen), und seine Labels sind 2D-Punkte auf dem Bildschirm (Point of Regard) – also genau die Größe, die diese Arbeit schätzt.
- **ETH-XGaze** [10] ist ein hochauflösender Datensatz mit mehreren Kameras. Er enthält mehr als eine Million Bilder von 110 Personen mit sehr großen Kopf- und Blickwinkeln.
- **EVE** [11] enthält gleichzeitig aufgenommene Bildschirminhalte, Kamerabilder und Blickdaten. 54 Personen wurden mit vier Kameras aufgenommen, insgesamt mehr als 12 Millionen Bilder.
- **Gaze360** [12] enthält Aufnahmen von 238 Personen drinnen und draußen. Die 3D-Blicklabels decken sehr viele Kopfhaltungen und Abstände ab (etwa 172 000 Bilder in Training, Validierung und Test).
- **EyeDiap** und **RT-GENE** werden vor allem für Tests über Datensätze hinweg verwendet. RT-GENE enthält unter anderem größere Kameraabstände und am Kopf getragene Geräte.

Tabelle 2.1.: Überblick über ausgewählte Datensätze zur Blickschätzung.

Datensatz	Umfang	Personen	Aufnahmebedingungen
MPIIGaze	213 659 Bilder	15	Laptop-Webcam, Alltag über Monate
GazeCapture	2 445 504 Bilder	1474	Smartphones und Tablets, Crowdsourcing
ETH-XGaze	¿1 Million Bilder	110	Labor mit mehreren Kameras, extreme Kopfhaltungen
EVE	¿12 Millionen Bilder	54	Bildschirm und Kameras, Videosequenzen
Gaze360	ca. 172 000 Bilder	238	Drinnen und draußen, viele Kopfhaltungen und Abstände

2.4. Netzarchitekturen für die Gaze Regression

2.4.1. Convolutional Neural Networks

CNNs wie ResNet-18/50 [2], VGG oder MobileNet sind die üblichen Feature Extractors für Augen- und Gesichtsbilder. Ihre lokalen Faltungen erkennen feine Texturen und Kanten in

der Augenregion. Auch spezielle Blickmodelle bauen oft auf CNNs auf: FAZE [13] nutzt zum Beispiel einen Encoder-Decoder auf DenseNet-Basis, um Blick, Kopfhaltung und Aussehen voneinander zu trennen. In dieser Arbeit ist ResNet-18 das verwendete Modell.

2.4.2. Vision Transformer

Vision Transformer (ViTs) [14] teilen ein Bild in kleine Felder (Patches). Mit Self-Attention erfassen sie Zusammenhänge über das ganze Bild, zum Beispiel zwischen Gesicht, Kopfdrehung und Augen. UniGaze [15] zeigt, dass mit MAE vortrainierte ViTs (Größen Base, Large und Huge) sehr gute Backbones für die Blickschätzung sind. TTP-GE [16] kombiniert dagegen zwei ResNet-18-Zweige mit einer Transformer-Fusion. GazeCLIP [17] zeigt, dass Transformer nicht immer besser sind: Dort erreicht ein CLIP-vortrainiertes ResNet-50 3,5° auf MPIIFaceGaze, die Variante mit ViT-B/32 nur 3,7°. Ye et al. [18] zeigen dagegen mit *TransGaze*, dass auch einfache ViTs mit großem Pretraining sehr gute Ergebnisse auf GazeCapture und MPIIFaceGaze erreichen. Am besten war dort das DINO-Pretraining mit *Self-Supervised Learning*. Man sollte also CNNs und Transformer gleichermaßen prüfen und nicht eine Architektur für allgemein besser halten.

2.4.3. Vortrainierte Foundation-Modelle

Beim Transfer Learning nutzt man ein Modell, das auf sehr vielen Bildern vortrainiert wurde. Seine Features sind allgemein nutzbar. Man kann den Backbone einfrieren und nur einen kleinen Regression Head darauf trainieren. Für diese Arbeit sind vier Arten von Pretraining wichtig:

- **Supervised Pretraining auf ImageNet** (dt. überwachtes Pretraining): Das Modell lernt mit Labels, die Menschen vergeben haben (hier: Objektklassen). Das ist der klassische Ausgangspunkt für CNNs wie ResNet [2]. Diese Arbeit verwendet ein solches Modell.
- **DINOv2** [19]: lernt robuste Features durch *Self-Supervised Learning*: Das Lernziel entsteht aus den Bildern selbst, ohne manuelle Labels.
- **CLIP** [20]: lernt Bild und Text gemeinsam durch kontrastives Lernen auf Bild-Text-Paaren.
- **Masked Autoencoders (MAE)** [21]: lernen, indem sie verdeckte Bildteile rekonstruieren.

Wie man diese Features für die Blickschätzung nutzt, beschreibt der nächste Abschnitt.

2.5. Vortrainierte Modelle für die Blickschätzung

2.5.1. Eingefrorener Backbone oder vollständiges Fine-Tuning

Es gibt zwei Grundstrategien, ein vortrainiertes Modell an die Blickschätzung anzupassen. Beim *vollständigen Fine-Tuning* werden alle Gewichte trainiert. Das Modell passt sich so am stärksten an, braucht aber viele Daten. Mit wenigen Daten droht Overfitting oder *katastrophales Vergessen*: Das Modell verliert das, was es im Pretraining gelernt hat. Bei einem *eingefrorenen Backbone* (zum Beispiel ResNet-18 oder ViT-B/14) bleiben die vortrainierten Gewichte fest. Man trainiert nur einen kleinen Regression Head. So gibt es viel weniger trainierbare Parameter, und die allgemeinen Features bleiben erhalten. Das ist wichtig, wenn man nur wenige Kalibrierdaten hat.

Kumar et al. [22] begründen diesen Zielkonflikt theoretisch und mit Experimenten. Sie vergleichen vollständiges Fine-Tuning mit *Linear Probing*, bei dem nur die letzte lineare Schicht trainiert wird. Auf zehn Datensätzen mit Verteilungsverschiebung ist Fine-Tuning auf Daten wie im Training im Mittel um 2 % besser, auf abweichenden Daten aber um 7 % schlechter. Der Grund: Wenn Head und Backbone gleichzeitig trainiert werden und der Head am Anfang noch zufällig ist, werden die vortrainierten Features verzerrt. Die Autoren schlagen deshalb LP-FT vor: zuerst Linear Probing, dann Fine-Tuning. Für die Personalisierung ist das direkt wichtig. Die Kalibrierdaten einer Person sind wenige und decken die spätere Nutzung nur zum Teil ab. Ein eingefrorener Backbone kann hier die Generalisierung schützen.

Der Regression Head ist meist ein mehrschichtiges Perzeptron (MLP). Es bildet die Features, zum Beispiel die 512 Zahlen eines ResNet-18, auf die Koordinaten (x, y) ab. Wichtige Entscheidungen sind die Activation am Ausgang (zum Beispiel Sigmoid, Gauß oder ReLU) und die Loss Function (zum Beispiel L1, Smooth L1 oder Varianten mit Gewichtung nach der Position). Zwischen den beiden Extremen liegen parametereffiziente Verfahren wie Adapter oder LoRA [23] (Abschnitt 2.6.3).

2.5.2. Großes MAE-Pretraining: UniGaze

Qin et al. [15] stellen mit UniGaze ein großes Pretraining speziell für die Blickschätzung vor. Mit Masked Autoencoders lernt das Modell aus etwa 1,6 Millionen normalisierten Gesichtsbildern von mehr als 260 000 Personen. Die Daten kommen aus echten Quellen (VGGFace2, VFHQ, CelebV-Text) und aus synthetischen Datensätzen (FaceSynthetics, SFHQ-T2I, FFHQ-NV, XGaze-Dense). Ein zentrales Ergebnis ist, wie wichtig die Normalisierung der Daten ist. Dabei werden Gesichtsbild und Blicklabel durch Drehen und Skalieren in einen gemeinsamen Raum gebracht. So verschwindet ein großer Teil der Unterschiede durch Kopfhaltung und Abstand. Zhang et al. [24] haben dieses Verfahren als Erste

genau untersucht. Eine Variante ohne Skalierungsfaktor verbessert die Genauigkeit je nach Test um 9,5 bis 32,7 %. UniGaze bestätigt das: In den Ablationen (UniGaze-B, nur echte Pretraining-Daten, Leave-one-dataset-out) senkt die Normalisierung den Winkelfehler auf XTest von 14,56° auf 11,95°. Mit zusätzlichen synthetischen Daten werden 11,78° erreicht.

UniGaze nutzt ViTs der Größen Base, Large und Huge. Beim Pretraining werden 75 % des Bildes verdeckt. ViT-Huge wird 300 Epochs lang vortrainiert. Das dauert etwa 120 h auf vier NVIDIA-H100-GPUs. Danach werden die Modelle mit L1-Loss auf MPIIFaceGaze, ETH-XGaze, EYEDIAP, Gaze360 und GazeCapture mit vollständigem Fine-Tuning angepasst. Die Autoren testen drei Protokolle:

- **Domain Generalization** (Training auf ETH-XGaze oder Gaze360, Test auf MPIIFaceGaze oder dem Bildschirm-Teil von EYEDIAP): UniGaze-H erreicht 5,57° (X→M), 4,65° (X→ECS), 5,65° (G360→M) und 5,86° (G360→ECS). Das ist besser als andere Verfahren, zum Beispiel CLIP-Gaze mit 6,41°, 7,51°, 6,89° und 7,06°.
- **Leave-one-dataset-out** (Training auf vier Datensätzen, Test auf dem fünften): UniGaze-H erreicht 11,29° (XTest), 4,51° (MPIIFaceGaze), 5,47° (GazeCapture), 5,88° (EYEDIAP) und 12,37° (Gaze360).
- **Gemeinsames Training auf allen Datensätzen**: UniGaze-H erreicht 4,46° (XTest), 5,08° (MPIIFaceGaze), 3,20° (GazeCapture), 5,16° (EYEDIAP) und 9,07° (Gaze360).

Die Ablationen zeigen: Mehr Pretraining-Daten verbessern die Generalisierung, und echte plus synthetische Daten sind besser als nur echte Daten. Auch Normalisierung und viele verschiedene Kopfhaltungen sind wichtig. Wenn man die Vielfalt der Kopfhaltungen einschränkt, steigt der Fehler auf XTest von 11,95° auf 16,70°. Vergleiche mit DINO und FaRL deuten darauf hin, dass die Zusammensetzung der Daten wichtiger sein kann als ihre Menge.

Grenzen. UniGaze lässt einige Fragen offen, die für die Personalisierung mit Webcams wichtig sind. Die Ergebnisse beruhen auf vollständigen Datensätzen und vollständigem Fine-Tuning, nicht auf einer kurzen Kalibrierung mit wenigen Bildern einer Person. Sparsame Strategien wie reines Head-Training, LoRA oder Adapter stehen nicht im Mittelpunkt. Auch der Einfluss falscher Labels in kurzen Kalibrierungen wird nicht untersucht. Das Pretraining braucht außerdem sehr viel Rechenleistung (ViT-Huge: etwa 120 h auf 4×H100). Offen bleibt auch, ob die Verbesserungen unter echten Webcam-Bedingungen gelten – mit Brille, wechselndem Hintergrund, niedriger Auflösung und verschiedenen Webcams.

Bedeutung für diese Arbeit. UniGaze ist eine wichtige Referenz für Pretraining speziell für den Blick. UniGaze untersucht die Generalisierung über viele Personen. Diese Arbeit stellt die ergänzende Frage: Wie gut kann man ein vortrainiertes Modell mit einer kurzen Kalibrierung (hier 30 s bis 120 s, also etwa 180 bis 720 Labels) an eine einzelne Person anpassen? Diese Arbeit verwendet dafür ein auf ImageNet vortrainiertes ResNet-18. UniGaze-, DINOv2- und CLIP-Modelle sind ein naheliegender nächster Schritt (Tabelle 2.2).

Tabelle 2.2.: Vergleich von UniGaze und dieser Arbeit.

Kriterium	**UniGaze-H**	**UniGaze-B**	**Diese Arbeit**
Pretraining-Daten	1,6 Millionen Gesichtsbilder, ¿260 000 Personen	Gleiche Daten	ImageNet (ResNet-18), Regression Head auf GazeCapture
Backbone	ViT-Huge	ViT-Base	ResNet-18, eingefroren
Fine-Tuning	Gesamtes Modell	Gesamtes Modell	Nur Regression Head
Kalibrierdaten	Vollständige Trainingsdatensätze	Vollständige Trainings-datensätze	30 s bis 120 s pro Sitzung (ca. 180–720 Labels)
Evaluation	Über Datensätze hinweg, Domain Generalization	Über Datensätze hinweg, Domain Generalization	Personendisjunkte Basismodelle, personalisierte Webcam-Sitzungen
Falsche Labels	Keine Filterung nach Phase	Keine Filterung nach Phase	`WAIT`/`MOVE`-Protokoll
Rechenaufwand	Ca. 120 h auf 4×H100	Nur für ViT-H angegeben	Kein Pretraining; Personalisierung ca. 2 s auf einer CPU
Winkelfehler (Leave-one-dataset-out)	4,51°–12,37°	4,73°–12,41°	Diagonalfehler in %, nicht direkt vergleichbar

2.5.3. Bild-Text-Modelle: CLIP-Gaze und GazeCLIP

Zwei neuere Arbeiten nutzen das Bild-Text-Modell CLIP [20] für die Blickschätzung, aber mit verschiedenen Zielen.

CLIP-Gaze. Yin et al. [25] wollen mit CLIP-Gaze die Domain Generalization verbessern. Das Modell soll in einer neuen Umgebung gut bleiben, ohne gelabelte Daten aus dieser Umgebung. Die Idee: Faktoren, die nichts mit dem Blick zu tun haben, werden durch Texte beschrieben, etwa „An image of a face with {condition}.“ Diese Faktoren bilden drei Gruppen: Aussehen (Identität, Gesichtsausdruck, Haare, Alter usw.), Zubehör (Brille, Hut, Make-up usw.) und Bildqualität (Noise, Unschärfe, Licht). Drei Losses steuern das Training: Ein Distillation Loss richtet die Blick-Features am CLIP-Image-Encoder aus. Ein

Separation Loss macht sie den blickfremden Features unähnlich. Ein Ranking Loss sorgt dafür, dass ähnliche Blicke auch ähnliche Features haben. Zusätzlich passt die *Personalized Context Optimization* (PCO) die Texte an die jeweilige Person an. CLIP bleibt eingefroren. Trainiert wird ein eigenes Netz aus ResNet-18, einem MLP-Filter und einem Regression Head. Mit ETH-XGaze und Gaze360 als Quelle und MPIIFaceGaze und EyeDiap als Ziel erreicht CLIP-Gaze über vier Aufgaben im Mittel etwa 6,97°.

GazeCLIP. Wang et al. [17] nutzen grobe Blickinformation aus Text für die Gaze Regression mit Supervised Learning. Ein Prompt-Modul bestimmt ohne Training (Zero-Shot) mit Texten wie „A photo of a face gazing [class]“ eine grobe Richtung aus {Front, Down, Left, Right}. Der Image Encoder ist ein CLIP-vortrainiertes ResNet-50 und wird mit Fine-Tuning weitertrainiert. Der Text Encoder (ein Transformer mit 12 Schichten) bleibt eingefroren. Ein Cross-Attention-Modul verbindet beide: Text ist die Query, die Bild-Features sind Key und Value. Ein MLP mit drei Schichten ($1024 \to 256 \to 128 \to 2$) sagt Pitch und Yaw vorher. GazeCLIP erreicht 3,5° auf MPIIFaceGaze, 4,7° auf EyeDiap und 7,3° auf RT-GENE. Cross-Attention (3,6°) ist besser als einfaches Aneinanderhängen (4,2°) oder Addieren (4,4°). Ein Image Encoder mit Fine-Tuning und eingefrorenem Text Encoder (3,6°) ist viel besser als zwei eingefrorene Encoder (8,9°). Fehler entstehen vor allem bei schlechtem Licht und wenn Haare oder Brillen die Augen verdecken. Außerdem kann die Zero-Shot-Klassifikation in einer neuen Umgebung die falsche Richtung liefern.

Grenzen und Bedeutung für diese Arbeit. Beide Arbeiten zeigen, dass CLIP-Features für die Blickschätzung nützlich sind. Eine Personalisierung mit kurzer Kalibrierung untersuchen sie aber nicht. Bei CLIP-Gaze bleibt offen, ob eine Anpassung des CLIP-Image-Encoders die Schätzung für eine Person verbessert. GazeCLIP braucht vollständiges Supervised Training auf Benchmarkdaten. Es behandelt weder Personalisierung mit wenigen Bildern noch falsche Kalibrierlabels, und die Daten gibt es laut Veröffentlichung nur auf Anfrage. CLIP-Features wurden in dieser Arbeit noch nicht untersucht; sie sind ein Kandidat für den Ausblick (Tabelle 2.3). Die Winkelfehler dieser Arbeiten sind nur Orientierungswerte. Sie lassen sich nicht direkt mit dem Diagonalfehler dieser Arbeit vergleichen.

2.6. Dateneffiziente Personalisierung

Allgemeine Modelle haben bei neuen Personen oft einen systematischen Versatz. Er entsteht durch Unterschiede im Auge, in der Gesichtsform und in der Kopfhaltung. Park et al. [13] sprechen von anatomischen Unterschieden zwischen Personen, die die Genauigkeit allgemeiner Netze begrenzen. Die Personalisierung soll diese Lücke mit möglichst wenig

Tabelle 2.3.: Vergleich von CLIP-Gaze, GazeCLIP und dieser Arbeit.

Aspekt	**CLIP-Gaze [25]**	**GazeCLIP [17]**	**Diese Arbeit**
Ziel	Domain Generalization	Supervised Gaze Regression	Personalisierung mit Webcam und wenigen Daten
Nutzung von CLIP	Bild- und Text Encoder eingefroren	Image Encoder mit Fine-Tuning, Text Encoder eingefroren	Nicht verwendet (Ausblick)
Architektur	ResNet-18, MLP-Filter, Regression Head	CLIP-ResNet-50, Cross-Attention, MLP	ResNet-18 (ImageNet), Regression Head
Labels der Zielperson	Keine	Vollständige Trainingsdaten	30 s bis 120 s Kalibrierung
Berichteter Fehler	Ca. 6,97° (Mittel über 4 Aufgaben)	3,5° / 4,7° / 7,3°	Diagonalfehler in %
Datenqualität	Modelliert blickfremde Faktoren	Grobe Richtung aus Text (unsicher)	`WAIT`-Bilder werden entfernt

Kalibrieraufwand schließen. Die folgenden Abschnitte beschreiben klassische Kalibrierung, Few-Shot- und Meta-Learning sowie parametereffiziente Verfahren.

2.6.1. Kalibrierverfahren

Bei der aktiven Kalibrierung schaut die Person nacheinander auf bekannte Punkte auf dem Bildschirm. Die Koordinaten dieser Punkte sind die Labels für die Anpassung. Typisch sind wenige feste Punkte oder ein Punkt, der sich über den Bildschirm bewegt. iTracker [1] verwendet bis zu 13 feste Punkte und trainiert darauf eine SVR pro Nutzer (Abschnitt 2.1.2). He et al. [26] zeigen, dass gute Verfahren mit nur 2 bis 5 Punkten pro Person besser sind als frühere Verfahren mit mehr als 13 Punkten. Auf Smartphones ist ihr bestes Modell mit höchstens fünf Punkten um 24 bis 26 % genauer als der damalige Stand der Technik und läuft in Echtzeit auf dem Gerät. Sie schlagen außerdem ein Verfahren vor, das nur ungelabelte Gesichtsbilder braucht. Valliappan et al. [7] verwenden neben Punkten eine *Zickzack-Kalibrierung*: Ein Ziel bewegt sich 60 Sekunden lang langsam von links oben nach rechts unten, und die Frontkamera nimmt mit 30 Hz auf. Schon etwa 100 Bilder senken den Fehler fast auf ein Viertel.

Die Verfahren unterscheiden sich nicht nur darin, *wie viele* Daten sie brauchen, sondern auch darin, *welchen Teil* des Modells sie anpassen:

- **Offset-Kalibrierung:** Chen und Shi [27] teilen den Blickwinkel in einen Teil, der für alle Personen gleich ist, und einen persönlichen Versatz (Bias). Sie beobachten, dass der Versatz zwischen Personen größer ist als die Schwankung bei einer Person. Die Kalibrierung braucht dann nur einen einzigen Blickpunkt. Auf MPIIGaze und

EYEDIAP ist das Verfahren um bis zu 10 % besser als vergleichbare Modelle. Schon etwa neun Kalibrierbilder senken den Fehler deutlich.

- **Wenige Personenparameter:** Lindén et al. [28] beschreiben persönliche Unterschiede mit dem *Spatial Adaptive Gaze Estimator* (SPAZE) durch wenige latente Parameter. Die Kalibrierung ist dann nur ein kleines Optimierungsproblem und kaum anfällig für Overfitting. Mit neun Beispielen erreicht SPAZE 2,70° auf MPIIGaze, 14 % besser als der damalige Stand der Technik. Drei Parameter pro Auge reichen, um die persönlichen Unterschiede gut zu beschreiben.
- **Differenzielle Schätzung:** Liu et al. [29] trainieren ein CNN, das den *Unterschied* im Blick zwischen zwei Augenbildern derselben Person vorhersagt. Mit gelabelten Referenzbildern aus der Kalibrierung ergibt sich daraus der Blick im neuen Bild. Weil beide Bilder von derselben Person stammen, heben sich Störungen wie Augenform, Lidschluss oder Licht teilweise auf. Auf EYEDIAP, MPIIGaze und UT-Multiview ist das Verfahren schon mit einem einzigen Kalibrierbild besser als der Stand der Technik.
- **Personalisierung ohne Kalibrierung:** Zhao et al. [30] schlagen das *Episode-based Personalization Network* (EbPN) vor. Ein eigener Zweig des Netzes soll persönliche Abweichungen ohne Kalibrierdaten ausgleichen.

Zusammen zeigen diese Arbeiten: Ein großer Teil des persönlichen Fehlers lässt sich mit wenigen angepassten Parametern erklären. Das unterstützt die Strategie dieser Arbeit, nur einen kleinen Regression Head auf einem eingefrorenen Backbone anzupassen.

Cheng et al. [3] nennen einen grundsätzlichen Zielkonflikt: Längere Kalibrierungen machen die Schätzung genauer, sind aber unbequemer. Hohe Genauigkeit mit kurzer, einfacher Kalibrierung ist daher eine offene Forschungsfrage. Ein weiterer Punkt wird oft übersehen: die Qualität der Kalibrierlabels selbst. Wenn ein Ziel springt, folgt der Blick erst nach einer kurzen Verzögerung. Bilder aus dieser Transition Period können ein falsches Label haben (Abschnitt 2.9).

2.6.2. Few-Shot-Learning und Meta-Learning: FAZE

Park et al. [13] stellen mit FAZE (*Few-Shot Adaptive Gaze Estimation*) ein einflussreiches Verfahren für die Personalisierung mit wenigen Kalibrierbildern vor. Es verbindet getrennte (entflochtene) Features für Blick, Kopf und Aussehen mit Model-Agnostic Meta-Learning (MAML). FAZE trainiert nicht für jede Person ein neues Modell. Es lernt stattdessen einen Startpunkt, von dem aus wenige Beispiele für eine schnelle Anpassung reichen.

FAZE hat zwei Teile. Ein *Disentangling Transforming Encoder-Decoder* (DT-ED) auf DenseNet-Basis stellt Aussehen, Blickrichtung und Kopfhaltung in getrennten Codes dar.

Weil diese Codes mit Drehungen mitgehen (rotationsäquivariant), kann man Änderungen von Blick und Kopf als Drehungen im Feature Space beschreiben. Trainiert wird auf Bildpaaren derselben Person mit einem Reconstruction Loss, einem Gaze Loss und einem Konsistenzterm. Der zweite Teil ist ein Blickschätzer, der mit MAML meta-trainiert wird: Über viele Trainingspersonen lernt er einen Startpunkt, aus dem wenige Gradientenschritte ein persönliches Modell machen. Das soll Overfitting vermeiden, die beim normalen Fine-Tuning mit sehr wenigen Daten droht.

FAZE wird auf GazeCapture trainiert und auf GazeCapture und MPIIGaze getestet. Mit $k = 9$ Kalibrierbildern liegt der mittlere Fehler auf MPIIGaze bei 3,14°. Für alle $1 \leq k \leq 256$ ist FAZE besser als die verglichenen Verfahren. Auf GazeCapture sinkt der Fehler gegenüber dem Stand der Technik um 19 %, von 3,91° auf 3,18°.

Grenzen und Abgrenzung. FAZE zeigt, dass eine Kalibrierung nicht nur von der Datenmenge abhängt, sondern auch von den vorher gelernten Features und der Art der Anpassung. Die Features von FAZE kommen aber aus Supervised Training mit Blickdaten und einem DenseNet. Allgemeine vortrainierte Modelle (DINOv2, MAE, CLIP) werden nicht untersucht. Die Anpassung nutzt Meta-Learning; einfachere Wege wie reines Head-Training, LoRA oder Adapter stehen nicht im Mittelpunkt. Auch Webcam-typische Probleme wie schwankende Bildqualität, Brillen, Hintergründe und verschiedene Kameras werden nicht betrachtet, ebenso wenig das Entfernen von Kalibrierbildern nach der Aufnahmephase. Diese Arbeit greift einige dieser Punkte auf. Da FAZE Winkelfehler angibt und diese Arbeit einen Fehler relativ zur Bildschirmdiagonale, sind die Zahlen nicht direkt vergleichbar.

Tabelle 2.4.: Vergleich von FAZE und dieser Arbeit.

Aspekt	**FAZE [13]**	**Diese Arbeit**
Ziel	Personalisierung der Blickrichtung mit wenigen Bildern	Dateneffiziente Personalisierung der Bildschirmposition mit Webcam
Features	Entflochtene Codes, DenseNet-Encoder-Decoder	ResNet-18, auf ImageNet vortrainiert und eingefroren
Pretraining	Supervised auf GazeCapture	ImageNet; Regression Head auf GazeCapture
Anpassung	MAML und Gradientenschritte pro Person	Nur Regression Head
Kalibrierdaten	$k = 1$ bis 256 Bilder	30 s bis 120 s (ca. 180–720 Labels)
Labelqualität	Keine Filterung nach Phase	`WAIT`-Bilder über Phasenprotokoll entfernt
Evaluation	GazeCapture und MPIIGaze	18 Webcam-Sitzungen unter wechselnden Bedingungen
Berichteter Fehler	3,14° (MPIIGaze, $k = 9$)	Diagonalfehler in %, nicht direkt vergleichbar

Yu et al. [31] erweitern die Anpassung mit wenigen Bildern: Aus wenigen Referenzbildern einer Person erzeugen sie mit Blickumlenkung (Gaze Redirection) zusätzliche Trainingsbilder und passen damit ein allgemeines Modell an.

2.6.3. Parametereffizientes Fine-Tuning (PEFT)

Parametereffiziente Verfahren passen nur einen kleinen Teil der Parameter an. Der vortrainierte Backbone bleibt fast unverändert. Das spart Speicher und Rechenzeit und senkt die Gefahr von Overfitting, wenn es nur wenige Kalibrierdaten gibt. Für diese Arbeit sind drei Varianten wichtig:

- **Reines Head-Training (nur FC):** Der Backbone bleibt komplett eingefroren, nur der Regression Head wird trainiert. Man kann die Features des Backbones einmal berechnen und speichern. Deshalb ist dieses Verfahren besonders schnell. Diese Arbeit verwendet es.
- **Adapter** [32]: Kleine zusätzliche Module werden zwischen die Schichten eines eingefrorenen Netzes gesetzt. Nur sie werden trainiert.
- **Low-Rank Adaptation (LoRA)** [23]: Die vortrainierten Gewichtsmatrizen W bleiben fest. Trainiert wird nur eine Änderung $\Delta W = BA$ aus zwei schmalen Matrizen mit niedrigem Rang r. So gibt es viel weniger trainierbare Parameter.

In der Blickschätzung wurden solche Verfahren bisher kaum systematisch untersucht. Eine Ausnahme ist TPGaze [33]. Es überträgt das Prompt-Tuning aus der Sprachverarbeitung: Ein zusätzlicher Prompt mit weniger als 1 % der Parameter eines ResNet-18 wird zur Testzeit ohne Labels angepasst. Meta-Learning sorgt dafür, dass diese Anpassung den Blickfehler wirklich senkt (Abschnitt 2.8). Bao und Lu [34] zeigen außerdem, dass gerade die letzte vollständig verbundene Schicht, die viele Bild-Features auf den Blick abbildet, leicht zu Overfitting neigt. Auch beim reinen Head-Training ist der Aufbau des Heads also wichtig. Die anderen hier betrachteten Arbeiten nutzen vollständiges Fine-Tuning (UniGaze, GazeCLIP), Meta-Learning (FAZE) oder ein eingefrorenes Modell, das ein separat trainiertes Netz steuert (CLIP-Gaze). Diese Arbeit untersucht reines Head-Training für die Personalisierung mit kurzen Webcam-Kalibrierungen. Adapter und LoRA bleiben für spätere Arbeiten.

2.7. Domain Shift, Generalisierung und Evaluationsprotokolle

2.7.1. Evaluation mit unbekannten Personen

Wie gut ein Modell auf neue Personen generalisiert, hängt stark vom Evaluationsprotokoll ab. Bei einer zufälligen Aufteilung (`norm_random`) können Bilder derselben Person in Training und Test landen. In dieser Arbeit werden dabei Gruppen aus Person und Zielpunkt aufgeteilt: Alle Bilder, in denen eine Person auf denselben Punkt schaut, liegen zusammen entweder im Training oder im Test; dieselbe Person kommt aber in beiden Teilen vor. Das Modell kann dann Features dieser Person ausnutzen, und die Generalisierung wird überschätzt. Bei einem personendisjunkten Split (`norm_subject`) werden dagegen die Personen aufgeteilt (hier 80 % Training, 20 % Test): Alle Bilder einer Person liegen nur im Training oder nur im Test. Dieses Datenleck gibt es dann nicht (ähnlich wie bei Leave-one-subject-out). Man misst dann die Leistung auf wirklich unbekannten Personen. In den Basisexperimenten dieser Arbeit auf GazeCapture ergibt `norm_subject` einen Testfehler von 28,39 % und `norm_random` 27,72 %. Der größte Teil dieses Unterschieds kommt aber von den unterschiedlichen Testdaten: Auch die Konstant-Baseline ist auf `norm_random` niedriger (27,66 % statt 28,46 %, siehe Kapitel 4).

Davon zu unterscheiden sind Tests über Datensätze hinweg, zum Beispiel Leave-one-dataset-out in UniGaze [15]. Dort wird ein ganzer Datensatz zurückgehalten. Beide Protokolle messen also verschiedene Arten der Generalisierung: auf unbekannte Personen in derselben Umgebung bzw. auf unbekannte Aufnahmebedingungen.

2.7.2. Domain Adaptation und Domain Generalization

Wenn sich Trainings- und Testdaten in Personen, Kameras oder Umgebung unterscheiden, werden erscheinungsbasierte Verfahren deutlich schlechter. Es gibt zwei Gegenstrategien. Die Domain Adaptation nutzt (meist ungelabelte) Daten aus der Zielumgebung. Die Domain Generalization braucht gar keine Zieldaten.

CRGA. Wang et al. [35] schlagen mit *Contrastive Regression Gaze Adaptation* (CRGA) eine Unsupervised Domain Adaptation vor. Ein Modul für *Contrastive Domain Generalization* (CDG) lernt stabile Features in der Source Domain: Features mit ähnlichem Blick werden zusammengezogen, Features mit sehr unterschiedlichem Blick auseinandergeschoben. Ein Modul für *Contrastive Self-training Adaptation* (CSA) lernt danach mit Pseudo-Labels in der Target Domain. Mit ETH-XGaze und Gaze360 als Quelle und MPIIGaze, RT-GENE, GazeCapture und EyeDiap als Ziel verbessern die Autoren die Baseline um 40,4 %, 34,7 %, 55,8 % und 34,3 % (Quelle ETH-XGaze) bzw. um 31,7 %, 30,5 %, 32,9 % und 23,8 % (Quelle Gaze360).

CRGA löst also ein anderes Problem: die Anpassung an eine neue Umgebung ohne gelabelte Zieldaten. Diese Arbeit nutzt dagegen wenige gelabelte Kalibrierdaten der Zielperson. Damit ist Supervised Training mit echten Labels möglich, nicht nur mit Pseudo-Labels. Selbsttraining mit Pseudo-Labels kann außerdem einen Bestätigungsfehler (Confirmation Bias) erzeugen: Falsche Vorhersagen werden im weiteren Training verstärkt. Zudem geht es hier um Unterschiede zwischen Personen und nicht um den Wechsel zwischen Benchmark-Datensätzen. CRGA ist daher verwandte Arbeit zur Robustheit, aber keine direkt vergleichbare Baseline.

Domain Generalization. Verfahren wie PureGaze [36] oder CLIP-Gaze [25] (Abschnitt 2.5.3) versuchen, blickfremde Faktoren schon im Training aus den Features zu entfernen. Dann funktioniert das Modell auch ohne Zieldaten in neuen Umgebungen. UniGaze [15] zeigt, dass großes blickspezifisches Pretraining diese Verfahren bei Tests über Datensätze hinweg übertreffen kann (Abschnitt 2.5.2).

2.7.3. Blickschätzung für mehrere Personen

Zhang et al. [37] stellen mit GazeOnce ein einstufiges Verfahren vor. Es schätzt den Blick aller Personen in einem Bild in einem einzigen Durchlauf und bleibt auch bei mehr als zehn Gesichtern echtzeitfähig. Neben der Blickrichtung sagt es auch Gesichtsrahmen (Bounding Boxes) und Gesichtspunkte (Landmarken) vorher. Ein Self-Supervised Loss prüft, ob die geschätzte 3D-Richtung zu ihren 2D-Projektionen passt. Für das Training erzeugen die Autoren den synthetischen Datensatz MPSGaze: Sie setzen Gesichter aus ETH-XGaze mit bekanntem Blick in passende Gesichter aus WiderFace ein. Laut den Autoren ist GazeOnce genauer und schneller als bestehende Verfahren, besonders bei vielen Gesichtern.

GazeOnce löst damit ein anderes Problem: den Blick vieler Personen in freien Szenen, nicht die Personalisierung für einen Webcam-Nutzer. Methodisch interessant ist die Konsistenz zwischen 3D-Richtung und 2D-Projektion. MPSGaze zeigt außerdem, dass synthetische Trainingsdaten sich von echten Webcam-Bildern unterscheiden können.

2.7.4. Unterschiede bei Geräten und Umgebung

Neben Unterschieden zwischen Datensätzen beeinflussen viele Faktoren von Gerät und Umgebung die Genauigkeit: Brille und Verdeckungen, Hintergrund und Licht, Bildauflösung und Kameraabstand sowie die Lage von Kamera und Bildschirm. Die Literatur gibt einige Hinweise:

- Cheng et al. [3] beobachten deutlich größere Fehler bei großem Abstand und niedriger Auflösung (Gaze360, RT-GENE).

- GazeCLIP [17] nennt schlechtes Licht und Verdeckung durch Haare oder Brille als typische Fehlerfälle.
- UniGaze [15] betont, wie wichtig viele verschiedene Kopfhaltungen und ein großer Bereich der Blicklabels sind.
- CLIP-Gaze [25] modelliert Zubehör und Bildqualität ausdrücklich als blickfremde Faktoren.

Systematische Untersuchungen dieser Faktoren bei der Personalisierung mit kurzen Webcam-Kalibrierungen fehlen aber weitgehend. Diese Arbeit betrachtet deshalb über mehrere Sitzungen auch zwei Geräte mit verschiedenen Webcams, Brille, Hintergrund und Kalibrierdauer (siehe Kapitel 4).

2.8. Test-Time Adaptation

Bei der *Test-Time Adaptation* (TTA, dt. Anpassung zur Testzeit) wird ein fertig trainiertes Modell erst während der Nutzung an die Person oder die Umgebung angepasst, meist mit wenigen oder gar keinen Labels. Anders als bei der klassischen Kalibrierung (Abschnitt 2.6.1) soll der Nutzer dabei möglichst wenig selbst tun müssen.

2.8.1. TTP-GE: Self-Supervised und Weakly Supervised Adaptation

Nagpure et al. [16] stellen mit TTP-GE (*Test-Time Personalized Gaze Estimation*) ein zweistufiges Verfahren für die Blickschätzung im Auto vor. Es baut auf GazeDPTR V2 auf. Diese Architektur hat zwei Zweige: einen für das Originalbild des Gesichts und einen für ein normalisiertes Gesichtsbild. Ein Transformer führt die Features zusammen. Mit Positionsinformation aus einer Punktprojektion kann das Modell zusätzlich Blickzonen erkennen.

Das Meta-Training nutzt zwei Schleifen auf Basis von MAML. In der inneren Schleife passt ein Self-Supervised Consistency Loss (im Stil von BYOL++) das Modell an neue Personen an – ohne Blicklabels. Die äußere Schleife optimiert Gaze Regression und Zonenerkennung mit gelabelten Daten. Zur Testzeit gibt es zwei Schritte: Zuerst passt sich das Modell mit Self-Supervised Learning an ungelabelte Bilder der Person an; das hilft bei veränderten Bildbedingungen. Danach wird die Zonenerkennung mit wenigen Zonenlabels angepasst (zum Beispiel Spiegel, Armaturenbrett, Windschutzscheibe). Diese Labels werden in einer kurzen Einrichtungsphase gesammelt.

Auf IVGaze (44 705 Bilder von 125 Personen) erreicht die Kombination einen mittleren Fehler von 6,00°. Die Baseline liegt bei 6,78°, nur *Weakly Supervised Adaptation* (dt. schwach überwachte Anpassung, hier mit wenigen groben Zonenlabels) bei 6,13° und nur

Self-Supervised Adaptation (dt. selbstüberwachte Anpassung, ganz ohne Labels) bei 6,72°. Der Anteil der Schätzungen mit weniger als 6° Fehler steigt von 49,95 % auf 58,2 %. Die beiden Schritte ergänzen sich also: Die Selbstüberwachung behandelt die Bildbedingungen, die Zonenlabels liefern persönliche Information.

2.8.2. Weitere labelsparende Verfahren

Einige neuere Arbeiten verfolgen ähnliche Ziele mit anderen Mitteln:

- **TPGaze** [33] passt zur Testzeit nur einen meta-gelernten Prompt an. Er hat weniger als 1 % der Parameter eines ResNet-18. Als Ziel ohne Labels reicht ein einfacher Symmetry Loss. Laut den Autoren ist die Anpassung bis zu zehnmal schneller als bei anderen Verfahren. Getestet wird in vier Szenarien über Datensätze hinweg.
- **ELF-UA** [38] behandelt die Anpassung *ohne Labels* als eigenes Problem: Wenige ungelabelte Bilder der Person reichen. Das Meta-Learning nutzt eine Schranke aus der Domain Adaptation als Loss Function.
- **PIGaze** [39] gewinnt Kalibrierdaten im Auto automatisch: Der Blick auf bekannte Zonen wie Spiegel und Windschutzscheibe muss geometrisch zusammenpassen (Selbstkalibrierung). Ein vortrainiertes Basismodell ist ein *eingefrorener* Feature Extractor. Darauf lernt ein kleiner Adapter die persönliche Abbildung. Auf IVGaze und LBW ist PIGaze besser als Fine-Tuning.

Grenzen und Abgrenzung. Diese Verfahren wollen den Kalibrieraufwand mit ungelabelten oder schwach gelabelten Daten senken. Sie schätzen meist 3D-Blickrichtungen und arbeiten bei TTP-GE und PIGaze im Auto mit festen Zonen. Ihre Anpassung (Meta-Training, Online-Updates, EMA-Zielnetze) ist deutlich aufwendiger als einfaches Head-Training. Allgemeine vortrainierte Modelle wie DINOv2, CLIP oder MAE werden nicht als Backbone untersucht. Diese Arbeit verfolgt den ergänzenden Weg einer *Supervised* Personalisierung mit Bildschirmkoordinaten aus einer kurzen Kalibrierung. Interessant ist aber, dass PIGaze – wie diese Arbeit – einen eingefrorenen Backbone mit einem kleinen, persönlich trainierten Modul kombiniert.

2.9. Datenqualität, falsche Labels und zeitlicher Ablauf

Supervised Personalisierung setzt voraus, dass jedes Kalibrierbild das richtige Label hat, also den Punkt, auf den die Person in diesem Moment wirklich schaut. In der Praxis stimmt das nur ungefähr. Abweichungen zwischen Label und echtem Blick nennt man

Tabelle 2.5.: Vergleich von TTP-GE und dieser Arbeit.

Aspekt	**TTP-GE [16]**	**Diese Arbeit**
Ansatz	Test-Time Adaptation mit ungelabelten Bildern und wenigen Zonenlabels	Supervised Personalisierung mit gelabelten Kalibrierdaten
Backbone	GazeDPTR V2: zwei ResNet-18-Zweige mit Transformer-Fusion	ResNet-18 (ImageNet), eingefroren
Labels	Ungelabelte Bilder und neun Blickzonen	Bildschirmkoordinaten; `WAIT`-Bilder werden entfernt
Anpassung	Meta-Training, Online-Updates, EMA-Zielnetz	Nur Regression Head
Anwendung	Fahrerüberwachung im Auto	Webcam vor einem Bildschirm
Ergebnis	6,00° auf IVGaze	Diagonalfehler in %, nicht direkt vergleichbar

Label Noise (dt. Label-Rauschen). Bei kurzen Kalibrierungen ist es besonders schädlich, weil jedes falsche Bild einen großen Anteil der Trainingsdaten ausmacht.

2.9.1. Datenqualität im Eye-Tracking

In der Eye-Tracking-Forschung beschreibt man die Datenqualität meist mit drei Größen. Niehorster et al. [40] geben einen aktuellen Überblick, wie man sie misst, und stellen Werkzeuge dafür bereit. Für N Messungen, bei denen die Person auf ein bekanntes Ziel schaut, gilt:

- **Accuracy** (dt. Genauigkeit): die *systematische* Abweichung zwischen gemessenem und wahrem Blickpunkt, meist als mittlerer Winkelfehler

$$\text{Acc} = \frac{1}{N} \sum_{i=1}^{N} \theta_i,$$

  wobei θ_i der Winkel zwischen gemessenem und wahrem Blick ist.

- **Precision** (dt. Präzision): die *Streuung* wiederholter Messungen, unabhängig vom wahren Ziel. Üblich ist der RMS-Wert zwischen aufeinanderfolgenden Messungen

$$\text{RMS-S2S} = \sqrt{\frac{1}{N-1} \sum_{i=1}^{N-1} \theta_{i,i+1}^2},$$

  mit $\theta_{i,i+1}$ als Winkel zwischen Messung i und $i+1$, oder die Standardabweichung der Messungen um ihren Mittelwert.

- **Data Loss** (dt. Datenverlust): der Anteil der Messungen ohne gültigen Blickwert, $\mathrm{DL} = N_{\text{ungültig}}/N \cdot 100\,\%$.

Der Unterschied: Ein Eye-Tracker kann präzise, aber ungenau sein (die Messungen liegen dicht beieinander, aber neben dem Ziel), oder genau, aber unpräzise (der Mittelwert stimmt, aber die Messungen streuen stark). Der Diagonalfehler dieser Arbeit ist ein RMSE und enthält damit beides: die systematische Abweichung und die Streuung. Bei lernenden Verfahren kommt eine vierte Größe dazu: die Qualität der *Trainingslabels*. Falsche Labels verfälschen nicht nur die Auswertung, sondern auch das gelernte Modell.

2.9.2. Reaktionszeit und Saccades

Wenn ein Kalibrierziel an einer neuen Stelle erscheint, folgt der Blick nicht sofort. Bis die *Saccade* beginnt (dt. Saccade: eine sehr schnelle Augenbewegung zu einem neuen Ziel), vergeht eine kurze Reaktionszeit. Valliappan et al. [7] messen auf Smartphones im Mittel 210 ms (Median 167 ms). Das passt zu früheren Studien mit 200 ms bis 250 ms. Danach kommen die Saccade selbst und eventuell kleine Korrekturen, bis das Auge ruhig auf dem Ziel bleibt.

Bilder aus dieser *Transition Period* (dt. Übergangszeit) haben das Label der *neuen* Position. Der Blick ist aber noch auf der *alten* Position oder irgendwo dazwischen. Bei 30 fps betrifft allein eine Reaktionszeit von etwa 200 ms rund sechs Bilder pro Sprung. Je öfter das Ziel springt, desto mehr Bilder haben ein falsches Label.

2.9.3. Filtern schon bei der Aufnahme

Eine einfache Gegenmaßnahme: Man verwirft die Bilder direkt nach einem Zielwechsel. Valliappan et al. [7] verwerfen zum Beispiel immer die ersten 800 ms nach jedem neuen Ziel. Ein festes Zeitfenster ist leicht umzusetzen. Es beruht aber auf einer Annahme über die Dauer des Übergangs, und seine Wirkung wird meist nicht eigens untersucht.

Diese Arbeit geht einen ähnlichen, aber genaueren Weg. Das Aufnahmeprogramm speichert für jedes Bild die aktuelle *Phase* des Ziels: `WAIT` (eine kurze Wartezeit von 0,5 s direkt nach einem Sprung) oder `MOVE` (das Ziel bewegt sich danach 4,5 s lang). So kann man die `WAIT`-Bilder eindeutig und reproduzierbar erkennen und vor dem Training entfernen. In den Aufnahmen betrifft das etwa 10 % der Bilder. Anders als ein festes Zeitfenster erlaubt dieses Protokoll einen direkten Vergleich: Modelle mit und ohne bereinigte Daten unter sonst gleichen Bedingungen.

2.9.4. Filtern nach der Aufnahme und robuste Lernverfahren

Andere Verfahren erkennen falsche Labels erst *nach* der Aufnahme mit statistischen oder modellbasierten Kriterien.

DMRF. Jiang et al. [41] schlagen mit *Dynamic Multi-model Regression Filtering* (DMRF) ein allgemeines Verfahren gegen falsche Labels in Regressionsaufgaben vor. Es löst ein *Chicken-and-Egg Problem* (dt. Henne-Ei-Problem: Zwei Dinge hängen gegenseitig voneinander ab, sodass unklar ist, womit man beginnen soll): Falsche Labels verzerren die Modelle, mit denen man das Noise schätzt, und verzerrte Modelle schätzen das Noise falsch. DMRF hat drei Teile:

1. eine *Aufwärmfilterung* mit einer Verteilungsfunktion der geschätzten Fehler,
2. eine *dynamische Modellauswahl* nach einem Korrelationskriterium,
3. einen *Rückhol-Schritt* (Data Recall), der Beispiele mit kleinem Loss wieder zu den sauberen Daten nimmt.

Neben 15 Benchmarks aus UCI und KEEL und einer Altersschätzung wird DMRF in das Blickverfahren L2CS-Net eingebaut. Auf einem vorverarbeiteten MPIIGaze-Datensatz mit 45 000 Bildern (Leave-one-person-out) sinkt der mittlere Fehler von 3,92° auf 3,85°. Dabei bleiben 74,3 % der Daten erhalten. Der Code ist öffentlich.

SeeTN. Peng et al. [42] untersuchen als Erste systematisch, wie falsche Labels die Domain Generalization in der Blickschätzung beeinflussen. In einem Vorversuch verfälschen sie 10, 20 und 30 % der Gaze360-Labels mit starkem Gaussian Noise. Der Fehler einer ResNet-18-Baseline auf MPIIGaze steigt dadurch von 7,94° auf 12,17° (20 %) bzw. 14,38° (30 %). Ihr Verfahren *See-Through-Noise* baut einen semantischen Feature Space auf. Es erkennt falsche Beispiele daran, dass Feature und Label nicht zusammenpassen, und überträgt Blickinformation von sauberen auf falsche Beispiele.

Vorher oder nachher filtern? Verfahren wie DMRF und SeeTN erkennen falsche Labels aus den Daten selbst. Sie finden daher auch unerwartete Fehlerquellen. Sie brauchen aber genug Beispiele für eine sichere Schätzung, rechnen aufwendiger und wurden bisher nur auf großen Datensätzen getestet, nicht auf kurzen Kalibrierungen einer Person. Das Phasenprotokoll erfasst dagegen nur eine *bekannte* Fehlerquelle, die durch den Ablauf der Aufnahme entsteht – dafür aber eindeutig und ohne zusätzliches Modell. Beide Ansätze ergänzen sich (Tabelle 2.6).

Tabelle 2.6.: Vergleich von nachträglicher Filterung (DMRF) und Phasenprotokoll.

Kriterium	**DMRF [41]**	**Diese Arbeit**
Strategie	Nachher: Fehler schätzen und filtern	Vorher: Phase bei der Aufnahme speichern
Erkennung	Modellvorhersagen, Fehlermuster, dynamische Modellauswahl	`WAIT`/`MOVE`-Label pro Bild
Erfasste Fehler	Alle statistisch auffälligen Beispiele	Nur die Transition Period nach einem Sprung
Erhaltene Daten	74,3 % (MPIIGaze)	Ca. 90 %
Anwendung	Viele Personen, Leave-one-person-out	Webcam-Kalibrierung einer Person
Zusatzaufwand	Mehrere Regressionsmodelle, iteratives Training	Kein zusätzliches Modell
Ergebnis	$3{,}92° \rightarrow 3{,}85°$	Diagonalfehler in %, nicht direkt vergleichbar

2.10. Vergleich und kritische Diskussion

Tabelle 2.7 fasst die wichtigsten Arbeiten dieses Kapitels zusammen. Die Spalten sind: Ziel, verwendete Features, Art der Personalisierung und Umgang mit der Labelqualität.

Kritische Diskussion. Aus dem Vergleich ergeben sich vier Beobachtungen:

1. **Features und Personalisierung werden getrennt untersucht.** Arbeiten zu großen vortrainierten Modellen (UniGaze, CLIP-Gaze, GazeCLIP) zielen auf Generalisierung über Datensätze hinweg und nutzen vollständiges Fine-Tuning mit vielen Daten. Arbeiten zur Personalisierung (FAZE, SPAZE, Chen & Shi) nutzen dagegen CNNs, die speziell für den Blick trainiert wurden. Wie gut sich allgemeine vortrainierte Modelle mit wenigen Kalibrierdaten personalisieren lassen, ist offen.

2. **Wenige Parameter reichen oft.** Offset-Kalibrierung, wenige Personenparameter, Prompt-Tuning und eingefrorene Modelle mit Adaptern (PIGaze) zeigen übereinstimmend: Ein großer Teil des persönlichen Fehlers lässt sich mit wenigen angepassten Parametern erklären. Kumar et al. [22] liefern dafür eine allgemeine Begründung.

3. **Falsche Labels werden meist erst nachher behandelt.** DMRF und SeeTN filtern oder gewichten falsche Labels in großen Datensätzen. Fehler durch den Ablauf kurzer Kalibrierungen werden, wenn überhaupt, mit festen Zeitfenstern behandelt (Valliappan et al.), ohne ihren Einfluss genau zu untersuchen.

Tabelle 2.7.: Vergleich der wichtigsten Arbeiten. k = Anzahl der Kalibrierbilder pro Person. Die Fehler stammen aus verschiedenen Protokollen und Metriken und sind nicht direkt vergleichbar.

Arbeit	**Ziel**	**Features**	**Personalisierung**	**Labelqualität**	**Ergebnis**
iTracker [1]	2D-Blick, mobil	CNN-Zweige ähnlich AlexNet	SVR, bis zu 13 Punkte	–	1,34 cm (Smartphone)
FAZE [13]	Wenige Bilder	DenseNet-DT-ED, supervised	MAML, $k \leq 256$	–	3,14° ($k = 9$)
SPAZE [28]	Wenige Bilder	CNN, latente Personenparameter	Kleines Optimierungsproblem	–	2,70° ($k = 9$)
Chen & Shi [27]	Offset-Kalibrierung	CNN	Versatz aus einem Blickpunkt	–	bis zu 10 % besser
Valliappan [7]	Smartphone	CNN, vortrainiert auf GazeCapture	Fine-Tuning + Regression, ca. 30 s	Feste 800-ms-Verwerfung	0,46 cm
CRGA [35]	Unsupervised DA	ResNet (ImageNet)	Pseudo-Labels	–	bis zu 55,8 % besser
UniGaze [15]	Generalisierung	MAE-ViT, 1,6 Millionen Gesichter	Vollständiges Fine-Tuning	–	4,65–5,86° (DG)
CLIP-Gaze [25]	Generalisierung	CLIP (eingefroren) + ResNet-18	–	Blickfremde Faktoren	6,97° (DG)
GazeCLIP [17]	Supervised Regression	CLIP-ResNet-50 (Fine-Tuning)	–	–	3,5° (MPIIFaceGaze)
TTP-GE [16]	Test-Time Adaptation	GazeDPTR V2	Self- + weakly supervised	–	6,00° (IVGaze)
TPGaze [33]	Test-Time Adaptation	ResNet-18	Prompt (¡1 % der Parameter)	–	–
DMRF [41]	Falsche Labels filtern	L2CS-Net	–	Nachher, modellbasiert	3,85° (MPIIGaze)
SeeTN [42]	Robuste Generalisierung	ResNet-18/50	–	Nachher, feature-basiert	–
Diese Arbeit	Webcam-Personalisierung	ResNet-18 (ImageNet), eingefroren	Nur Head; 30 s bis 120 s	Vorher, Phasenprotokoll	Diagonalfehler in %

4. **Die Ergebnisse sind kaum vergleichbar.** Die Arbeiten geben Winkel in Grad, Abstände in Zentimetern oder relative Verbesserungen an und nutzen verschiedene Datensätze, Splits und Protokolle. Einen Winkelfehler kann man nur mit bekannter Geometrie (Abstand, Bildschirmgröße) in einen Bildschirmfehler umrechnen. Die Metrik dieser Arbeit, der euklidische Fehler relativ zur Bildschirmdiagonale, ist daher nicht direkt mit der Literatur vergleichbar. Die Zahlen in Tabelle 2.7 dienen der Orientierung, nicht als Rangliste.

2.11. Forschungslücken und Bezug zu dieser Arbeit

2.11.1. Forschungslücken

Aus dem Stand der Technik ergeben sich vier Forschungslücken:

F1: Dateneffiziente Personalisierung vortrainierter Modelle. Große vortrainierte Modelle (ImageNet-CNNs, DINOv2, CLIP, MAE oder UniGaze) wurden für die Blickschätzung bisher vor allem mit vollständigem Fine-Tuning auf großen Datensätzen untersucht. Es fehlen Untersuchungen, wie gut sie sich mit nur wenigen Minuten Webcam-Kalibrierung an eine Person anpassen lassen.

F2: Sparsame Anpassung für die Personalisierung. Mehrere Arbeiten zeigen, dass wenige angepasste Parameter den größten Teil des persönlichen Fehlers erfassen. Trotzdem wurden reines Head-Training, Adapter und LoRA für die Personalisierung in der Blickschätzung kaum systematisch verglichen.

F3: Labelqualität kurzer Kalibrierungen. Reaktionszeit und Zielwechsel erzeugen Kalibrierbilder mit falschem Label. Bisherige Arbeiten behandeln falsche Labels meist nachher in großen Datensätzen oder verwerfen feste Zeitfenster. Wie sich ein genaues, protokollbasiertes Entfernen solcher Bilder auf die Personalisierung auswirkt, wurde noch nicht untersucht.

F4: Realistische Evaluation unter Webcam-Bedingungen. Viele Ergebnisse stammen aus Benchmarks mit kontrollierten Bedingungen oder aus zufälligen Splits auf Bildebene, die die Generalisierung überschätzen können. Wie Kamera, Brille, Hintergrund und Kalibrierdauer die Personalisierung beeinflussen, ist kaum dokumentiert.

2.11.2. Was diese Arbeit beiträgt

Diese Arbeit bearbeitet die Lücken mit einer einfachen und reproduzierbaren Personalisierungspipeline für Webcam-Eye-Tracking:

- **Eingefrorener Backbone mit kleinem Regression Head (F1, F2):** Ein auf ImageNet vortrainiertes ResNet-18 bleibt eingefroren. Seine Features werden gespeichert, und nur ein kleiner Regression Head wird pro Person trainiert. Ich vergleiche außerdem, ob das Trainieren weiterer Schichten hilft. Andere Backbones (DINOv2, CLIP, MAE, UniGaze) und Adapter oder LoRA sind der nächste Schritt (Kapitel 6).
- **Phasenprotokoll und Bereinigung (F3):** Das Aufnahmeprogramm speichert die Phasen `WAIT` und `MOVE`. So lässt sich die Wirkung des Entfernens von Transition Frames kontrolliert messen: Modelle mit ursprünglichen und mit bereinigten Daten werden unter sonst gleichen Bedingungen verglichen.
- **Systematische Ablationen:** Batch Size, Learning Rate, trainierbare Schichten, Activation, Loss Function (auch ein nach Position gewichteter L1-Loss) und Datenmenge werden mit wiederholten Läufen und Confidence Intervals untersucht.
- **Realistische Evaluation (F4):** Die Basismodelle werden mit dem personendisjunkten Split `norm_subject` bewertet. Die Personalisierung wird auf 18 Sitzungen mit wechselnder Webcam (zwei Geräte), Brille, Hintergrund und Kalibrierdauer getestet, und zwar mit zufälligem und mit zeitlichem Split.

Kapitel 3 beschreibt die Methodik, Kapitel 4 die Ergebnisse. Kapitel 5 beantwortet damit die Forschungsfragen aus Kapitel 1.

3. Methodik

Dieses Kapitel gibt einen Überblick über das Vorgehen: Daten (Abschnitte 3.1 und 3.2), Vorverarbeitung (Abschnitt 3.3), Modell und Training (Abschnitt 3.4), Auswertung (Abschnitt 3.5) und Implementierung (Abschnitt 3.6). Die genauen Einstellungen der Experimente stehen in Abschnitt 4.1.

3.1. Datensätze

Die Arbeit nutzt zwei Datenquellen:

- **GazeCapture** [1] für die Basismodelle. Der vollständige Datensatz hat 2 445 504 Bilder von 1474 Personen. Verwendet wird eine öffentlich verfügbare Teilmenge von Kaggle [43]. Für jede Person werden die Bilder und die zugehörigen Zielpunkte auf dem Bildschirm aus den Metadaten gelesen. Personen mit unvollständigen Metadaten werden übersprungen. So entstehen 347 085 gelabelte Bilder von 262 Personen auf iPhones und iPads. Es gibt zwei Splits, jeweils 80/20: `norm_subject` (80 % der Personen im Training, 20 % im Test; keine Person in beiden) und `norm_random` (zufällig nach Gruppen aus Person und Zielpunkt; dieselbe Person kann in Training und Test vorkommen). Für die Experimente werden 1000 Trainings- und 200 Testbilder zufällig gezogen, dazu 200 Validierungsbilder einer weiteren Person.
- **Eigene Aufnahmen** für die Personalisierung. Person A (der Autor) hat 27 Kalibriersitzungen mit zwei Laptop-Webcams aufgenommen; 18 davon werden ausgewertet. Zum Vergleich hat eine zweite Person (Person B) zwei Sitzungen aufgenommen (Abschnitt 3.2).

3.2. Aufnahme der Personalisierungsdaten

Ein Aufnahmeprogramm zeigt einen roten Punkt auf dem Bildschirm, und die Person folgt ihm mit den Augen. Gleichzeitig nimmt die Webcam Bilder auf. Zu jedem Bild wird die Position des Punktes gespeichert, und zwar 6 Labels pro Sekunde. Die Positionen werden direkt auf $[0,1]^2$ normiert. Es gibt drei verwendete Generationen des Programms:

- **Gen 1** (Sitzungen 01–04): Der Punkt bewegt sich gleichmäßig und ohne Sprünge über den ganzen Bildschirm.
- **Gen 2** (Sitzungen 05–09): Der Punkt springt alle 1,4 bis 2,7 Sekunden an eine zufällige neue Stelle. Die Aufnahmen sind kurz (etwa 30 s).
- **Gen 4** (Sitzungen 19–27): Die Aufnahme besteht aus Abschnitten von 5 s. Jeder Abschnitt beginnt mit 0,5 s `WAIT` an einem neuen Startpunkt; danach bewegt sich der Punkt 4,5 s lang (`MOVE`). 90 % der Startpunkte liegen in den Ecken. Das Programm speichert die Phase zu jedem Bild.

Gen 3 (Sitzungen 10–18) wurde verworfen, weil das Modell daraus nichts lernen konnte. Die Sitzungen unterscheiden sich außerdem in Licht, Hintergrund, Brille, Dauer (90 oder 120 s in Gen 4) und im Gerät. Es wurden zwei Laptops mit jeweils eingebauter Webcam verwendet: *Gerät A*, ein Microsoft Surface Pro 9 (Bildschirmbereich 1430 × 880 Pixel), für die Sitzungen 01–03 und 25–27, und *Gerät B*, ein HP-Laptop (1870 × 1000 Pixel), für die Sitzungen 05–09 und 19–24. Für Sitzung 04 ist das Gerät nicht protokolliert. Die Bilder werden auf beiden Geräten mit 640 × 480 Pixeln gespeichert. Tabelle 4.12 zeigt alle Bedingungen.

Zum Vergleich hat eine zweite Person (Person B) zwei Sitzungen mit Gen 4 aufgenommen (120 s, 90 % Ecken, ohne Brille, hell): Sitzung 28 mit Gerät A vor einem ruhigen weißen Hintergrund und Sitzung 29 mit Gerät B vor einem unruhigen Hintergrund mit Fenster. Sitzung 28 nutzt einen etwas kleineren Bildschirmbereich (1390 × 880 Pixel); die Normierung auf $[0,1]^2$ gleicht das aus. Die Sitzungen von Person B werden getrennt ausgewertet (Abschnitt 4.8) und gehen nicht in die Mittelwerte der 18 Sitzungen von Person A ein.

3.3. Vorverarbeitung

- **Zielwerte:** Die Blickziele von GazeCapture werden durch Breite und Höhe des jeweiligen Bildschirms geteilt. So liegen alle Ziele im Einheitsquadrat $[0,1]^2$, unabhängig vom Gerät (Abschnitt 4.1.4).
- **Bilder:** Das ganze Kamerabild wird auf 224 × 224 Pixel skaliert und mit den Mittelwerten und Standardabweichungen von ImageNet normiert. Es gibt keinen Gesichts- oder Augenausschnitt.
- **Bereinigte Labels:** Für Gen 4 kann man die `WAIT`-Bilder entfernen, weil die Phase zu jedem Bild protokolliert ist (Abschnitt 4.4.4).

3.4. Modell und Training

Das Modell besteht aus zwei Teilen:

1. einem **ResNet-18** [2], auf ImageNet vortrainiert, als Feature Extractor. Es liefert 512 Features pro Bild.
2. einem **Regression Head**: ein MLP aus vier vollständig verbundenen Schichten $512 \to 512 \to 256 \to 128 \to 2$ mit ReLU, Dropout $p = 0{,}2$ nach der zweiten Schicht und einer Activation am Ausgang (Standard: Sigmoid). Er berechnet daraus die Position (x,y).

Trainiert wird mit L1-Loss, AdamW (Learning Rate 10^{-4}, Weight Decay 10^{-5}), Batch Size 32 und Early Stopping (Abbruch nach drei Epochs ohne Verbesserung, höchstens 500 Epochs). Das Vorgehen hat zwei Stufen:

1. **Basismodell (E0):** Der Head wird auf GazeCapture trainiert. Von fünf Seeds wird der Lauf mit dem kleinsten Validierungsfehler behalten.
2. **Personalisierung (E1–E3):** Der Head des Basismodells wird mit den Bildern einer eigenen Sitzung weiter trainiert. Der Backbone bleibt dabei eingefroren, auch die BatchNorm-Statistiken.

Weil der Backbone eingefroren ist, werden seine Features nur einmal berechnet und gespeichert. Danach wird nur der Head trainiert. Ein Lauf dauert deshalb nur Sekunden.

3.5. Auswertung

- **Fehlermaß:** Diagonalfehler E_{diag}, also der euklidische RMSE in Prozent der Bildschirmdiagonale (Gleichung (4.1)).
- **Baselines:** Die Konstant-Baseline sagt immer den Mittelwert der Trainingsziele vorher, die Zufalls-Baseline rät zufällig. Beide werden auf denselben Testdaten wie das Modell berechnet (Abschnitt 4.1.5).
- **Statistik:** Bei GazeCapture gibt es fünf Wiederholungen pro Einstellung mit 98 %-Confidence Interval (Student-t) und dem Mann-Whitney-U-Test. Bei den Sitzungen nutze ich den Wilcoxon-Vorzeichen-Rang-Test (gepaart) und den Kruskal-Wallis-Test (Vergleich von Gruppen).
- **Aufteilung der Sitzungsdaten:** zufällig 70/15/15, sequenziell (zeitliche Blöcke mit einer Lücke von einer Sekunde) und zwei Videos (Training auf einer Sitzung, Test auf einer anderen) (Abschnitt 4.5).

- **Räumliche Analyse:** Fehler in Mitte, Rändern und Ecken des Bildschirms (Abschnitt 4.3.1).
- **Zeitliche Glättung (E4):** Ein Moving Average über die letzten k Vorhersagen wird nachträglich auf die gespeicherten Testvorhersagen angewendet. Gemessen werden Genauigkeit (E_{diag}) und Stabilität (RMS-S2S, Abschnitt 4.7).

3.6. Implementierung

Der Code ist in Python mit PyTorch und torchvision geschrieben. Eine kurze Übersicht über den Aufbau des Codes und die Befehle zum Wiederholen der Experimente steht im Anhang (Anhänge A.1 und A.2). Alle Experimente laufen ohne Grafikkarte auf der CPU des HP-Laptops (Gerät B): AMD Ryzen 7 3700U, etwa 13 GB nutzbarer Arbeitsspeicher, Ubuntu 26.04.1 LTS, Python 3.12.3, PyTorch 2.12.1 und torchvision 0.27.1 (jeweils CPU-Version). Der Code und die Web-Demo sind auf GitHub verfügbar: `https://github.com/RafeiKAr/gaze-estimation`. Das Basismodell der Demo liegt auf Hugging Face: `https://huggingface.co/RafeiKAr/demo_model`. Eine Kopie liegt in der BHT-Cloud: `https://cloud.bht-berlin.de/index.php/s/P4GkQ9J8zWHbdf9`. Die Bilder und Videos der eigenen Aufnahmen zeigen die Gesichter der beiden Personen. Sie sind deshalb nicht öffentlich, sondern liegen in einem privaten Dataset auf Hugging Face.

4. Experimente und Ergebnisse

Dieses Kapitel beschreibt die Experimente auf dem Datensatz GazeCapture [1] und auf meinen eigenen Aufnahmen. Zuerst erkläre ich Modell, Daten und Auswertung (Abschnitt 4.1). Danach folgen die Trainingseinstellungen (Abschnitt 4.2), die räumliche Verteilung des Fehlers und die Loss Functions (Abschnitt 4.3) und schließlich die Personalisierung (Abschnitte 4.4 bis 4.6) und die zeitliche Glättung der Vorhersagen (Abschnitt 4.7) und eine zweite Person (Abschnitt 4.8). Abschnitt 4.9 fasst zusammen, was die Ergebnisse bedeuten.

Alle Zahlen wurden mit den Protokolldateien der Experimente abgeglichen. Dabei wurde ein Fehler im Auswertungscode gefunden und korrigiert (Abschnitt 4.1.2). Alle Werte in den Tabellen verwenden die korrigierte Metrik. Die Lernkurven in Abbildung 4.2 stammen dagegen aus älteren Einzelläufen mit einer anderen Datenauswahl; die Bildunterschrift nennt die Unterschiede.

4.1. Versuchsaufbau

Modell, Training, Daten und Auswertung sind in Kapitel 3 beschrieben. Hier stehen nur die Details, die man für die Experimente zusätzlich braucht. Die Standardwerte zeigt Tabelle 4.1.

4.1.1. Daten und Splits

Die verwendete Teilmenge von GazeCapture und die beiden Splits `norm_subject` und `norm_random` sind in Abschnitt 3.1 beschrieben. Bei `norm_random` liegen alle Bilder einer Person zum selben Zielpunkt zusammen im Training oder im Test. Für die Hyperparameterstudie ziehe ich 1000 Trainings- und 200 Testbilder *zufällig* aus den Splits (fester Seed). Bei `norm_subject` kommen die Trainingsbilder von 179 Personen und die Testbilder von 45 anderen Personen. Frühere Läufe mit einer nicht zufälligen Auswahl (nur fünf Trainingspersonen und eine Testperson) werden nicht mehr verwendet.

4.1.2. Fehlermaß

Alle Blickziele liegen im Einheitsquadrat $[0,1]^2$ (Abschnitt 4.1.4). Der Fehler ist die Wurzel aus dem mittleren quadrierten *euklidischen* Abstand zwischen Vorhersage $\hat{\boldsymbol{p}}_i$ und Ziel $\boldsymbol{p}_i$. Ich gebe ihn in Prozent der Bildschirmdiagonale $\sqrt{2}$ an:

$$E_{\text{diag}} \;=\; 100 \cdot \frac{\sqrt{\frac{1}{N}\sum_{i=1}^{N} \|\hat{\boldsymbol{p}}_i - \boldsymbol{p}_i\|_2^2}}{\sqrt{2}} \quad [\%]. \tag{4.1}$$

0 % bedeutet eine perfekte Vorhersage, 100 % einen Fehler so groß wie die ganze Bildschirmdiagonale.

4.1.3. Ablauf der Experimente

In der Hyperparameterstudie ändere ich immer nur einen Wert (zum Beispiel die Batch Size). Alle anderen Werte bleiben auf der Standardeinstellung (Tabelle 4.1). Jede Einstellung wird fünfmal trainiert. Das Early Stopping nutzt eine eigene Validierungsmenge von 200 Bildern einer weiteren Person. Ich gebe den *Test*fehler in der Epoch mit dem kleinsten Validierungsfehler an. Die Testdaten werden also nie für die Modellauswahl benutzt. Die Tabellen zeigen den mittleren Testfehler, das zweiseitige 98 %-Confidence Interval (CI) des Mittelwerts (Student-t, vier Freiheitsgrade) und die mittlere Laufzeit.

Laufzeit. Die Laufzeit ist die Dauer *eines ganzen Trainingslaufs* bis zum Early Stopping, gemittelt über die fünf Läufe. Die einmalige Berechnung der Backbone-Features ist nicht enthalten. Weil das Early Stopping verschieden früh abbricht, zeigt die Laufzeit auch, wie lange sich eine Einstellung noch verbessert.

Tabelle 4.1.: Standardeinstellung der Hyperparameterstudie. Jede Variation ändert genau einen dieser Werte.

Parameter	Wert	Parameter	Wert
Split	`norm_subject`	Trainierbare Schichten	nur FC
Trainings-/Testgröße	1000 / 200[a]	Output Activation	Sigmoid
Batch Size	32	Loss	L1
Learning Rate	10^{-4}	Max. Epochs / Patience	500 / 3
Weight Decay	10^{-5}	Validierungsmenge	200 Bilder[b]
Wiederholungen	5		

[a] zufällig gezogen, Seed 0. [b] von einer Person, die weder im Training noch im Test vorkommt.

So liest man die Tabellen. In jeder Hyperparametertabelle ist die gewählte Option mit † markiert. Die Spalte „p vs. †“ enthält den p-Wert eines zweiseitigen Mann-Whitney-U-Tests zwischen den fünf Läufen dieser Option und den fünf Läufen der gewählten Option. Ich verwende einen Rangtest, weil man mit fünf Läufen nicht prüfen kann, ob die Werte normalverteilt sind, und weil einige Optionen einzelne Ausreißer haben (zum Beispiel ein ReLU-Lauf mit 46,98 %). Bei $5 + 5$ Läufen ist der kleinste mögliche p-Wert 0,008. Er bedeutet: *jeder* Lauf der einen Option ist besser als *jeder* Lauf der anderen. Ein Mittelwert ist nur dann **fett**, wenn die gewählte Option *signifikant besser* ist als jede andere Option der Tabelle ($p < 0{,}05$ und kleinerer Mittelwert).

Drei Punkte sind dabei wichtig:

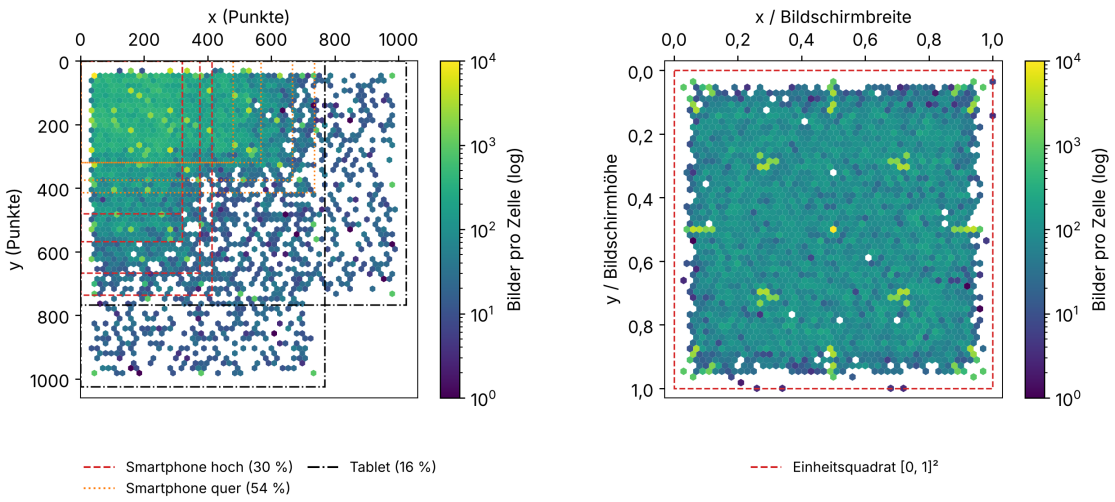
1. **Gleiche Daten in allen Wiederholungen.** Der Seed legt Trainings-, Test- und Validierungsdaten fest. Die fünf Wiederholungen unterscheiden sich nur in den Startgewichten, der Reihenfolge der Daten und im Dropout. Das CI zeigt also die Zufälligkeit des Trainings, nicht den Einfluss anderer Datenteilmengen.
2. **Kleine Validierungsmenge.** Die 200 Validierungsbilder stammen von nur einer Person. Das Early Stopping ist daher etwas zufällig. Die Testdaten werden aber nie für die Auswahl benutzt.
3. **Trainingszeit.** Bei „nur FC“ wird der Head auf gespeicherten ResNet-Features trainiert (512 Zahlen pro Bild statt des Bildes). Ein Lauf dauert daher nur etwa eine Sekunde, und Unterschiede in diesen Zeiten sind unwichtig. Bei FC + Layer 4 und beim vollen ResNet läuft in jeder Epoch jedes Bild vorwärts und rückwärts durch den Backbone. Diese Zeiten sind viel länger und nicht direkt mit „nur FC“ vergleichbar.

4.1.4. Normierung der Zielwerte

Die rohen Blickziele in GazeCapture sind Bildschirmpunkte des jeweiligen Geräts, gemessen von der oberen linken Ecke. Ihr Wertebereich hängt daher von Bildschirmgröße und Ausrichtung ab. Die 347 085 Bilder der 262 Personen stammen von zehn Bildschirmformaten, von 320×480 bis 1024×768 Punkten, im Hoch- und im Querformat. Ich teile die Ziele deshalb durch die Bildschirmbreite W und -höhe H des jeweiligen Bildes (Werte außerhalb von [0,1] werden abgeschnitten, das betrifft 0,006 % der Bilder):

$$x_{\text{norm}} = \frac{x}{W}, \qquad y_{\text{norm}} = \frac{y}{H}. \tag{4.2}$$

Abbildung 4.1 zeigt die Wirkung. Ohne Normierung liegen die Ziele der vielen Smartphone-Bilder vor allem oben links, und dieselbe Koordinate bedeutet auf jedem Gerät eine andere Stelle (Abbildung 4.1a). Ein Fehler in Bildschirmpunkten wäre damit zwischen Geräten



(a) Rohe Ziele in Bildschirmpunkten

(b) Normierte Ziele im Einheitsquadrat

Abbildung 4.1.: Verteilung der Blickziele von GazeCapture vor und nach der Normierung (Dichte aller Bilder, logarithmische Farbskala). Links: gestrichelt die Umrisse der Bildschirmformate. Rechts: gestrichelt das Einheitsquadrat; die hellen Zellen sind Kalibrierpunkte, die auf allen Geräten an denselben relativen Stellen gezeigt werden.

nicht vergleichbar. Nach der Normierung liegen alle Ziele im Einheitsquadrat $[0,1]^2$ (Abbildung 4.1b), und das Fehlermaß in Gleichung (4.1) ist für alle Geräte gleich definiert. Alle weiteren Experimente verwenden normierte Ziele.

4.1.5. Baselines

Ich verwende zwei einfache Vergleichsschätzer. Die *Konstant-Baseline* sagt für jedes Testbild den Mittelwert der Trainingsziele vorher. Die *Zufalls-Baseline* zieht Vorhersagen gleichverteilt aus $[0,1]^2$. Ein Modell ist nur dann nützlich, wenn es deutlich besser ist als die Konstant-Baseline. Ein untrainiertes Modell liegt nicht bei der Zufalls-Baseline, sondern bei der Konstant-Baseline: Seine letzte Schicht gibt Werte nahe 0 aus, die Sigmoid macht daraus 0,5, und das Modell sagt für alle Bilder etwa die Bildschirmmitte vorher. Ein Lerneffekt zeigt sich daher erst, wenn der Fehler *unter* der Konstant-Baseline derselben Testdaten liegt.

Der untere Teil von Tabelle 4.2 ist die richtige Referenz für alle Modellergebnisse in Abschnitt 4.2, weil er auf denselben Daten berechnet wurde.

Tabelle 4.2.: Baseline-Fehler E_{diag} in %. Oben: gesamter Datensatz (Bootstrap mit 30 Stichproben zu je 2000 Bildern, Mittelwert und 98 %-CI). Unten: dieselben zufälligen Trainings-/Testteilmengen (Seed 0) wie beim Modelltraining (kein CI, eine feste Teilmenge).

Daten	Konstant-Baseline	Zufalls-Baseline
Gesamter Datensatz (347 085 Bilder)	27,28 [27,15; 27,40]	39,82 [39,60; 40,04]
`norm_subject`, 1000/200	28,46	40,36
`norm_subject`, 10 000/2000	27,62	39,96
`norm_random`, 1000/200	27,66	39,83

4.2. Trainingseinstellungen

Alle Ergebnisse dieses Abschnitts stammen aus einer gemeinsamen Versuchsreihe (korrigierte Metrik, zufällige Teilmengen mit festem Seed, Early Stopping auf der Validierung, fünf Wiederholungen pro Einstellung). Die Konstant-Baseline der Standardeinstellung auf denselben Daten liegt bei 28,46 %.

4.2.1. Batch Size

Tabelle 4.3.: Batch Size. Mittlerer Testfehler über fünf Läufe mit 98 %-CI und mittlere Dauer eines ganzen Trainingslaufs (Head auf gespeicherten Features, siehe Abschnitt 4.1.3).

Batch Size	Mittl. Testfehler (%)	98 %-CI (%)	p vs. †	Laufzeit (min)
32†	28,39	[28,21; 28,58]	—	0,019
64	28,35	[28,29; 28,41]	0,69	0,012
128	28,38	[28,30; 28,47]	0,84	0,009

Die drei Batch Sizes ergeben denselben Testfehler (Tabelle 4.3): Die Mittelwerte unterscheiden sich um höchstens 0,05 Prozentpunkte, die Confidence Intervals überlappen, und der Rangtest findet keinen Unterschied ($p \geq 0{,}69$). Ein Lauf dauert weniger als eine Sekunde, weil nur der kleine Head auf gespeicherten Features trainiert wird. Die Zeitunterschiede sind daher unwichtig.

Ich behalte die Batch Size 32 als Standard. Das Experiment zeigt keinen Nachteil, und zwei praktische Gründe sprechen für eine kleine Batch Size bei der Personalisierung: (i) Eine persönliche Sitzung hat nur einige hundert Trainingsbilder. Mit kleinen Batches gibt es mehr Updates pro Epoch. (ii) Das Noise kleiner Batches wirkt nach gängiger Meinung leicht regularisierend. Die Daten dieses Experiments *beweisen* aber keinen Vorteil von 32 gegenüber 64 oder 128.

4.2.2. Learning Rate

Tabelle 4.4.: Learning Rate. Mittlerer Testfehler über fünf Läufe mit 98 %-CI und mittlere Dauer eines ganzen Trainingslaufs.

Learning Rate	Mittl. Testfehler (%)	98 %-CI (%)	p vs. †	Laufzeit (min)
10^{-3}	28,43	[28,33; 28,54]	0,15	0,018
$10^{-4\dagger}$	28,37	[28,32; 28,42]	—	0,020
10^{-5}	28,33	[28,28; 28,38]	0,056	0,022
10^{-6}	28,37	[28,21; 28,52]	0,42	0,055

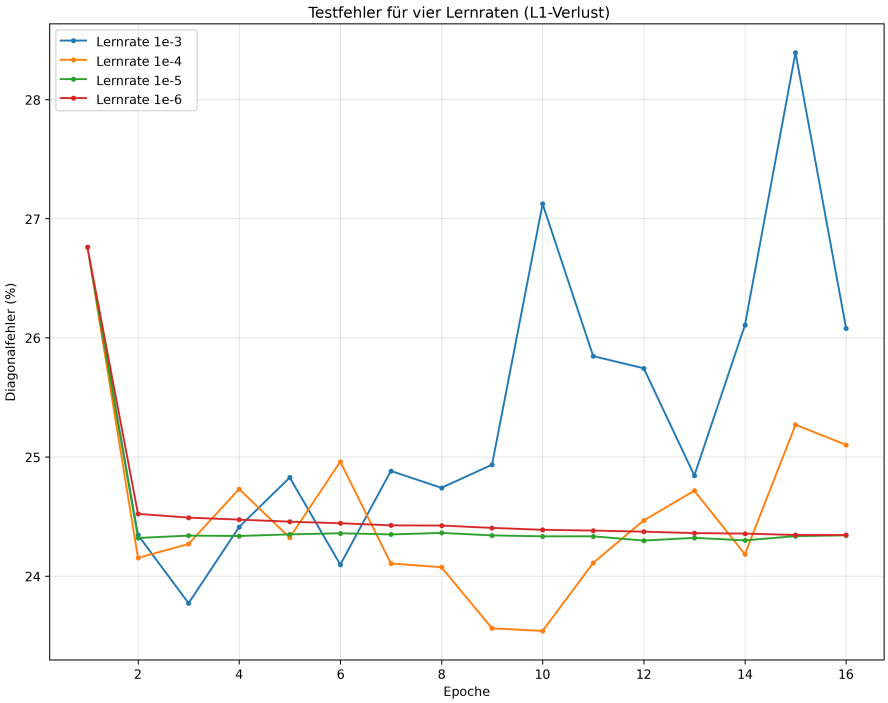


Abbildung 4.2.: Testfehler einzelner Trainingsläufe mit vier Learning Rates aus einem älteren Notebook-Lauf (`norm_random`, 1000/200, ältere Datenauswahl, 15 Epochs ohne Early Stopping). Der erste Punkt (Epoch 1 auf der Achse) ist das untrainierte Modell. Die Werte sind nicht direkt mit Tabelle 4.4 vergleichbar.

Auch bei der Learning Rate gibt es keinen signifikanten Unterschied (Tabelle 4.4): Alle Mittelwerte liegen zwischen 28,33 % und 28,43 %, die Intervalle überlappen, und kein Rangtest ist signifikant ($p \geq 0{,}056$). Der Endfehler allein kann die Wahl also nicht begründen. Den Ausschlag gibt der erste Test, also der *Lernverlauf* in Abbildung 4.2:

- $\boldsymbol{\eta = 10^{-3}}$: Die Schritte sind zu groß. Nach einem schnellen Abfall schwankt der Testfehler stark und steigt wieder (Spitzen bei etwa 27,1 % und 28,4 %). Der Lauf findet kein stabiles Minimum.
- $\boldsymbol{\eta = 10^{-4}}$: erreicht klar den kleinsten Testfehler aller Kurven (etwa 23,6 % um

Epoch 10, also etwa 0,7 Prozentpunkte unter 10^{-5} und 10^{-6}). Die Kurve schwankt noch, aber viel weniger als bei 10^{-3}. Das Early Stopping kann diesen besten Stand behalten.

- **$\eta = 10^{-5}$ und 10^{-6}**: Die Kurven sind sehr glatt und fallen gleichmäßig, bleiben aber bei etwa 24,3 % stehen. Die Schritte sind zu klein, um in der verfügbaren Zeit weiterzukommen. Das Ergebnis ist stabil, aber nicht das beste.

Auch die Laufzeit spricht für 10^{-4} (Tabelle 4.4): Mit 0,020 min (etwa 1,2 s) gehört dieser Wert zu den schnellsten. Nur 10^{-3} ist minimal schneller, aber instabil; 10^{-6} braucht fast dreimal so lange (0,055 min), weil das Training mit sehr kleinen Schritten später abbricht. Ich wähle deshalb $\eta = 10^{-4}$: kleinster Fehler im ersten Test, ein ruhiger Lernverlauf und eine kurze Laufzeit. Die Wiederholung mit fünf Läufen zeigt zusätzlich, dass der Head mit gespeicherten Features robust gegenüber der Learning Rate ist: Keiner der anderen Werte ist signifikant besser.

4.2.3. Trainierbare Schichten

Ich vergleiche drei Tiefen des Fine-Tunings (Tabelle 4.5): nur den Regression Head (nur FC), den Head plus die letzte Residualstufe (Layer 4) und das ganze Netz.

Tabelle 4.5.: Trainierbare Parameter der drei Varianten (ResNet-18 mit Regression Head, insgesamt 11 603 650 Parameter).

	Nur FC	FC + Layer 4	Volles ResNet
Trainierbare Parameter	427 138	8 820 866	11 603 650
Anteil an allen Parametern	3,68 %	76,02 %	100,00 %
Backbone-Features speicherbar	ja	nein	nein

Tabelle 4.6.: Trainierbare Schichten. Mittlerer Testfehler über fünf Läufe mit 98 %-CI und mittlere Dauer eines ganzen Trainingslaufs. Bei „nur FC“ läuft kein Bild durch den Backbone (gespeicherte Features).

Trainierbare Schichten	Mittl. Testfehler (%)	98 %-CI (%)	p vs. †	Laufzeit (min)
Nur FC†	28,36	[28,23; 28,49]	—	0,015
FC + Layer 4	29,07	[26,58; 31,55]	0,22	9,160
Volles ResNet	29,39	[26,99; 31,78]	0,31	15,366

„Nur FC“ hat den kleinsten mittleren Fehler und mit Abstand das schmalste Intervall (Tabelle 4.6). Mehr trainierbare Schichten helfen nicht. Sie machen das Ergebnis sogar *unsicherer*: Ein Lauf mit FC + Layer 4 (31,72 %) und zwei Läufe mit dem vollen ResNet (30,70 % und 31,18 %) enden deutlich über der Konstant-Baseline (28,46 %). Alle Läufe mit „nur FC“ bleiben zwischen 28,28 % und 28,47 %. Mit nur fünf Läufen sind die Unterschiede

nicht signifikant (p = 0,22 und 0,31); der Wert für „nur FC“ ist daher nicht fett. Die Trainingszeit wächst stark mit der Zahl der Parameter: 9,2 min pro Lauf für FC + Layer 4 und 15,4 min für das ganze Netz.

Ich wähle „nur FC“ aus drei Gründen:

1. **Nicht schlechter, aber stabiler:** Mehr Schichten senken den Fehler hier nicht, sie erhöhen nur die Streuung zwischen den Läufen.
2. **Robust bei wenigen Daten:** Eine persönliche Sitzung hat nur einige hundert Bilder. Wenn man Millionen von Backbone-Parametern mit so wenigen Beispielen trainiert, droht Overfitting, und die vortrainierten Features werden verzerrt. Kumar u. a. [22] zeigen, dass vollständiges Fine-Tuning vortrainierte Features beschädigen und schlechter generalisieren kann als reines Head-Training.
3. **Aufwand:** Nur 3,68 % der Parameter werden trainiert, und die Backbone-Features werden nur einmal berechnet. Die Personalisierung ist dadurch schnell und braucht wenig Speicher.

4.2.4. Activation am Ausgang

Die Activation am Ausgang kommt nach der letzten linearen Schicht, die (x,y) ausgibt. Sigmoid bildet auf (0,1) ab, also genau auf den Bereich der normierten Koordinaten. Die Gauß-Aktivierung $g(z) = \exp(-z^2/2\sigma^2)$ mit $\sigma = 1$ bildet auf (0,1] ab, ist aber nicht monoton. ReLU entfernt nur negative Werte, und „Keine“ lässt die Ausgabe unverändert.

Tabelle 4.7.: Activation am Ausgang. Mittlerer Testfehler über fünf Läufe mit 98 %-CI und mittlere Dauer eines ganzen Trainingslaufs.

Activation	Mittl. Testfehler (%)	98 %-CI (%)	p vs. †	Laufzeit (min)
Sigmoid†	**28,36**	[28,29; 28,43]	—	0,022
Gauß	31,29	[28,44; 34,14]	0,008	0,019
ReLU	32,90	[19,69; 46,10]	0,008	0,028
Keine	29,39	[28,42; 30,36]	0,008	0,032

Sigmoid ist der einzige klare Gewinner der Hyperparameterstudie (Tabelle 4.7): kleinster Fehler, schmalstes Intervall, und *jeder* Sigmoid-Lauf ist besser als *jeder* Lauf der drei anderen Activations ($p = 0{,}008$ in allen drei Vergleichen). Der Wert ist daher fett. Die anderen Activations sind auch weniger stabil: Ein ReLU-Lauf endet bei 46,98 %, also schlechter als zufälliges Raten. Ein möglicher Grund: ReLU kann für alle Eingaben null ausgeben („tote“ Ausgabe), und der Gradient erholt sich davon nicht mehr. Ohne begrenzende Activation (Keine, ReLU) kann das Netz außerdem Punkte außerhalb des Bildschirms vorhersagen. Ich wähle Sigmoid, weil sie die Ausgabe auf den Bildschirm begrenzt und den kleinsten und stabilsten Fehler ergibt.

4.2.5. Datenmenge

Tabelle 4.8.: Datenmenge (Training/Test). Mittlerer Testfehler über fünf Läufe mit 98 %-CI, mittlere Dauer eines ganzen Trainingslaufs und Konstant-Baseline der jeweiligen Testdaten.

Training / Test	Mittl. Testfehler (%)	98 %-CI (%)	p vs. †	Laufzeit (min)	Konst.-Baseline (%)
10 000 / 2000	27,64	[27,55; 27,73]	0,008	0,167	27,62
1000 / 200†	28,39	[28,33; 28,44]	—	0,018	28,46

Die größere Datenmenge hat einen kleineren mittleren Fehler (Tabelle 4.8). Die beiden Varianten werden aber auf *verschiedenen* Testdaten ausgewertet, und jeder Mittelwert ist praktisch gleich der Konstant-Baseline seiner eigenen Testdaten (27,64 % vs. 27,62 % und 28,39 % vs. 28,46 %). Der Unterschied von 0,75 Prozentpunkten kommt also von den unterschiedlichen Testdaten und nicht von mehr Trainingsdaten – auch wenn der Rangtest signifikant ist ($p = 0{,}008$). Ich behalte die kleine Variante (1000/200), weil sie etwa zehnmal schneller ist und etwa so viele Daten hat wie eine Personalisierungssitzung.

4.2.6. Art des Splits

Tabelle 4.9.: Art des Splits. Mittlerer Testfehler über fünf Läufe mit 98 %-CI und Konstant-Baseline der jeweiligen Testdaten.

Split	Mittl. Testfehler (%)	98 %-CI (%)	p vs. †	Konstant-Baseline (%)
`norm_random`	27,72	[27,64; 27,80]	0,008	27,66
`norm_subject`†	28,39	[28,26; 28,53]	—	28,46

Der zufällige Split ergibt den kleineren Fehler (Tabelle 4.9). Auch hier kommt der größte Teil des Unterschieds von den Testdaten: Die Konstant-Baseline ist auf `norm_random` schon um 0,80 Prozentpunkte niedriger, und beide Modelle liegen höchstens 0,07 Prozentpunkte neben ihrer Baseline. Außerdem können beim zufälligen Split dieselben Personen in Training und Test vorkommen. Das macht die Aufgabe leichter und das Ergebnis zu optimistisch. Ich verwende daher `norm_subject` als Standard. Nur dieser Split misst die Leistung auf unbekannten Personen, also die Situation vor der Personalisierung.

4.3. Räumliche Fehleranalyse und Loss Functions

Der mittlere Fehler aus Abschnitt 4.2 zeigt nicht, *wo* auf dem Bildschirm die Fehler entstehen. Dieser Abschnitt untersucht zuerst die räumliche Verteilung des Fehlers (Ab-

schnitte 4.3.1 und 4.3.2). Das Ergebnis führte zur Idee, den Loss nach der Position zu gewichten (Abschnitt 4.3.3). Abschnitt 4.3.4 wertet diese Idee aus.

4.3.1. Einteilung des Bildschirms

Ich beschreibe den normierten Bildschirm $[0,1]^2$ mit einem 3×3-Raster aus drei Regionen:

Mitte:	(0,50; 0,50),
Ränder:	(0,10; 0,50), (0,50; 0,10), (0,90; 0,50), (0,50; 0,90),
Ecken:	(0,10; 0,10), (0,10; 0,90), (0,90; 0,10), (0,90; 0,90).

Ein Testbeispiel mit Ziel $\boldsymbol{p}$ gehört zum Rasterpunkt $\boldsymbol{g}$, wenn $\|\boldsymbol{p}-\boldsymbol{g}\|_2 \le r$ mit $r = 0{,}15$ gilt. Der Fehler eines Rasterpunkts ist der mittlere euklidische Fehler $\|\hat{\boldsymbol{p}}-\boldsymbol{p}\|_2$ seiner Beispiele (in normierten Einheiten, also als Anteil der Bildschirmseite; die Diagonale ist $\sqrt{2} \approx 1{,}41$). Der Fehler einer Region ist der Mittelwert über alle Beispiele ihrer Rasterpunkte. Diese Definitionen gelten für alle Abbildungen und Tabellen in diesem Abschnitt.

4.3.2. Fehler-Heatmaps

Abbildung 4.3 nutzt die 200 Testvorhersagen des Standardmodells (`norm_subject`, L1-Loss). Für eine Position $\boldsymbol{c}$ (Mitte, Rand oder Ecke) berechne ich den mittleren Fehler $\bar{e}(\boldsymbol{c})$ aller Beispiele im Radius r und zeichne ihn als Gaußfleck:

$$H(x,y) = \bar{e}(\boldsymbol{c})\,\exp\!\left(-\frac{\|(x,y)-\boldsymbol{c}\|_2^2}{2\sigma^2}\right), \qquad \sigma = 0{,}20. \tag{4.3}$$

Die Farbe zeigt also die *Größe* des lokalen Fehlers, und die Lage des hellen Flecks zeigt, *wo* er gemessen wurde. Alle drei Teilbilder nutzen dieselbe Farbskala (von 0 bis zum größten Wert), damit man die Farben direkt vergleichen kann.

Der Fehler wächst von innen nach außen: Er beträgt 0,086 in der Mitte ($n = 18$), 0,432 an den Rändern ($n = 62$) und 0,586 in den Ecken ($n = 42$). Die Randfehler sind etwa fünfmal und die Eckfehler etwa siebenmal so groß wie in der Mitte.

Das vierte Teilbild erklärt den Grund. Alle Vorhersagen liegen in einem sehr kleinen Bereich um (0,5; 0,5). Ihre Standardabweichung beträgt in beiden Koordinaten nur etwa 0,004, die der Ziele dagegen etwa 0,28. Das Modell sagt also für jedes Bild fast denselben Punkt vorher. Sein Fehler ist einfach der Abstand des Ziels von der Bildschirmmitte. Ein Schätzer, der immer die Mitte ausgibt, liefert praktisch dieselben Werte (Mitte 0,085, Ränder 0,432, Ecken 0,587; insgesamt $E_{\text{diag}} = 28{,}45\,\%$ gegenüber 28,47 % für das Modell).

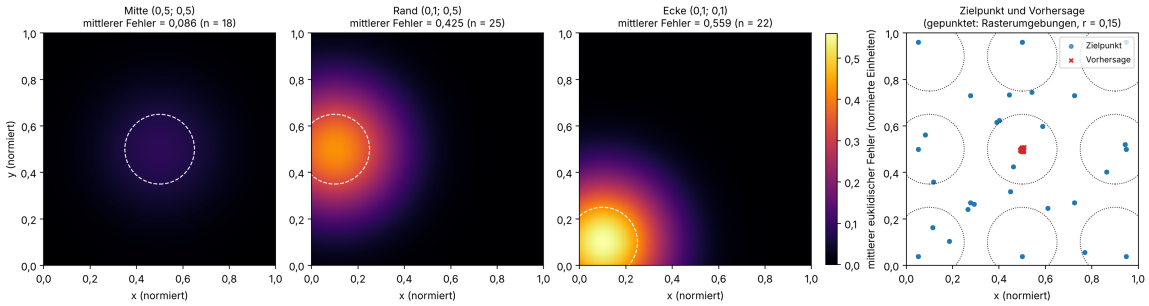


Abbildung 4.3.: Räumlicher Fehler des Standardmodells (L1-Loss, `norm_subject`, 200 Testbeispiele). Teilbilder 1–3: Fehler-Heatmaps ($r = 0{,}15$, $\sigma = 0{,}20$, gemeinsame Farbskala) in der Mitte (0,5; 0,5), am linken Rand (0,1; 0,5) und in der unteren linken Ecke (0,1; 0,1). Der Fehler wächst von der Mitte (0,086) über den Rand (0,425) zur Ecke (0,559). Teilbild 4: Ziele (blau) und Vorhersagen (rot); alle Vorhersagen liegen nahe der Bildschirmmitte.

4.3.3. Loss Functions

Wegen der großen Fehler an Rändern und Ecken entstand die Idee, diese Bereiche im Loss stärker zu gewichten. Sei $\hat{\boldsymbol{p}}_i = (\hat{x}_i, \hat{y}_i)$ die Vorhersage und $\boldsymbol{p}_i = (x_i, y_i)$ das Ziel von Beispiel i in einem Batch der Größe N.

L1-Loss.

$$\mathcal{L}_1 = \frac{1}{2N} \sum_{i=1}^{N} \big(|\hat{x}_i - x_i| + |\hat{y}_i - y_i| \big). \tag{4.4}$$

Der Gradient hat immer denselben Betrag, egal wie groß der Fehler ist. Der Loss ist daher robust gegen Ausreißer (zum Beispiel falsche Labels beim Zielwechsel), behandelt aber alle Bildschirmpositionen gleich.

Smooth-L1-Loss ($\beta = 1$). Für ein Residuum u gilt:

$$\ell_\beta(u) = \begin{cases} \dfrac{u^2}{2\beta}, & |u| < \beta, \\ |u| - \dfrac{\beta}{2}, & \text{sonst.} \end{cases} \tag{4.5}$$

Er ist quadratisch für kleine und linear für große Residuen. Da hier alle Residuen kleiner als $\beta = 1$ sind, verhält er sich wie ein skalierter quadratischer Fehler: Bei kleinen Fehlern wird der Gradient klein.

Sensitiver L1-Loss (nach Position gewichtet). Jedes Beispiel wird mit seinem L_1-Abstand zur Bildschirmmitte gewichtet:

$$d_i = |x_i - 0{,}5| + |y_i - 0{,}5| \in [0{,}1], \qquad w_i = 1 + d_i \in [1{,}2], \tag{4.6}$$

$$\mathcal{L}_{\text{sens}} = \frac{1}{N} \sum_{i=1}^{N} w_i \cdot \frac{|\hat{x}_i - x_i| + |\hat{y}_i - y_i|}{2}. \tag{4.7}$$

Ein Beispiel in der Ecke zählt doppelt so viel wie eines in der Mitte, ein Beispiel am Rand etwa 1,4-mal so viel. Der Gradient für äußere Ziele wird größer, und die Vorhersagen sollen dadurch von der Mitte weggezogen werden.

Der „verbesserte sensitive Loss“ in Tabelle 4.11 war eine weitere Variante aus einem frühen Versuch. Seine genaue Formel ist nicht mehr dokumentiert; er wird nur der Vollständigkeit halber genannt.

4.3.4. Ergebnisse: Vergleich der Loss Functions

Tabelle 4.10 zeigt den globalen Vergleich mit fünf Läufen und dazu die Fehler in den Bildschirmregionen aus Abschnitt 4.3.1.

Tabelle 4.10.: Vergleich von L1- und sensitivem L1-Loss. Links: mittlerer Testfehler E_{diag} über fünf Läufe (98 %-CI) und mittlere Laufzeit. Rechts: mittlerer euklidischer Fehler pro Bildschirmregion (normierte Einheiten; je ein Lauf, 200 Testbeispiele, $r = 0{,}15$; n = Anzahl der Beispiele). Letzte Zeile: Schätzer, der immer die Mitte ausgibt, auf denselben 200 Testbeispielen.

	Global (5 Läufe)			Räumlicher Fehler (1 Lauf)		
Loss	E_{diag} (%)	98 %-CI (%)	Laufzeit (min)	Mitte ($n = 18$)	Ränder ($n = 62$)	Ecken ($n = 42$)
L1 (standard)[†]	**28,32**	[28,23; 28,42]	0,011	0,086	0,432	0,586
Sensitiver L1	28,48	[28,19; 28,78]	0,021	0,090	0,431	0,585
Konstante Mitte	28,45[a]	—	—	0,085	0,432	0,587

[a] Auf denselben 200 Testbeispielen wie die räumliche Analyse.

Beobachtungen.

- Global ist L1 leicht, aber signifikant besser als der sensitive Loss: 28,32 % gegenüber 28,48 % (Mann-Whitney $p = 0{,}032$, Tabelle 4.10); der L1-Wert ist daher fett. Der sensitive Loss streut außerdem stärker zwischen den Läufen. Beide Werte liegen nahe an der Konstant-Baseline (28,46 %).

Tabelle 4.11.: Zusatzexperiment: räumlicher Fehler von vier Loss Functions nach 15 Epochs auf Trainingsdaten mit 52 Eckbeispielen (zwei Läufe, A und B, Werte wie protokolliert). Die Zahlen stammen aus einem Notebook zum Ausprobieren. Die Berechnung der Regionswerte ist im aktuellen Code nicht enthalten; sie sind daher nicht direkt mit Tabelle 4.10 vergleichbar.

	Gesamt (%)		Mitte (%)		Ränder (%)		Ecken (%)	
Loss	A	B	A	B	A	B	A	B
L1	24,54	24,63	17,01	16,74	28,28	28,98	34,93	35,07
Smooth L1	23,94	24,91	15,40	16,41	29,78	30,59	34,13	35,17
Sensitiver L1	25,57	25,55	19,11	18,61	29,87	29,93	33,41	34,20
Verbesserter sensitiver L1	25,53	27,75	19,20	21,86	29,17	35,03	33,77	31,58

- Räumlich ändert die Gewichtung die Regionsfehler um weniger als 0,005 normierte Einheiten. Rand- und Eckfehler bleiben etwa fünf- bis siebenmal so groß wie in der Mitte.
- Beide Modelle haben dasselbe räumliche Muster wie ein Schätzer, der immer die Mitte ausgibt. Die Gewichtung vergrößert zwar den Gradienten für äußere Beispiele, aber das reicht nicht, damit das Modell die Mitte verlässt.
- Im Zusatzexperiment (Tabelle 4.11) senken die sensitiven Varianten den Eckfehler etwas (sensitiver L1 um 0,9–1,5, die verbesserte Variante um 1,2–3,5 Prozentpunkte). Sie erhöhen aber den Fehler in der Mitte um 1,9–5,1 Prozentpunkte und den Gesamtfehler in allen Läufen. Die beiden Läufe unterscheiden sich stark; diese Tendenzen sind daher nicht verlässlich.

Fazit. Die räumliche Analyse zeigt, *was* das Problem ist: Die Fehler liegen vor allem an den Rändern und in den Ecken. Der gewichtete Loss sollte diese Fehler senken. Er hat die Ecken aber nicht verbessert und war global sogar leicht, aber signifikant schlechter als L1 ($p = 0{,}032$). Im Zusatzexperiment erhöhte er den Fehler in der Mitte. Ich behalte daher den normalen L1-Loss: Er hat den kleineren Fehler, ist einfacher, hat keinen zusätzlichen Parameter, und sein konstanter Gradient macht ihn robust gegen falsche Labels in den eigenen Aufnahmen. Die Analyse zeigt auch, *warum* die Gewichtung nicht helfen konnte: Die großen Fehler außen entstehen nicht durch eine falsche Gewichtung, sondern weil das Modell die Bildschirmmitte kaum verlässt (Abschnitt 4.9).

4.4. Personalisierungssitzungen

4.4.1. Aufbau

In jeder persönlichen Sitzung wird der Head eines GazeCapture-Basismodells mit den Bildern einer eigenen Aufnahme neu trainiert (nur FC, Sigmoid, L1, $\eta = 10^{-4}$, Weight Decay 10^{-5}, Batch Size 32, AdamW). Wenn nichts anderes steht, wird jede Sitzung zufällig in 70 % Training, 15 % Validierung und 15 % Test geteilt (Seed 42). Das Early Stopping (Patience 3) nutzt den Validierungsfehler. Ich gebe den Testfehler in der Epoch mit dem kleinsten Validierungsfehler an. Ist die beste Epoch 0, hat die Personalisierung die Validierung nicht verbessert. Der angegebene Testfehler ist dann der des unveränderten Basismodells.

Alle Ergebnisse ab hier verwenden die korrigierte Metrik (Gleichung (4.1)) und feste Zufalls-Seeds. Der Backbone ist einschließlich seiner BatchNorm-Statistiken vollständig eingefroren.

Gespeicherte Features. Weil der Backbone eingefroren ist, liefert er für ein Bild in jeder Epoch dieselben 512 Features. Ich berechne diese Features deshalb nur einmal pro Sitzung und Basismodell (ohne Augmentierung) und speichere sie. Danach wird nur noch der Head trainiert. Das Ergebnis ändert sich dadurch nicht, aber ein Lauf dauert auf einer CPU nur Sekunden. Bei der Personalisierung wird keine Bildaugmentierung verwendet.

Basismodelle (E0). Die beiden Basismodelle werden mit der Einstellung aus Abschnitt 4.2 (nur FC, Sigmoid, L1, $\eta = 10^{-4}$, Batch Size 32, 1000/200 zufällige Bilder, Seed 0, Early Stopping auf der Validierung) auf `norm_subject` und `norm_random` trainiert. Von fünf Seeds behalte ich jeweils den Lauf mit dem kleinsten *Validierungs*fehler. Für `norm_subject` ist das Seed 0 (Validierung 27,37 %, Test 28,70 %; Konstant-Baseline derselben Testdaten 28,46 %), für `norm_random` Seed 3 (Validierung 26,74 %, Test 27,81 %; Konstant-Baseline 27,66 %). Die fünf Seeds unterscheiden sich um weniger als 0,4 Prozentpunkte; die Wahl des Seeds ist also unkritisch. Wie in Abschnitt 4.9 beschrieben, liegen beide Basismodelle auf dem Niveau der Konstant-Baseline.

Von 27 aufgenommenen Sitzungen verwende ich 18: Gen 1 (01–04), Gen 2 (05–09) und Gen 4 (19–27). Gen 3 (10–18) habe ich verworfen, weil das Modell daraus nichts lernen konnte. Tabelle 4.12 zeigt die Aufnahmebedingungen.

4.4.2. Ergebnisse aller Sitzungen (E1)

Tabelle 4.13 zeigt jede Sitzung mit beiden Basismodellen.

Tabelle 4.12.: Aufnahmebedingungen der 18 Sitzungen. Gen 1: Ziel bewegt sich gleichmäßig, ohne Sprünge; Gen 2: Ziel mit zufälligen Sprüngen; Gen 4: 5-s-Abschnitte (0,5 s WAIT an einem neuen Startpunkt, 4,5 s MOVE), 90 % der Startpunkte in den Ecken. Die Dauer wurde nur in Gen 4 verändert (Gen 1/2: nicht protokolliert). Gerät A: Sitzungen 01–03 und 25–27; Gerät B: 05–09 und 19–24; Sitzung 04: nicht protokolliert.

Sitzungen	Generation	Brille	Licht / Hintergrund
01, 03, 04	Gen 1	mit	01, 04: hell; 03: dunkel
02	Gen 1	ohne	hell
05, 07, 08	Gen 2	mit	05: hell; 07: dunkel; 08: sehr dunkel
06, 09	Gen 2	ohne	06: hell; 09: sehr dunkel
Gen 4 (Dauer / Gerät)			
19, 20	Gen 4	mit	ruhig; 120 s / 90 s; B
21, 22	Gen 4	ohne	ruhig; 120 s / 90 s; B
23 / 24	Gen 4	mit / ohne	unruhig; 120 s; B
25 / 26	Gen 4	mit / ohne	unruhig; 120 s; A
27	Gen 4	mit	unruhig; 90 s; A
28 / 29 (Person B)	Gen 4	ohne	hell; ruhig / unruhig; 120 s; A / B

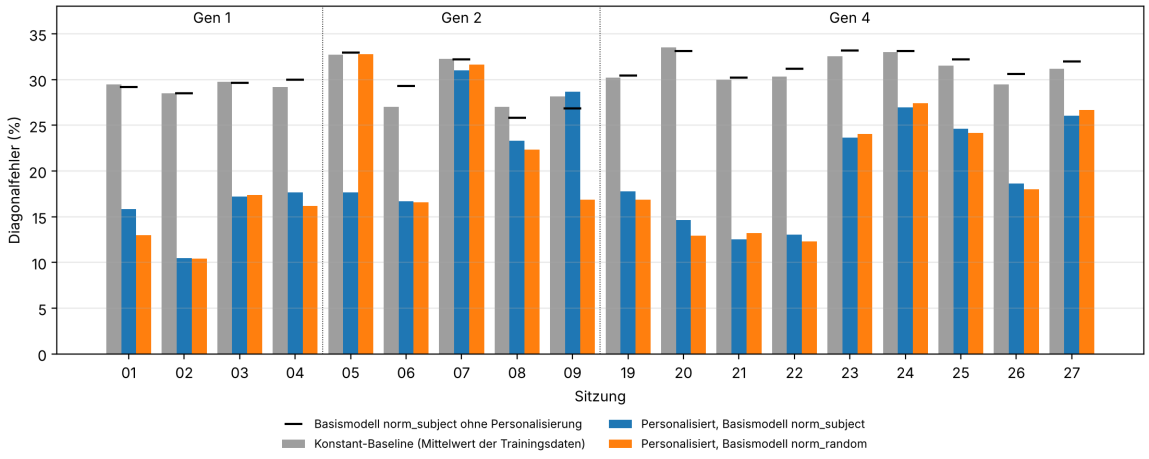


Abbildung 4.4.: Testfehler der 18 Sitzungen nach der Personalisierung mit beiden Basismodellen, verglichen mit der Konstant-Baseline und dem unveränderten Basismodell (`norm_subject`) auf denselben Testbildern (Daten aus Tabelle 4.13).

Tabelle 4.13.: Personalisierung der 18 Sitzungen mit zwei Basismodellen (ursprüngliche Labels, zufälliger 70/15/15-Split, Seed 42). Basis: Testfehler des unveränderten Basismodells (Epoch 0); Val.: bester Validierungsfehler; Test: Testfehler in der besten Validierungsepoche; Ep.: beste Epoch; t: Dauer eines Laufs in Sekunden (Abschnitt 4.4.3); Konst.: Konstant-Baseline (Mittelwert der Trainingsziele, auf denselben Testbildern). Fehler in % (Gleichung (4.1)). Gruppenzeilen: Mittelwert und 98 %-CI über die Sitzungen der Gruppe.

		Basismodell `norm_subject`					Basismodell `norm_random`					
Sitzung	Gen.	Basis	Val.	Test	Ep.	t (s)	Basis	Val.	Test	Ep.	t (s)	Konst.
01	1	29,19	14,82	15,83	22	2,3	29,49	11,70	12,97	47	4,2	29,45
02	1	28,48	10,08	10,48	30	2,2	28,42	10,04	10,43	44	3,2	28,49
03	1	29,61	15,26	17,20	33	2,5	30,13	15,41	17,35	36	2,6	29,76
04	1	29,98	16,88	17,64	17	2,1	29,38	15,23	16,16	31	2,7	29,17
05	2	32,92	25,43	17,64	26	1,1	32,49	31,93	32,77	2	0,2	32,72
06	2	29,29	11,31	16,67	54	1,8	28,89	12,09	16,55	55	2,0	27,02
07	2	32,18	24,84	30,99	16	0,7	32,43	25,02	31,62	18	0,6	32,28
08	2	25,82	23,65	23,30	24	0,8	26,32	23,38	22,31	23	0,6	27,00
09	2	26,83	23,55	28,64	4	0,2	26,21	15,19	16,87	47	1,9	28,17
19	4	30,42	13,38	17,76	33	2,8	30,04	12,13	16,85	47	4,4	30,19
20	4	33,14	16,06	14,64	23	1,9	33,01	14,58	12,93	35	2,7	33,49
21	4	30,18	15,03	12,51	39	4,6	30,46	15,80	13,20	23	2,6	29,97
22	4	31,17	13,54	13,02	22	2,2	30,87	12,53	12,32	37	3,1	30,32
23	4	33,15	23,48	23,65	10	1,4	32,59	24,02	24,05	10	2,0	32,57
24	4	33,09	28,77	26,97	7	0,9	32,84	29,53	27,42	6	1,0	33,01
25	4	32,19	26,98	24,61	19	2,4	33,00	26,74	24,13	26	2,8	31,54
26	4	30,60	21,93	18,61	20	2,3	30,39	21,40	17,97	37	4,5	29,48
27	4	31,98	26,05	26,06	19	1,5	32,29	26,27	26,68	19	1,7	31,19
Gen 1 (4)		29,32	14,26	15,29	25,5	2,3	29,35	13,10	14,23	39,5	3,2	29,22
		[27,86; 30,77]	[7,62; 20,89]	[7,80; 22,77]		[1,8; 2,7]	[27,75; 30,96]	[7,07; 19,12]	[7,10; 21,35]		[1,5; 4,8]	[27,99; 30,45]
Gen 2 (5)		29,41	21,76	23,45	24,8	0,9	29,27	21,52	24,02	29,0	1,0	29,44
		[24,14; 34,68]	[11,88; 31,63]	[12,74; 34,16]		[0,0; 1,9][a]	[24,06; 34,47]	[8,20; 34,85]	[10,93; 37,12]		[0,0; 2,5][a]	[24,68; 34,20]
Gen 4 (9)		31,77	20,58	19,76	21,3	2,2	31,72	20,33	19,51	26,7	2,8	31,31
		[30,60; 32,94]	[14,66; 26,50]	[14,26; 25,26]		[1,2; 3,3]	[30,51; 32,93]	[13,88; 26,79]	[13,59; 25,42]		[1,7; 3,9]	[29,91; 32,70]
Alle (18)		**30,57**	**19,50**	**19,79**	**23,2**	**1,9**	**30,51**	**19,05**	**19,59**	**30,2**	**2,4**	**30,32**
		[29,27; 31,87]	[15,87; 23,13]	[16,18; 23,40]		[1,3; 2,5]	[29,21; 31,82]	[14,86; 23,25]	[15,47; 23,71]		[1,6; 3,2]	[29,12; 31,53]

[a] Die untere Grenze des t-Intervalls liegt unter null (wenige Sitzungen, große Streuung) und wurde bei 0 abgeschnitten.

Die Personalisierung funktioniert. Über alle 18 Sitzungen sinkt der Testfehler von 30,32 % (Konstant-Baseline) auf 19,79 % mit dem Basismodell `norm_subject` und auf 19,59 % mit dem Basismodell `norm_random`. Das ist eine Verringerung um 35 % bzw. 36 % (Wilcoxon-Vorzeichen-Rang-Test $p = 1{,}5 \cdot 10^{-5}$ für beide; gepaarter t-Test $p < 10^{-6}$). Die unveränderten Basismodelle sind nicht besser als die Konstant-Baseline (30,57 % und 30,51 %; Wilcoxon $p = 0{,}25$ und $p = 0{,}35$). Der ganze Gewinn kommt also aus den wenigen Minuten persönlicher Daten. Die beste Sitzung, S02 (Gen 1, heller Raum, ohne Brille), erreicht 10,5 %. Die neuen Läufe bestätigen die älteren Notebook-Läufe (Mittelwert 19,85 % über dieselben Sitzungen mit `norm_subject`).

Gruppen. Gegenüber der Konstant-Baseline sinkt der Fehler um 48 % / 51 % in Gen 1, um 20 % / 18 % in Gen 2 und um 37 % / 38 % in Gen 4 (`norm_subject` / `norm_random`). In Gen 4 ist die Verbesserung signifikant (Wilcoxon $p = 0{,}004$). Für Gen 1 ($n = 4$) und Gen 2 ($n = 5$) ist der kleinste mögliche p-Wert dieses Tests 0,125 bzw. 0,0625. Diese Gruppen sind also zu klein für ein signifikantes Ergebnis, obwohl der Effekt in Gen 1 groß ist. Die Unterschiede zwischen den Generationen sind nicht signifikant (Kruskal-Wallis $p = 0{,}13$ und $p = 0{,}12$). Man darf sie nicht allein als Wirkung des Aufnahmeablaufs deuten (Abschnitt 4.6).

Wenn die Personalisierung scheitert. In zwei Läufen ist das personalisierte Modell nicht besser als die Konstant-Baseline: S09 mit `norm_subject` (beste Epoch 4, 28,64 % gegenüber 28,17 %) und S05 mit `norm_random` (beste Epoch 2, 32,77 % gegenüber 32,72 %). In beiden Fällen hat sich der Validierungsfehler sehr früh nicht mehr verbessert. Mit dem jeweils anderen Basismodell erreichen dieselben Sitzungen 16,87 % (S09) und 17,64 % (S05). Das Scheitern liegt also nicht an der Sitzung, sondern an einem einzelnen Lauf: Mit nur 20 bis 30 Validierungsbildern (Gen 2) kann das Early Stopping das Training schon nach wenigen Epochs beenden. S07 (dunkler Raum) verbessert sich mit beiden Basismodellen nur wenig (31,0 % / 31,6 % gegenüber 32,3 %). Gutes Licht bleibt also eine Voraussetzung für die Personalisierung mit Webcam.

Basismodell. Beide Basismodelle ergeben dasselbe Ergebnis (19,79 % gegenüber 19,59 %; Wilcoxon $p = 0{,}20$). Das passt zum Hauptergebnis: Das Basismodell liefert vor allem einen Startpunkt, und die persönlichen Daten bestimmen das Ergebnis. In den folgenden Experimenten verwende ich das Basismodell `norm_subject`, weil es ohne Information über die Testpersonen trainiert wurde.

Validierungs- und Testfehler. Im Mittel liegt der Validierungsfehler (19,50 %) nahe am Testfehler (19,79 %). Die größten Abweichungen (5 bis 8 Prozentpunkte, S05 bis S07, S09) gibt es bei den kurzen Gen-2-Aufnahmen. Dort haben Validierung und Test jeweils nur etwa 25 Bilder.

4.4.3. Trainingszeit einer Sitzung

Die Zeit t in Tabelle 4.13 ist die Dauer *eines ganzen Personalisierungslaufs* auf den gespeicherten Features, von der Auswertung des unveränderten Modells bis zum Early Stopping. Die einmalige Berechnung der Backbone-Features ist nicht enthalten. Ein Lauf dauert auf einer CPU im Mittel 1,9 s (`norm_subject`) bzw. 2,4 s (`norm_random`). Die Dauer wächst mit der Zahl der Bilder und der Epochs (kurze Gen-2-Aufnahmen: 0,9 s). Ohne gespeicherte Features, also mit einem Durchlauf jedes Bildes durch den Backbone in jeder Epoch, dauerte ein Lauf 1 bis 26 Minuten pro Sitzung. Die gespeicherten Features machen eine Kalibrierung in Sekunden also erst möglich.

4.4.4. Bereinigung der Labels (Gen 4, E1b)

In Gen 4 beginnt jeder Abschnitt mit einer WAIT-Phase von 0,5 s. Das Ziel erscheint an einer neuen Stelle, und der Nutzer muss es erst finden. Diese Bilder (10,0 bis 10,5 % der Labels) können ein falsches Blicklabel haben. Weil die Phase zu jedem Bild protokolliert ist, kann man diese Bilder gezielt aus den Labels entfernen.

Ein einfacher Vergleich wäre aber unfair: Das bereinigte Modell wird ohne WAIT-Bilder getestet, das ursprüngliche Modell dagegen mit allen Bildern, also auch mit den schwer vorhersagbaren WAIT-Bildern. Deshalb werte ich das ursprüngliche Modell zusätzlich nur auf den MOVE-Bildern seiner Testdaten aus (gleiches Modell, WAIT-Bilder aus dem Test entfernt; Tabelle 4.14).

Tabelle 4.14.: Bereinigung der Labels in Gen 4 (Basismodell `norm_subject`, zufälliger Split, Seed 42). Ursprünglich: mit allen Labels trainiert; Testfehler auf allen Testbildern, nur auf MOVE und nur auf WAIT (n_W = Anzahl der WAIT-Testbilder). Bereinigt: ohne WAIT-Bilder trainiert und getestet. Δ = Bereinigt − Ursprünglich (MOVE).

	Ursprüngliche Labels				Bereinigte Labels		
Sitzung	Alle	MOVE	WAIT	n_W	Test	Konst.	Δ
19	17,76	13,28	41,12	8	13,06	29,07	−0,22
20	14,64	12,24	28,38	8	12,77	30,71	+0,53
21	12,51	9,77	27,59	10	9,79	29,23	+0,01
22	13,02	10,21	27,64	8	9,96	31,71	−0,25
23	23,65	20,95	41,84	10	17,18	30,92	−3,77
24	26,97	24,96	41,93	10	23,99	31,64	−0,97
25	24,61	21,63	44,36	10	17,94	30,49	−3,70
26	18,61	14,34	41,72	10	14,58	30,20	+0,24
27	26,06	23,10	44,80	8	23,69	30,59	+0,60
Mittel	19,76	16,72	37,71	9,1	15,88	30,51	−0,84

Ergebnis. Die WAIT-Bilder werden sehr schlecht vorhergesagt (37,7 %, schlechter als die Konstant-Baseline). Der Blick ist noch nicht auf dem Ziel, ihre Labels sind also falsch. Entfernt man sie nur aus den *Test*daten, sinkt der Fehler von 19,76 % auf 16,72 %. Entfernt man sie auch aus den *Trainings*daten, sinkt er weiter auf 15,88 %. Dieser Gewinn von 0,84 Prozentpunkten ist nicht signifikant (Wilcoxon $p = 0{,}43$). Er kommt von zwei Sitzungen mit unruhigem Hintergrund (S23, S25, je etwa −3,7 Punkte). In den ruhigen Sitzungen ist der Unterschied kleiner als 0,6 Punkte. Fazit: Die WAIT-Bilder sollte man mindestens aus der Auswertung entfernen, weil sie den Fehler der Labels messen und nicht den Fehler des Modells. Sie auch aus dem Training zu entfernen, kostet nichts und hilft in schwierigen Sitzungen; der Effekt ist aber klein.

Schwankung zwischen Läufen. Zwei ältere Läufe mit gleicher Einstellung auf denselben Daten (Gen 4, Seeds nicht fest) unterschieden sich im Mittel um 1,9 und höchstens um 5,5 Prozentpunkte. Die neuen Läufe mit drei festen Seeds (Tabelle 4.15) zeigen eine Standardabweichung von bis zu 3,1 Prozentpunkten zwischen den Seeds. Unterschiede zwischen *einzelnen* Läufen in dieser Größe kann man also nicht deuten. Das erklärt auch die Fälle S05 und S09 oben.

4.4.5. Aufnahmebedingungen (Gen 4)

In Gen 4 kann man Sitzungen vergleichen, die sich nur in einem Faktor unterscheiden. Jeder Wert ist die Differenz zweier einzelner Sitzungen (Testfehler aus Tabelle 4.13, `norm_subject` / `norm_random`, in Prozentpunkten; positiv bedeutet: die erste Bedingung ist schlechter):

- **Brille** (mit − ohne): +5,2/ + 3,6 (S19–S21), +1,6/ + 0,6 (S20–S22), −3,3/ − 3,4 (S23–S24), +6,0/ + 6,2 (S25–S26);
- **Dauer** (90 s − 120 s): −3,1/ − 3,9 (S20–S19), +0,5/ − 0,9 (S22–S21);
- **Hintergrund** (unruhig − ruhig): +5,9/ + 7,2 (S23–S19), +14,5/ + 14,2 (S24–S21);
- **Gerät** (A − B, verschiedene Webcams): +1,0/+0,1 (S25–S23), −8,4/−9,4 (S26–S24).

Der einzige einheitliche und große Effekt ist der **Hintergrund**: Ein unruhiger Hintergrund erhöht den Fehler mit beiden Basismodellen um 6 bis 15 Prozentpunkte. Eine Brille erhöht den Fehler meistens (drei von vier Paaren). Die Dauer (90 vs. 120 s) zeigt keinen klaren Effekt, und der Vergleich der beiden Geräte ist widersprüchlich. Jede Bedingung kommt nur in einzelnen Sitzungen vor. Diese Werte beschreiben also nur, sie sind nicht statistisch getestet.

4.5. Strategien zum Aufteilen der Daten (E2)

Der zufällige Split aus Abschnitt 4.4 hat eine Schwäche: Benachbarte Bilder eines Videos sind fast gleich (6 Labels pro Sekunde). Die Testdaten enthalten also fast exakte Kopien von Trainingsbildern. Das ist ein Datenleck (Data Leakage), und es macht den zufälligen Split zu optimistisch. Der folgende Vergleich misst, wie groß dieser Effekt ist.

Sitzungen. Ich verwende die Sitzungen 21 und 22. Ich wähle sie nach einer festen Regel: Sie sind die einzigen zwei Sitzungen, die sich nur in einem Faktor unterscheiden (Dauer 120 s vs. 90 s). Sonst wurden sie unter den besten Bedingungen aufgenommen (Gen 4, ohne Brille, ruhiger Hintergrund, gleiches Gerät, gleicher Tag). Sie eignen sich daher für den Transfer zwischen zwei Videos, und beide haben genug Bilder (720 und 540) für zeitliche Blöcke.

Strategien.

Zufällig 70 % / 15 % / 15 % der Bilder werden zufällig gezogen (Referenz; enthält fast gleiche Bilder in Training und Test).

Sequenziell Die Bilder bleiben in der Reihenfolge der Aufnahme. Die ersten 70 % sind Training, die nächsten 15 % Validierung und die letzten 15 % Test. Am Anfang des Validierungs- und des Testblocks wird jeweils eine Sekunde (6 Labels) weggelassen, damit keine Nachbarbilder auf beiden Seiten einer Grenze liegen. Das entspricht der echten Nutzung: Der Nutzer kalibriert zuerst und benutzt den Tracker danach.

Zwei Videos 80 % der Bilder der ersten Sitzung sind Training, die übrigen 20 % (zufällig) Validierung. Die zweite Sitzung dient *nur* als Test (alle Bilder). Ich teste beide Richtungen (21→22 und 22→21). So sieht man, ob eine Kalibrierung auch für eine neue Aufnahme derselben Person gilt.

Fairer Vergleich. Alle Strategien verwenden dasselbe Basismodell (`norm_subject`), dieselben Trainingseinstellungen, Early Stopping auf ihren eigenen Validierungsdaten und dieselben drei Seeds (42, 43, 44). Für jeden Lauf gebe ich die Konstant-Baseline (Mittelwert der *Trainings*ziele, ausgewertet auf den Testbildern dieses Laufs) und den Fehler des unveränderten Basismodells auf denselben Testbildern an. So kann man die verschiedenen Testdaten vergleichen. Kein Testbild wird für Training oder Modellauswahl verwendet.

Ergebnis. Die erwartete Reihenfolge stimmt: zufällig (13,85 %) < sequenziell (15,55 %) < zwei Videos (17,24 %). Mit 6 Läufen pro Strategie (zwei Sitzungen × drei Seeds) ist nur der Unterschied zwischen sequenziell und zwei Videos signifikant (Mann-Whitney U, $p = 0{,}009$). Zufällig vs. sequenziell ($p = 0{,}09$) und zufällig vs. zwei Videos ($p = 0{,}06$)

Tabelle 4.15.: Strategien zum Aufteilen der Daten (Sitzungen 21 und 22, Basismodell `norm_subject`, ursprüngliche Labels). Mittelwert über drei Seeds; SD: Standardabweichung des Testfehlers über die Seeds; Basis: unverändertes Basismodell; Red.: Verringerung des Testfehlers gegenüber der Konstant-Baseline; n: Trainings- / Validierungs- / Testbilder; t: Dauer eines Laufs (s).

Strategie	Training → Test	Test (%)	SD	Val. (%)	Basis (%)	Konst. (%)	Red. (%)	n	t (s)
Zufällig	21 → 21	14,40	3,13	14,15	31,52	31,25	53,9	503 / 108 / 109	3,9
	22 → 22	13,30	0,38	15,98	30,97	30,68	56,7	378 / 81 / 81	3,1
Sequenziell	21 → 21	14,47	1,22	19,09	27,62	27,43	47,2	503 / 102 / 103	2,0
	22 → 22	16,63	0,14	14,41	28,83	29,91	44,4	378 / 75 / 75	2,4
Zwei Videos	21 → 22	16,79	0,13	15,67	31,05	32,17	47,8	576 / 144 / 540	5,0
	22 → 21	17,70	0,42	14,33	32,03	33,13	46,6	432 / 108 / 720	3,2
Zufällig (Mittel)		13,85			31,25	30,97	55,3		
Sequenziell (Mittel)		15,55			28,22	28,67	45,8		
Zwei Videos (Mittel)		17,24			31,54	32,65	47,2		

sind es nicht. Weil die Konstant-Baselines der Testdaten verschieden sind, ist die relative Verringerung das fairere Maß: 55 % beim zufälligen Split, aber nur 46 % bis 47 % bei den realistischen Strategien. Der zufällige Split überschätzt den Nutzen der Personalisierung also um etwa 8 bis 9 Prozentpunkte der Verringerung.

Deutung.

- Der zufällige Split ist zu optimistisch, bei diesen beiden guten Sitzungen aber nur mäßig (1,7 Prozentpunkte). Bei schwierigen Sitzungen ist der Effekt viel größer (Abschnitt 4.6.2).
- Eine Kalibrierung funktioniert auch für eine zweite Aufnahme derselben Person unter denselben Bedingungen: Auf einem nie gesehenen Video erreicht das Modell 17 % bis 18 % bei 47 % Verringerung. Der Transfer kostet gegenüber dem zufälligen Split etwa 3 Prozentpunkte.
- Die Ergebnisse mit zwei Videos schwanken am wenigsten zwischen den Seeds (SD unter 0,5), weil die Testdaten groß sind (540 bis 720 Bilder). Der zufällige Split schwankt am meisten (SD 3,1 bei S21), weil seine 81 bis 109 Testbilder vom Seed abhängen.
- Beim sequenziellen Split sagt der Validierungsfehler den Testfehler schlecht voraus (S21: 19,1 % Validierung vs. 14,5 % Test). Validierungs- und Testblock zeigen verschiedene Bereiche des Bildschirms.

Für einen Eye-Tracker, der einmal kalibriert und danach benutzt wird, sind die Werte des sequenziellen Splits und der zwei Videos die realistische Schätzung.

4.6. Gestaltung der Kalibriersitzung

Die Gestaltung der Sitzung bestimmt, welche Bildschirmbereiche die Kalibrierdaten abdecken. Weil die Fehler an Rändern und Ecken am größten sind (Abschnitt 4.3), soll die Gestaltung diese Bereiche gut abdecken. Ich habe drei Varianten aufgenommen:

- **Standardvideo** (Gen 1): Das Ziel bewegt sich gleichmäßig und ohne Sprünge über den Bildschirm;
- **Zufällige Sprünge** (Gen 2): Das Ziel springt alle 1,4 bis 2,7 s an einen zufälligen neuen Startpunkt;
- **Ecken-gewichtete Sprünge** (Gen 4): 5-s-Abschnitte mit 0,5 s WAIT an einem neuen Startpunkt und 4,5 s MOVE; 90 % der Startpunkte liegen in den vier Eckbereichen (je 10 % × 10 % des Bildschirms).

4.6.1. Abdeckung des Bildschirms und Transition Frames

Tabelle 4.16 wird direkt aus den Label- und Positionsdateien der 18 Sitzungen berechnet; dafür ist kein Training nötig. Die Anteile der Regionen nutzen die Einteilung aus Abschnitt 4.3.1 ($r = 0{,}15$). Transition Frames sind Labels, die aufgenommen wurden, während der Blick noch zum neuen Ziel wandert: in Gen 4 die protokollierte WAIT-Phase, in Gen 2 die Labels bis 0,5 s nach einem Sprung (geschätzt, ohne Phasenprotokoll), in Gen 1 keine.

Tabelle 4.16.: Abdeckung des Bildschirms und Transition Frames pro Gestaltung (Mittelwert über die Sitzungen jeder Generation). Zellen: Anteil der 100 Zellen eines 10 × 10-Rasters mit mindestens einem Label; Abst.: mittlerer Abstand der Ziele von der Bildschirmmitte (normierte Einheiten).

Gestaltung	Labels	Länge	Sprünge	Übergang	Anteil der Labels (%)			Zellen	Abst.
		(s)		(%)	Mitte	Ränder	Ecken	(%)	
Standard (Gen 1, 4 Sitz.)	493	82	0	0	7,1	25,0	23,0	97	0,383
Zufällige Sprünge (Gen 2, 5 Sitz.)	179	30	16	28,5[a]	6,3	23,0	26,3	57	0,384
Ecken-gewichtet (Gen 4, 9 Sitz.)	644	107	20	10,1	6,1	19,5	36,1	91	0,420

[a] Geschätzt: Labels bis 0,5 s nach einem Sprung.

Beobachtungen.

- **Die Gewichtung der Ecken wirkt wie geplant:** Gen 4 hat 36 % seiner Labels in der Nähe der Ecken, Gen 1 nur 23 % und Gen 2 26 %. Gen 4 hat auch den größten mittleren Abstand von der Mitte.
- **Eine gleichmäßige Bewegung deckt den Bildschirm am besten ab:** Gen 1 erreicht 97 % der Rasterzellen. Die kurzen Gen-2-Aufnahmen (30 s) decken nur 57 % ab.

- **Transition Frames:** Mit Sprüngen alle 1,4 bis 2,7 Sekunden und ohne Phasenprotokoll fallen im Mittel etwa 28,5 % der Gen-2-Labels in einen Übergang (geschätzt). Gen 4 hat 10 %; diese sind genau protokolliert und können entfernt werden (Abschnitt 4.4.4).

4.6.2. Ergebnis der Personalisierung (E3)

Der zufällige Split bevorzugt Gestaltungen mit langsamer, gleichmäßiger Bewegung, weil fast gleiche Nachbarbilder in Training und Test landen. Deshalb habe ich alle 18 Sitzungen zusätzlich mit dem sequenziellen Split trainiert (Abschnitt 4.5; Basismodell `norm_subject`, Seed 42). Tabelle 4.17 vergleicht beide Splits pro Gestaltung. Tabelle 4.18 zeigt die Fehler pro Bildschirmregion, berechnet aus den gespeicherten Testvorhersagen.

Tabelle 4.17.: Testfehler pro Gestaltung mit zufälligem und sequenziellem Split (Mittelwert über die Sitzungen; Basismodell `norm_subject`). Konst.: Konstant-Baseline der jeweiligen Testbilder; Ep. 0: Anzahl der Sitzungen mit bester Epoch 0 (keine Verbesserung gegenüber dem Basismodell); n_{Test}: mittlere Anzahl der Testbilder.

	Zufälliger Split		Sequenzieller Split			
Gestaltung	Test	Konst.	Test	Konst.	Ep. 0	n_{Test}
Standard (Gen 1)	15,29	29,22	21,52	28,70	1 / 4	69
Zufällige Sprünge (Gen 2)	23,45	29,44	32,80	34,39	2 / 5	22
Ecken-gewichtet (Gen 4)	19,76	31,31	28,07	31,82	5 / 9	91
Alle (18)	19,79	30,32	27,93	31,84[a]	8 / 18	67

[a] Mittelwert der Sitzungswerte des sequenziellen Splits.

Tabelle 4.18.: Testfehler pro Bildschirmregion (Abschnitt 4.3.1, $r = 0{,}15$), Mittelwert über die Sitzungen einer Gestaltung; in Klammern die Gesamtzahl der Testbilder in der Region. Basismodell `norm_subject`.

	Zufälliger Split				Sequenzieller Split			
Gestaltung	Alle	Mitte	Ränder	Ecken	Alle	Mitte	Ränder	Ecken
Standard (Gen 1)	15,3	17,7 (20)	13,5 (67)	16,7 (83)	21,5	11,9 (25)	20,9 (64)	28,9 (52)
Zufällige Sprünge (Gen 2)	23,4	13,7 (12)	21,6 (34)	26,1 (42)	32,8	6,6 (2)[a]	29,8 (15)	38,6 (45)
Ecken-gewichtet (Gen 4)	19,8	11,5 (45)	14,9 (175)	26,5 (299)	28,1	9,0 (60)	23,9 (136)	37,1 (289)
Alle (18)	19,8	13,5 (77)	16,4 (276)	24,2 (424)	27,9	9,7 (87)	24,3 (215)	36,1 (386)

[a] Nur eine Sitzung mit zwei Bildern in der Mitte; nicht aussagekräftig.

Sequenzieller Split. Ohne fast gleiche Bilder in Training und Test steigt der Fehler bei jeder Gestaltung, im Mittel von 19,8 % auf 27,9 % (Wilcoxon $p = 4 \cdot 10^{-5}$). Das personalisierte Modell ist immer noch besser als die Konstant-Baseline (Wilcoxon $p = 0{,}002$), aber

die Verringerung schrumpft von 35 % auf etwa 12 %. In 8 von 18 Sitzungen (02, 05, 08, 23–27) ist die beste Epoch 0: Training auf den ersten 70 % der Aufnahme verbessert den Fehler auf dem Validierungsblock nicht. Das angegebene Ergebnis ist dann das unveränderte Basismodell. Das passiert vor allem in Gen 4 mit unruhigem Hintergrund (23–27) und bei den kurzen Gen-2-Aufnahmen, deren Validierungs- und Testblöcke nur 17 bis 27 Bilder haben. Der zufällige Split aus Abschnitt 4.4 überschätzt den Nutzen der Personalisierung bei schwierigen Sitzungen also stark.

Gestaltungen. Bei beiden Splits hat das Standardvideo (Gen 1) den kleinsten und die zufälligen Sprünge (Gen 2) den größten Fehler. Auch mit dem sequenziellen Split sind die Unterschiede nicht signifikant (Kruskal-Wallis $p = 0{,}06$). Die Reihenfolge lässt sich durch die Abdeckung erklären (Tabelle 4.16): Gen 1 deckt in jedem Teil der Aufnahme 97 % des Bildschirms ab. Bei den Sprung-Gestaltungen deckt ein zeitlicher Block nur die Ziele ab, die in dieser Zeit gezeigt wurden. Die kurzen Gen-2-Aufnahmen leiden am meisten darunter. Die Gestaltungen sind außerdem mit Licht, Hintergrund und Brille vermischt. Die Reihenfolge ist also eine Tendenz, kein Beweis.

Regionen. Die Ecken sind bei jeder Gestaltung und bei beiden Splits am schwierigsten (24 % zufällig, 36 % sequenziell), die Mitte am leichtesten (10 bis 14 %). Die Eckengewichtete Gestaltung senkt den Eckfehler *nicht*: Gen 4 hat 26,5 % / 37,1 % in den Ecken, das Standardvideo 16,7 % / 28,9 %. Mehr Ecklabels allein helfen also nicht, wenn der Blick in den Ecken schwerer zu schätzen ist (Kopfdrehung, halb geschlossene Augen, Lage der Kamera) und wenn die Ecklabels unter schlechteren Bedingungen aufgenommen wurden (Gen-4-Sitzungen 23–27). Außerdem muss die Sigmoid-Ausgabe in den äußersten Ecken nahe 0 oder 1 liegen.

Folgerung für die Gestaltung. Mit den vorhandenen Daten liefert für eine kurze Kalibrierung eine gleichmäßige Zielbewegung über den ganzen Bildschirm das beste Ergebnis. Sprünge erzeugen Transition Frames (Gen 2: im Mittel etwa 28,5 % der Labels). Wenn man Sprünge verwendet, muss man sie protokollieren, damit man diese Bilder entfernen kann. Die Gewichtung der Ecken erhöht den Anteil der Ecklabels wie geplant, senkt aber nicht den Eckfehler.

4.7. Zeitliche Glättung der Vorhersagen (E4)

Die Vorhersagen des Modells springen von Bild zu Bild, auch wenn sich das Ziel nur wenig bewegt. Für eine ruhige Anzeige liegt es nahe, sie über ein gleitendes Zeitfenster zu mitteln

(Moving Average). In den Begriffen aus Abschnitt 2.9.1 kann eine solche Glättung die *Precision* verbessern. Ob sie auch die *Accuracy* verbessert, ist die Frage dieses Abschnitts.

Vorgehen. Für dieses Experiment ist kein neues Training nötig. Ich glätte die gespeicherten Testvorhersagen, die in zeitlicher Reihenfolge vorliegen: den sequenziellen Split aller 18 Sitzungen (Seed 42, Abschnitt 4.6.2) und die zwei Videos (21→22 und 22→21, drei Seeds, Abschnitt 4.5). Der zufällige Split eignet sich nicht, weil seine Testbilder nicht zeitlich geordnet sind. Für ein Fenster von k Bildern ist der *kausale* Moving Average

$$\bar{\boldsymbol{p}}_i = \frac{1}{k} \sum_{j=i-k+1}^{i} \hat{\boldsymbol{p}}_j \tag{4.8}$$

(am Anfang einer Folge entsprechend weniger Bilder). Er nutzt nur vergangene Vorhersagen und kann daher live verwendet werden, läuft dem Blick aber um etwa $(k-1)/2$ Bilder hinterher. Zum Vergleich berechne ich einen *zentrierten* Moving Average über k Bilder um Bild i herum. Er braucht zukünftige Bilder, ist also nur offline möglich, hat aber keine Verzögerung. Bei 6 Labels pro Sekunde entsprechen $k = 3$, 5, 9 und 15 etwa 0,5, 0,8, 1,5 und 2,5 s. Neben der Genauigkeit E_{diag} messe ich die Stabilität als RMS-S2S der Vorhersagen, also den mittleren quadratischen Sprung zwischen zwei aufeinanderfolgenden Vorhersagen, in Prozent der Bildschirmdiagonale. Jedes Fenster wird mit einem gepaarten Wilcoxon-Test über die 18 Sitzungen mit $k = 1$ (ohne Glättung) verglichen; die p-Werte sind je Kennzahl nach Holm für die vier Fenster korrigiert.

Tabelle 4.19.: Zeitliche Glättung der Vorhersagen (sequenzieller Split, 18 Sitzungen, Seed 42). E_{diag} und RMS-S2S in % der Bildschirmdiagonale, Mittelwert über die Sitzungen; Δ: Differenz zu $k = 1$ in Prozentpunkten. *: signifikant gegenüber $k = 1$ (Wilcoxon, Holm-korrigiert, $p < 0{,}05$).

		Kausal (live möglich)			Zentriert (nur offline)		
k	Fenster	E_{diag}	Δ	RMS-S2S	E_{diag}	Δ	RMS-S2S
1	—	27,93	—	2,17	27,93	—	2,17
3	0,5 s	28,10	+0,17	1,29*	27,79	−0,14*	1,30*
5	0,8 s	28,33	+0,40	1,01*	27,73	−0,20	1,02*
9	1,5 s	28,87	+0,94	0,79*	27,80	−0,14	0,78*
15	2,5 s	29,68	+1,75*	0,63*	28,02	+0,09	0,62*

Stabilität. Die Glättung macht die Vorhersagen deutlich ruhiger (Tabelle 4.19). Schon $k = 3$ senkt RMS-S2S um 40 % (2,17 → 1,29), $k = 15$ um 71 %. Der Unterschied ist für alle Fenster und beide Filter signifikant (Holm-korrigiert $p < 0{,}001$).

Genauigkeit. Die Genauigkeit verbessert sich mit dem kausalen Moving Average dagegen nicht. Der Fehler steigt mit dem Fenster: Bei $k = 3$ und $k = 5$ ist der Anstieg klein und nicht signifikant (+0,17 und +0,40 Prozentpunkte), bei $k = 15$ beträgt er +1,75 Prozentpunkte (Holm $p = 0{,}031$). Der Grund ist die Verzögerung: Das Ziel bewegt sich in fast allen Bildern (Gen 1 und die MOVE-Phase von Gen 4), und die geglättete Vorhersage läuft ihm hinterher. Der Effekt ist dort am größten, wo das Modell der Bewegung tatsächlich folgt. In den zehn Sitzungen, in denen das Training das Modell verändert hat (beste Epoch > 0), ist die Vorhersage unruhiger (RMS-S2S 3,75), und $k = 15$ erhöht den Fehler um 3,13 Prozentpunkte (24,91 → 28,04). Bei den zwei Videos steigt der Fehler schon bei $k = 5$ von 17,24 % auf 19,78 %. In den acht Sitzungen mit unverändertem Basismodell liegen die Vorhersagen nahe der Mitte, und die Glättung ändert dort kaum etwas.

Wie viel Fehler ist Rauschen? Der zentrierte Moving Average zeigt, was eine Glättung *ohne* Verzögerung höchstens bringen kann. Der Gewinn ist klein: im besten Fall −0,20 Prozentpunkte über alle Sitzungen ($k = 5$; Holm $p = 0{,}055$), −0,36 Prozentpunkte in den zehn angepassten Sitzungen ($p = 0{,}023$) und −1,2 Prozentpunkte bei den zwei Videos. Der größte Teil des Fehlers ist also *systematisch* (Versatz und Zug zur Bildschirmmitte) und kein zufälliges Rauschen von Bild zu Bild. Ein Mittelwert kann nur das Rauschen entfernen, nicht den systematischen Fehler.

Fixationen in der Demo. Wenn das Ziel stillsteht, entfällt die Verzögerung weitgehend. Im kurzen Test der Web-Demo (fünf feste Punkte, 77 Vorhersagen, ein Durchlauf; Abschnitt 6.2) halbiert $k = 3$ das Springen der Vorhersagen (RMS-S2S 5,79 → 2,41), und der Fehler ändert sich kaum (18,97 % → 19,12 %). Dieser Wert stammt aus einem einzelnen Durchlauf und ist nur ein Hinweis.

Folgerung. Ein Moving Average ist ein Kompromiss zwischen Stabilität und Verzögerung. Ein kurzes kausales Fenster von etwa 0,5 s ($k = 3$) senkt das Springen der Vorhersagen um 40 bis 60 % und kostet keine messbare Genauigkeit. Längere Fenster lohnen sich nicht, weil die Verzögerung bei bewegtem Blick den Fehler erhöht. Die Web-Demo verwendet deshalb ein Fenster von 0,5 s. Um die Genauigkeit zu verbessern, muss man den systematischen Fehler verringern, zum Beispiel durch eine bessere Eingabe oder mehr Kalibrierdaten.

4.8. Zweite Person (E5)

Alle bisherigen Ergebnisse stammen von Person A. Um zu prüfen, ob sich der Nutzen auf eine andere Person übertragen lässt, hat Person B zwei Sitzungen mit demselben Protokoll aufgenommen (Abschnitt 3.2): Sitzung 28 mit Gerät A und ruhigem Hintergrund,

Sitzung 29 mit Gerät B und unruhigem Hintergrund mit Fenster. Beide werden genauso ausgewertet wie die Sitzungen von Person A (Basismodell `norm_subject`, Seed 42). Zusätzlich prüfe ich mit zwei Videos, ob eine Kalibrierung zwischen den beiden Sitzungen und zwischen den Personen übertragbar ist. Als Partner von Person A dienen die Sitzungen mit den ähnlichsten Bedingungen: 24 (Gerät B, ohne Brille, unruhig) und 26 (Gerät A, ohne Brille).

Tabelle 4.20.: Ergebnisse von Person B und Vergleich mit Person A. E_{diag} in %; Konst.: Konstant-Baseline derselben Testdaten. Zum Vergleich die Partner-Sitzungen von Person A.

			Zufälliger Split		Sequenzieller Split	
Sitzung	Person	Gerät / Hintergrund	E_{diag}	Konst.	E_{diag}	Konst.
28	B	A / ruhig	34,04	34,10	37,83	40,54
29	B	B / unruhig, Fenster	32,33	32,32	36,16	35,10
26	A	A / unruhig	18,61	29,48	31,74	30,32
24	A	B / unruhig	26,97	33,01	36,62	35,98

Personalisierung. Bei Person B hat die Personalisierung in beiden Sitzungen nicht funktioniert (Tabelle 4.20). Selbst mit zufälligem Split, der bei Person A immer einen deutlichen Gewinn zeigt, liegt der Fehler genau bei der Konstant-Baseline (34,04 % gegenüber 34,10 % und 32,33 % gegenüber 32,32 %). Das Early Stopping wählt eine sehr frühe Epoch (0 bis 8), und die Vorhersagen bleiben fast konstant in der Bildschirmmitte (Standardabweichung unter 0,005). Der Head findet in den Features also keinen Zusammenhang mit dem Blick. Beim sequenziellen Split bleibt das Basismodell unverändert (beste Epoch 0). Die Partner-Sitzungen von Person A zeigen unter ähnlichen Bedingungen zumindest mit zufälligem Split einen klaren Gewinn (-37 % bzw. -18 %).

Übertragung zwischen Sitzungen und Personen. Auch mit zwei Videos bleibt der Fehler bei Person B auf der Höhe der Konstant-Baseline: 28→29 33,94 % (Konstant 34,30 %) und 29→28 34,11 % (34,06 %), jeweils gemittelt über drei Seeds. Eine Kalibrierung von Person A auf Person B ist dagegen *schlechter* als die Bildschirmmitte: 24→29 35,15 % gegenüber 33,93 % und 26→28 34,81 % gegenüber 33,45 %. In umgekehrter Richtung (29→24, 28→26) bleibt das Modell von Person B nahe der Mitte. Eine Kalibrierung ist also personengebunden.

Ursache: die Eingabe. Naheliegend ist die Eingabe: Das Modell nutzt das ganze Kamerabild, in dem die Augen nur wenige Pixel groß sind. Ein Teil des Gewinns bei Person A stammt vermutlich aus kleinen Kopfbewegungen, die den Blick begleiten. Hält eine Person

den Kopf ruhiger, fehlt dieses Signal. Das passt zu dem Vorschlag, Augen- oder Gesichtsausschnitte zu verwenden (Abschnitt 6.2). Ein Durchlauf der Web-Demo mit Person B stützt diese Erklärung (Tabelle 4.21). Die Demo verwendet einen Augenausschnitt und räumliche Features. Damit sank der Fehler auf den Prüfdaten der Kalibrierung bei Person B von 26,9 % (Basismodell) auf 9,7 %, ähnlich wie bei Person A (26,0 % → 6,7 %). Auch der Test mit fünf Punkten lag mit 20,8 % unter der konstanten Schätzung (26,6 %). Außerdem wählte die Demo für Person B kein Gewicht für die Kopfposition, für Person A dagegen schon; das passt zu einem ruhigeren Kopf. Die Demo unterscheidet sich allerdings in mehreren Punkten von den Experimenten (Ausschnitt, räumliche Features, Ridge Regression, andere Kalibrierbewegung), und es gibt pro Person nur einen Durchlauf. Der Vergleich ist daher ein starker Hinweis, aber kein Beweis.

Tabelle 4.21.: Web-Demo mit Augenausschnitt, je ein Durchlauf (Gerät A, Kalibrierung 60 s). Fehler in % der Bildschirmdiagonale; Prüfdaten: 2 von 10 Zeitabschnitten der Kalibrierung, nicht im Training.

	Prüfdaten der Kalibrierung			Test mit 5 Punkten	
Person	Konstant	Basismodell	Personalisiert	Fehler	Messungen
A	28,3	26,0	6,7	11,8	78
B	26,6	26,9	9,7	20,8	35

Glättung. Weil die Vorhersagen von Person B fast konstant sind, ändert der Moving Average dort weder den Fehler noch die Stabilität merklich (RMS-S2S unter 0,2).

4.9. Diskussion der Ergebnisse

Hauptergebnis. Auf GazeCapture erreichen alle Einstellungen der Hyperparameterstudie praktisch nur den Fehler eines konstanten Schätzers auf denselben Testdaten: Die besten Einstellungen mit „nur FC“ liegen zwischen 28,32 % und 28,39 %, die Konstant-Baseline bei 28,46 %. Die räumliche Analyse bestätigt, dass die Vorhersagen in der Bildschirmmitte liegen. Die Hyperparameterstudie trennt die Einstellungen daher vor allem nach ihrer *Stabilität*: Optionen, die das Training unruhiger machen (Gauß, ReLU, keine Activation, mehr trainierbare Schichten, sensitiver Loss), sind schlechter. Aber keine Option verlässt deutlich die Mitte. Die Entscheidungen in Abschnitt 4.2 beruhen daher auf Stabilität, Lernverlauf, Aufwand und methodischen Gründen, wie in jedem Unterabschnitt beschrieben. Einzelne Notebook-Läufe auf `norm_random` (Abbildung 4.2) erreichten zwar etwa 23,6 % bei einer Konstant-Baseline von 26,8 % auf ihren Testdaten. Diese Läufe nutzten aber eine ältere Datenauswahl. Mit dem aktuellen Protokoll (zufällige Datenauswahl, fünf Läufe) ist ein

solcher Lerneffekt nicht sichtbar. Die älteren Werte sind daher kein Beleg für einen Lerneffekt. Die Basismodelle bestätigen das: Ihr Fehler auf den persönlichen Sitzungen (30,6 %) entspricht der Konstant-Baseline.

Mögliche Ursachen. Zwei Erklärungen kann das neue Protokoll bereits ausschließen: Die Trainingsdaten enthalten jetzt 179 statt fünf Personen, und die Testdaten werden nicht mehr für die Modellauswahl verwendet. Trotzdem bleiben die Vorhersagen in der Mitte. Die wahrscheinlichsten Ursachen sind: (i) Ich verwende ganze Kamerabilder. Die Augen sind darin nur ein kleiner Teil des Bildes. Die eingefrorenen ImageNet-Features enthalten daher wenig Blickinformation. (ii) 1000 Bilder von 179 Personen sind nur etwa sechs Bilder pro Person. Das ist zu wenig, um eine Abbildung für alle Personen zu lernen. Mehr trainierbare Schichten mit so wenigen Daten machen das Training nur instabil (Abschnitt 4.2.3). Gesichts- oder Augenausschnitte als Eingabe und mehr Trainingsdaten sind die nächsten Schritte, die man prüfen sollte.

Personalisierung. Mit demselben eingefrorenen Backbone senkt ein Head, der auf einigen hundert Bildern einer Person trainiert wurde, den Fehler gegenüber der Konstant-Baseline. Mit einem zeitlichen Split, der der echten Nutzung entspricht, beträgt die Verringerung im Mittel etwa 12 % (31,8 % → 27,9 %) und in schwierigen Sitzungen null. Gute Sitzungen behalten aber den größten Teil des Gewinns, und eine Kalibrierung funktioniert sogar für eine zweite Aufnahme (47 % Verringerung, Abschnitt 4.5). Der zufällige Split zeigt eine Verringerung um etwa ein Drittel, ist aber zu optimistisch. Ein Lauf dauert auf einer CPU etwa zwei Sekunden, und die Wahl des Basismodells spielt keine Rolle; es liefert vor allem einen Startpunkt. Das unterstützt die zentrale Idee dieser Arbeit, die dateneffiziente Personalisierung eines vortrainierten Modells. Wichtig ist außerdem: Die Aufnahmebedingungen (Hintergrund, Licht, Brille) beeinflussen das Ergebnis stärker als die Gestaltung der Sitzung.

Reproduzierbarkeit. Gegenüber früheren Versuchen wurden die Fehlermetrik korrigiert, die Baselines auf denselben Teilmengen wie das Modell berechnet und eine personendisjunkte Validierungsmenge eingeführt. Die Personalisierungsläufe sind mit festen Seeds, eingefrorener BatchNorm und gespeicherten Vorhersagen reproduzierbar (Anhang A.2).

4.10. Zusammenfassung der Ergebnisse

Tabelle 4.22 fasst alle Experimente zusammen. „Signifikant“ bedeutet $p < 0{,}05$ im Test, der im jeweiligen Abschnitt genannt ist. Alle Fehler sind Diagonalfehler (Gleichung (4.1)) in %. MAE und MSE wurden in diesen Experimenten nicht protokolliert. Der Diagonalfehler

(ein skalierter euklidischer RMSE) ist daher das einzige Genauigkeitsmaß, das für alle Experimente vorhanden und vergleichbar ist.

Tabelle 4.22.: Zusammenfassung der Ergebnisse und der gewählten Einstellung. GazeCapture: `norm_subject`, 1000/200 zufällige Bilder, fünf Läufe, Konstant-Baseline 28,46 %; Zeit = mittlere Dauer eines Trainingslaufs in Minuten (Head auf gespeicherten Features). Personalisierung: Mittelwert über die Sitzungen, Zeit = ein Lauf pro Sitzung in Sekunden (Abschnitt 4.4.3).

Experiment	Gewählt	Fehler (%)	Zeit	Ergebnis und Begründung
Baselines	—	28,46	—	Konstant-Baseline auf denselben Testdaten; Zufalls-Baseline 40,36 (Abschnitt 4.1.5)
Zieldarstellung	normiert $[0,1]^2$	—	—	unabhängig vom Gerät; Metrik sinnvoll definiert (Abschnitt 4.1.4)
Batch Size	32	28,39	0,019 min	kein signifikanter Unterschied (Abschnitt 4.2.1)
Learning Rate	10^{-4}	28,37	0,020 min	kleinster Fehler im ersten Test, schnell; Wiederholung ohne signifikanten Unterschied (Abschnitt 4.2.2)
Trainierbare Schichten	nur FC	28,36	0,015 min	kleinster und stabilster Fehler; FC + Layer 4: 9,2 min, voll: 15,4 min (Abschnitt 4.2.3)
Activation	Sigmoid	**28,36**	0,022 min	**signifikant** besser als Gauß, ReLU, Keine (Abschnitt 4.2.4)
Loss Function	L1	**28,32**	0,011 min	**signifikant** besser als der sensitive Loss (Abschnitt 4.3.4)
Datenmenge	1000/200	28,39	0,018 min	größere Menge nur wegen anderer Testdaten besser (Abschnitt 4.2.5)
Split	`norm_subject`	28,39	0,020 min	einziger Split, der unbekannte Personen misst (Abschnitt 4.2.6)
Personalisierung (E1)	nur FC, 18 Sitzungen	**19,79**	1,9 s	**signifikant** besser als Konstant-Baseline (30,32) und Basismodell (30,57), −35 % (Abschnitt 4.4.2)
Basismodell (E0/E1)	`norm_subject`	19,79	1,9 s	gleich wie `norm_random` (19,59; 2,4 s; $p = 0{,}20$); gewählt, weil es keine Information über die Testpersonen enthält
Bereinigung (E1b)	WAIT-Bilder entfernen	15,88	—	vs. 16,72 auf denselben MOVE-Testbildern; −0,84, nicht signifikant; WAIT-Bilder selbst 37,7 (Abschnitt 4.4.4)
Aufteilung der Daten (E2)	sequenziell / zwei Videos	15,55 / 17,24	2–5 s	zufällig 13,85 ist zu optimistisch; zwei Videos signifikant schlechter als sequenziell; Kalibrierung funktioniert auch für ein neues Video (−47 %) (Abschnitt 4.5)
Gestaltung der Sitzung (E3)	Standardvideo	15,29 / 21,52	—	zufälliger / sequenzieller Split; zufällige Sprünge 23,45 / 32,80, Ecken-gewichtet 19,76 / 28,07; nicht signifikant und vermischt; Ecken-Gewichtung senkt den Eckfehler nicht (Abschnitt 4.6.2)
Glättung (E4)	kausal, $k = 3$ (0,5 s)	28,10	—	sequenzieller Split; vs. 27,93 ohne Glättung, nicht signifikant; Springen (RMS-S2S) −40 %, signifikant; längere Fenster erhöhen den Fehler (Abschnitt 4.7)
Zweite Person (E5)	Person B, 2 Sitzungen	34,04 / 32,33	—	zufälliger Split; gleich der Konstant-Baseline (34,10 / 32,32), kein Gewinn; Kalibrierung von Person A auf Person B schlechter als die Mitte; mit Augenausschnitt (Demo) 9,7 statt 26,9 (Abschnitt 4.8)

5. Diskussion

5.1. Antworten auf die Forschungsfragen

FF1: Wie stark hilft eine kurze Personalisierung? Das allgemeine Basismodell ist auf den eigenen Aufnahmen nicht besser als die Konstant-Baseline (30,57 % gegenüber 30,32 %). Bei einem zeitlichen Split, der der echten Nutzung entspricht, verbessert die Personalisierung das Ergebnis. Der Fehler sinkt von 31,84 % auf 27,93 %. Das ist eine Verbesserung von etwa 12 % (Wilcoxon $p = 0{,}002$). In 8 von 18 Sitzungen gibt es jedoch keine Verbesserung (Abschnitt 4.6.2). Bei den guten Sitzungen 21 und 22 ist die Verbesserung mit 46 % weiterhin deutlich. Auch bei einer zweiten Aufnahme bleibt der Gewinn mit 47 % fast gleich (Abschnitt 4.5).

Bei einem zufälligen Split sind die Ergebnisse noch besser. Der Fehler sinkt auf 19,79 %, also um etwa ein Drittel. Die beste Sitzung erreicht sogar einen Fehler von nur 10,5 % (Abschnitt 4.4.2). Dieser Split zeigt aber ein zu positives Ergebnis und entspricht nicht der echten Nutzung.

Bei Person B brachte die Personalisierung mit dem vollständigen Kamerabild in beiden Sitzungen keine Verbesserung. Das gilt auch beim zufälligen Split. Mit dem Augenausschnitt aus der Web-Demo sank der Fehler dagegen von 26,9 % auf 9,7 % (Abschnitt 4.8).

Antwort: Eine kurze Personalisierung kann den Fehler deutlich reduzieren. Das funktioniert aber nicht bei jeder Aufnahme gleich gut. Gute Aufnahmebedingungen und ein passender Bildausschnitt der Augen sind dafür wichtig. Ein zufälliger Split zeigt außerdem bessere Ergebnisse, als man bei der echten Nutzung erwarten kann.

FF2: Welche Trainingseinstellung eignet sich? Auf GazeCapture zeigen die meisten Trainingseinstellungen keinen deutlichen Unterschied. Die Ergebnisse aller Modelle liegen nahe an der Konstant-Baseline (Abschnitt 4.2). Die Tests zeigen aber, dass Sigmoid als Activation die besten Ergebnisse liefert. Außerdem ist L1-Loss besser als der Loss mit Positionsgewichtung. Es reicht aus, nur den Regression Head zu trainieren. Das liefert ähnliche Ergebnisse wie das Training weiterer Schichten, ist aber stabiler und deutlich schneller.

Antwort: Für das Training eignet sich folgende Einstellung:

- eingefrorener Backbone (wird nicht trainiert),

- Regression Head mit Sigmoid,
- L1-Loss,
- Learning Rate 10^{-4},
- Batch Size 32.

Diese Einstellung wurde vor allem wegen ihrer Stabilität und des geringen Trainingsaufwands ausgewählt. Die Learning Rate 10^{-4} wurde zusätzlich gewählt, weil sie im ersten Test den kleinsten Fehler erreicht hat.

FF3: Welche Rolle spielen Datenaufteilung, Kalibrierung und Glättung? Die Aufteilung der Daten hat einen großen Einfluss auf die Ergebnisse. Ein zufälliger Split liefert zu gute Ergebnisse, weil fast gleiche Bilder aus einer Aufnahme sowohl im Training als auch im Test vorkommen. Die gleichmäßige Bewegung des Ziels über den Bildschirm (Gen 1) deckt den Bildschirm am besten ab und erreicht den kleinsten Fehler; der Unterschied ist allerdings nicht signifikant (Abschnitt 4.6.2). Bei schnellen Sprüngen entstehen Bilder mit falschen Labels. Wenn diese WAIT-Bilder entfernt werden, verbessert sich das Ergebnis leicht um 0,84 Prozentpunkte. Diese Verbesserung ist jedoch nicht signifikant. Mehr Daten in den Ecken verbessern die Ergebnisse in diesen Bereichen nicht. Ein Moving Average über die Vorhersagen macht die Anzeige deutlich ruhiger. Bei einem Fenster von $k = 3$ sinkt die RMS-S2S um 40 %. Die Genauigkeit wird dadurch aber nicht besser. Bei längeren Fenstern wird das Ergebnis sogar schlechter, weil die Vorhersage stärker verzögert wird (Abschnitt 4.7).

Antwort: Für die Kalibrierung ist eine kurze und gleichmäßige Bewegung über den gesamten Bildschirm am besten. Schnelle Sprünge sollten erkannt und protokolliert werden, damit die Bilder während dieser Bewegungen später entfernt werden können. Für die Bewertung sollte immer ein zeitlicher Split verwendet werden, da dieser der echten Nutzung besser entspricht. Ein kurzer Moving Average (etwa 0,5 s) kann die Anzeige ruhiger machen. Er verbessert aber nicht die Genauigkeit und ersetzt keine bessere Kalibrierung.

FF4: Welchen Einfluss haben die Aufnahmebedingungen? Der größte Einfluss kommt vom Hintergrund. Ein unruhiger Hintergrund erhöht den Fehler um 6 bis 15 Prozentpunkte. Auch eine Brille führt meistens zu einem höheren Fehler. In dunklen Räumen hilft die Personalisierung nur wenig. Die Dauer der Aufnahme und das verwendete Gerät (Webcam) zeigen dagegen keinen klaren Einfluss (Abschnitt 4.4.5).

Antwort: Ein ruhiger Hintergrund und gute Lichtverhältnisse sind für gute Ergebnisse besonders wichtig. Sie haben einen größeren Einfluss als die Art der Kalibrierung. Diese Ergebnisse basieren jedoch nur auf einzelnen Sitzungen und müssen deshalb vorsichtig betrachtet werden.

5.2. Einordnung in den Stand der Technik

Einige Ergebnisse passen gut zur Literatur:

- **Wenige Parameter reichen.** Wie bei der Offset-Kalibrierung [27], bei SPAZE [28] und bei PIGaze [39] genügt hier ein kleiner, angepasster Head auf einem eingefrorenen Backbone. Mehr trainierbare Schichten machen das Training nur instabiler. Das passt zu Kumar et al. [22].
- **Personalisierung ist der wichtigste Faktor.** Wie bei Valliappan et al. [7] kommt fast der ganze Gewinn aus wenigen Sekunden persönlicher Daten.
- **Das Evaluationsprotokoll entscheidet.** Ähnlich wie beim Unterschied zwischen `norm_random` und `norm_subject` überschätzen zufällige Splits die Leistung (Abschnitt 2.7.1).
- **Glättung verbessert die Precision, nicht die Accuracy.** Das entspricht der Unterscheidung von Niehorster et al. [40]: Ein Moving Average verringert die Streuung von Bild zu Bild deutlich, der systematische Fehler bleibt aber fast gleich (Abschnitt 4.7).
- **Falsche Labels haben einen kleinen Effekt.** Auch DMRF [41] senkt den Fehler nur wenig (3,92° → 3,85°). Hier bringt das Entfernen der WAIT-Bilder 0,84 Prozentpunkte; dieser Unterschied ist nicht signifikant ($p = 0{,}43$).

Es gibt aber auch einen wichtigen Unterschied: Das allgemeine Modell dieser Arbeit ist sehr schwach. Es bleibt bei der Bildschirmmitte, während Verfahren in der Literatur auch ohne Personalisierung einige Grad Genauigkeit erreichen. Der wichtigste Grund ist wahrscheinlich die Eingabe: Die meisten Verfahren nutzen Gesichts- oder Augenausschnitte, diese Arbeit dagegen das ganze Kamerabild. Außerdem nutzt das Basismodell nur 1000 Bilder von 179 Personen. Die absoluten Zahlen sind wegen der unterschiedlichen Metriken ohnehin nicht direkt mit der Literatur vergleichbar (Abschnitt 2.10).

5.3. Grenzen der Arbeit

- **Wenige Personen:** Die 18 ausgewerteten Sitzungen stammen von einer Person (dem Autor). Von einer zweiten Person gibt es nur zwei Sitzungen und einen Durchlauf der Demo. Dass der Augenausschnitt die Ursache des Unterschieds ist, ist ein Hinweis aus diesem einen Durchlauf und nicht systematisch geprüft. Die Ergebnisse lassen sich daher nicht ohne Weiteres auf andere Personen übertragen.

- **Wenige Sitzungen und vermischte Bedingungen:** 18 Sitzungen reichen nicht für sichere Aussagen über einzelne Faktoren. Gestaltung, Licht, Hintergrund und Brille ändern sich oft gleichzeitig.
- **Einzelne Läufe:** Pro Sitzung gibt es meist nur einen Lauf (Seed 42). Die Streuung zwischen Seeds kann bis zu 3 Prozentpunkte betragen.
- **Ein Backbone und ganze Bilder:** Untersucht wurde nur ResNet-18 mit ganzen Kamerabildern. DINOv2, CLIP, MAE, UniGaze, Adapter und LoRA wurden nicht getestet, ebenso wenig Gesichts- oder Augenausschnitte in den Experimenten von Kapitel 4.
- **Schwaches Basismodell:** Das Basismodell lernt auf GazeCapture kaum etwas und dient in dieser Arbeit vor allem als Startpunkt für die Personalisierung. Ob ein zufällig initialisierter Head ähnlich gut wäre, wurde nicht getestet. Ein besseres Basismodell könnte die Personalisierung verändern.
- **Viele Tests:** Es wurden viele statistische Tests ohne Korrektur für Mehrfachvergleiche (zum Beispiel nach Bonferroni) gerechnet. Knappe Ergebnisse wie $p = 0{,}032$ (L1 gegenüber dem sensitiven Loss) sind daher vorsichtig zu lesen.
- **Glättung nur nachträglich:** Der Moving Average wurde auf gespeicherten Vorhersagen des sequenziellen Splits (meist ein Seed) und der zwei Videos ausgewertet. Für Fixationen gibt es nur einen einzelnen Durchlauf der Demo.
- **Metrik:** Der Diagonalfehler ist nicht direkt mit Winkelfehlern oder Zentimetern aus der Literatur vergleichbar.

6. Fazit und Ausblick

6.1. Fazit

In dieser Arbeit wurde untersucht, ob ein vortrainiertes Bildverarbeitungsmodell mit einer kurzen Kalibrierung über eine Webcam an eine bestimmte Person angepasst werden kann. Dafür wurde ein ResNet-18 verwendet, das bereits auf ImageNet trainiert wurde. Die Gewichte dieses Modells blieben während des Trainings unverändert. Nur ein kleiner zusätzlicher Teil für die Berechnung der Blickposition (Regression Head) wurde trainiert.

Die wichtigsten Ergebnisse dieser Arbeit lassen sich wie folgt zusammenfassen:

- **Das allgemeine Modell allein liefert noch keine guten Ergebnisse.** Das auf GazeCapture trainierte Modell war auf den eigenen Aufnahmen nicht besser als eine einfache Schätzung, die immer die Bildschirmmitte ausgibt. Deshalb eignet sich das allgemeine Modell vor allem als Ausgangspunkt für die spätere Personalisierung.
- **Eine kurze Personalisierung kann den Fehler deutlich reduzieren.** Mit wenigen Minuten persönlicher Aufnahmen sank der Fehler bei einem zeitlichen Split von 31,8 % auf 27,9 % der Bildschirmdiagonale. Das entspricht einer Verbesserung von etwa 12 % über 18 Sitzungen. Bei guten Aufnahmen war die Verbesserung sogar etwa 46 %. Dieser Gewinn konnte auch bei einer neuen Aufnahme derselben Person beobachtet werden. Das Training dauert auf einer CPU nur ungefähr zwei Sekunden. Die Personalisierung benötigt also nicht viel Zeit und auch keine besonders starke Hardware.
- **Ein zufälliger Split zeigt deutlich bessere Ergebnisse, ist aber nicht realistisch.** Bei dieser Aufteilung sank der Fehler von 30,3 % auf 19,8 %. Das entspricht einer Verbesserung von etwa 35 %. Dieses Ergebnis ist jedoch zu positiv, weil sehr ähnliche Bilder aus derselben Aufnahme sowohl im Trainings- als auch im Testdatensatz vorkommen können. Deshalb zeigt ein zufälliger Split nicht zuverlässig, wie gut das Modell bei einer späteren echten Nutzung funktioniert.
- **Die Aufnahmebedingungen haben einen großen Einfluss auf die Genauigkeit.** Besonders wichtig sind ein ruhiger Hintergrund und ausreichend Licht. Ein unruhiger Hintergrund kann den Fehler deutlich erhöhen. Außerdem hat eine gleichmäßige Bewegung des Kalibrierungspunkts über den gesamten Bildschirm

die besten Ergebnisse geliefert, wenn auch nicht signifikant. Die Art der Kalibrierung allein reicht also nicht aus. Auch die Bedingungen während der Aufnahme müssen stimmen.

- **Bilder während der Bewegung des Kalibrierungspunkts können falsche Labels enthalten.** Besonders direkt nach einem Sprung des Punkts stimmen die gespeicherten Blickpositionen teilweise nicht mehr mit der tatsächlichen Position überein. Das Entfernen dieser Bilder verbessert die Ergebnisse nur leicht. Trotzdem ist es sinnvoll, diese Bilder zu erkennen und beim Training nicht zu verwenden.
- **Die Eingabe des Modells ist ebenfalls sehr wichtig.** Bei einer zweiten Person brachte die Personalisierung mit dem vollständigen Kamerabild zunächst keine Verbesserung. Mit einem Ausschnitt, der hauptsächlich die Augen zeigt, sank der Fehler in der Web-Demo dagegen von 26,9 % auf 9,7 %. Das zeigt, dass nicht nur das Training, sondern auch die verwendeten Bildinformationen eine wichtige Rolle spielen. Außerdem ist die Kalibrierung stark von der jeweiligen Person abhängig. Die Kalibrierung von Person A führte bei Person B sogar zu schlechteren Ergebnissen als die einfache Schätzung der Bildschirmmitte.
- **Eine Glättung macht die Vorhersagen ruhiger, verbessert aber nicht die Genauigkeit.** Ein kurzer Moving Average mit ungefähr 0,5 s macht die Vorhersagen um etwa 40 % stabiler. Die Genauigkeit bleibt dabei ungefähr gleich. Bei längeren Zeitfenstern wird der Fehler jedoch größer, weil die Vorhersage zu spät auf eine Änderung der Blickposition reagiert. Ein großer Teil des Fehlers entsteht also durch systematische Abweichungen, die sich durch eine Glättung nicht beheben lassen.

Insgesamt zeigen die Ergebnisse dieser Arbeit, dass eine Personalisierung mit wenigen persönlichen Aufnahmen und einem einfachen Trainingsverfahren möglich ist. Dafür muss nicht das gesamte vortrainierte Modell neu trainiert werden. Es reicht aus, einen kleinen zusätzlichen Teil des Modells anzupassen. Dadurch ist das Training schnell und benötigt nur wenige persönliche Daten.

Allerdings hängt der Erfolg stark von den Aufnahmebedingungen, der verwendeten Eingabe und der jeweiligen Person ab. Besonders wichtig sind ein ruhiger Hintergrund, gutes Licht und eine geeignete Aufnahme der Augen. Außerdem muss das Modell mit einer zeitlichen Aufteilung der Daten bewertet werden, damit die Ergebnisse möglichst gut der späteren echten Nutzung entsprechen.

Die Untersuchung mit einer zweiten Person hat außerdem gezeigt, dass die gleichen Einstellungen nicht automatisch bei jeder Person funktionieren. Eine Kalibrierung, die für eine Person gut funktioniert, kann bei einer anderen Person sogar schlechtere Ergebnisse liefern. Deshalb sind weitere Untersuchungen mit mehr Personen notwendig. Nur so kann besser beurteilt werden, wie gut sich die Methode auch auf andere Personen übertragen lässt.

6.2. Ausblick

Mehrere nächste Schritte liegen nahe:

- **Augen- oder Gesichtsausschnitte als Eingabe.** Im ganzen Kamerabild sind die Augen sehr klein. Ein Ausschnitt gibt dem Modell viel mehr Blickinformation; der Durchlauf der Demo mit Person B spricht stark dafür (Abschnitt 4.8). Dieser Schritt sollte als Erstes systematisch mit allen Sitzungen geprüft werden.
- **Andere vortrainierte Modelle.** DINOv2, CLIP, MAE oder UniGaze statt ResNet-18, jeweils mit eingefrorenem Backbone und kleinem Head.
- **Sparsame Anpassung des Backbones.** Adapter oder LoRA als Mittelweg zwischen reinem Head-Training und vollständigem Fine-Tuning.
- **Mehr Personen und mehr Sitzungen,** mit Bedingungen, die sich jeweils nur in einem Faktor ändern.
- **Adaptive Glättung.** Filter, die bei schneller Bewegung weniger und bei Fixationen stärker glätten, zum Beispiel der 1-Euro-Filter [44], könnten die Ruhe des Moving Average ohne seine Verzögerung erreichen.
- **Kopfbewegung berücksichtigen,** zum Beispiel mit der Kopfposition als zusätzlichem Feature oder mit normalisierten Gesichtsbildern.

Web-Demo. Als praktischen Test habe ich eine Demo im Browser gebaut (Server mit FastAPI). Der Nutzer folgt etwa 60 s lang einem Punkt. Der Punkt startet an einer zufälligen Stelle, bewegt sich in eine zufällige Richtung mit konstanter Geschwindigkeit und prallt an den Rändern ab. Ein Weg wird nur verwendet, wenn er alle Felder eines 3×3-Rasters besucht; so bleibt die volle Abdeckung des Bildschirms erhalten, die sich in Abschnitt 4.6 als wichtig gezeigt hat, und die Kalibrierung wirkt trotzdem weniger gleichförmig. Danach wird ein Modell personalisiert, und der Blick wird live als Lichtfeld auf einem Raster von 3×3 Feldern angezeigt. Die angezeigte Position ist ein kausaler Moving Average über die letzten 0,5 s (Abschnitt 4.7). Am Ende zeigt eine Auswertung, wann welches Feld angeschaut wurde. Die Demo nutzt bereits einige Ideen aus dem Ausblick: einen Augenausschnitt, räumliche Features des ResNet-18, eine Ridge Regression und die Kopfposition als Zusatz-Feature. Ein kurzer Test mit fünf Punkten (je 3 s) nach der Kalibrierung misst den Fehler auf neuen Bildern. In zwei Durchläufen der neuen Version (Person A) lag der Fehler auf den Prüfdaten der Kalibrierung bei 19,1 % bzw. 6,7 %; das Basismodell ohne Anpassung lag bei 25,4 % bzw. 26,0 %, die konstante Schätzung im zweiten Durchlauf bei 28,3 %. Im zweiten Durchlauf erreichte der Test mit fünf Punkten 11,8 % (78 Messungen); am besten war dort die Ridge Regression auf räumlichen Features, und das Training dauerte 6,1 s. In beiden Durchläufen zeigte das Basismodell während der

ganzen Blickverfolgung nur auf das mittlere Feld, das personalisierte Modell verteilte den Blick auf acht bzw. alle neun Felder. Ein Durchlauf mit Person B erreichte 9,7 % auf den Prüfdaten und 20,8 % im Test mit fünf Punkten (Tabelle 4.21). Mit der früheren Version der Demo (fester Schlangenweg) lag der Fehler im Test mit fünf Punkten in mehreren Einzeltests zwischen etwa 17,6 % und 25,2 % (letzter Test: 19,0 %); eine konstante Schätzung erreicht auf den Kalibrierdaten etwa 23 %. In einem direkten Vergleich sank der Testfehler mit der Kopfposition von 23,0 % auf 17,6 %. Die Werte schwanken stark zwischen den Durchläufen und wurden nicht systematisch ausgewertet. Sie zeigen aber, dass Kopfbewegung und Licht im Live-Betrieb große Fehlerquellen sind.

Literaturverzeichnis

[1] Kyle Krafka, Aditya Khosla, Petr Kellnhofer, Harini Kannan, Suchendra Bhandarkar, Wojciech Matusik und Antonio Torralba. Eye tracking for everyone. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 2176–2184, 2016. doi: 10.1109/CVPR.2016.239.

[2] Kaiming He, Xiangyu Zhang, Shaoqing Ren und Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 770–778, 2016.

[3] Yihua Cheng, Haofei Wang, Yiwei Bao und Feng Lu. Appearance-based gaze estimation with deep learning: A review and benchmark. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(12):7509–7528, 2024. doi: 10.1109/TPAMI.2024.3393571.

[4] Jiahui Liu, Jiannan Chi, Huijie Yang und Xucheng Yin. In the eye of the beholder: A survey of gaze tracking techniques. *Pattern Recognition*, 132:108944, 2022. doi: 10.1016/j.patcog.2022.108944.

[5] Primesh Pathirana, Shashimal Senarath, Dulani Meedeniya und Sampath Jayarathna. Eye gaze estimation: A survey on deep learning-based approaches. *Expert Systems with Applications*, 199:116894, 2022. doi: 10.1016/j.eswa.2022.116894.

[6] Alexandra Papoutsaki, Patsorn Sangkloy, James Laskey, Nediyana Daskalova, Jeff Huang und James Hays. Webgazer: Scalable webcam eye tracking using user interactions. In *Proceedings of the Twenty-Fifth International Joint Conference on Artificial Intelligence (IJCAI)*, S. 3839–3845, 2016.

[7] Nachiappan Valliappan, Na Dai, Ethan Steinberg, Junfeng He, Kantwon Rogers, Venky Ramachandran, Pingmei Xu, Mina Shojaeizadeh, Li Guo, Kai Kohlhoff und Vidhya Navalpakkam. Accelerating eye movement research via accurate and affordable smartphone eye tracking. *Nature Communications*, 11:4553, 2020. doi: 10.1038/s41467-020-18360-5.

[8] Xucong Zhang, Yusuke Sugano, Mario Fritz und Andreas Bulling. Appearance-based gaze estimation in the wild. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 4511–4520, 2015.

[9] Xucong Zhang, Yusuke Sugano, Mario Fritz und Andreas Bulling. Mpiigaze: Real-world dataset and deep appearance-based gaze estimation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(1):162–175, 2019. doi: 10.1109/TPAMI.2017.2778103.

[10] Xucong Zhang, Seonwook Park, Thabo Beeler, Derek Bradley, Siyu Tang und Otmar Hilliges. Eth-xgaze: A large scale dataset for gaze estimation under extreme head pose and gaze variation. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2020. doi: 10.1007/978-3-030-58558-7_22.

[11] Seonwook Park, Emre Aksan, Xucong Zhang und Otmar Hilliges. Towards end-to-end video-based eye-tracking. In *Proceedings of the European Conference on Computer Vision (ECCV)*, 2020. doi: 10.1007/978-3-030-58610-2_44.

[12] Petr Kellnhofer, Adrià Recasens, Simon Stent, Wojciech Matusik und Antonio Torralba. Gaze360: Physically unconstrained gaze estimation in the wild. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, S. 6911–6920, 2019.

[13] Seonwook Park, Shalini De Mello, Pavlo Molchanov, Umar Iqbal, Otmar Hilliges und Jan Kautz. Few-shot adaptive gaze estimation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, S. 9368–9377, 2019. doi: 10.1109/ICCV.2019.00946.

[14] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit und Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2021.

[15] Jiawei Qin, Xucong Zhang und Yusuke Sugano. Unigaze: Towards universal gaze estimation via large-scale pre-training. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, S. 5809–5820, 2026.

[16] Vikrant Nagpure, Tanisha Jain, Rongali Sai Bhargav, Ashwin K. Krishna und Kenji Okuma. Learning to adapt: Test-time personalized gaze estimation with weak and self-supervised learning for in-vehicle scenarios. In *Proceedings of the IEEE Intelligent Vehicles Symposium (IV)*, S. 1334–1339, 2025. doi: 10.1109/IV64158.2025.11097756.

[17] Jun Wang, Hao Ruan, Liangjian Wen, Yong Dai und Mingjie Wang. Gazeclip: Enhancing gaze estimation through text-guided multimodal learning. *Neurocomputing*, 685:133584, 2026. doi: 10.1016/j.neucom.2026.133584.

[18] Lang Ye, Xinggang Wang, Jingfeng Yao und Wenyu Liu. Transgaze: exploring plain vision transformers for gaze estimation. *Machine Vision and Applications*, 35:128, 2024. doi: 10.1007/s00138-024-01609-0.

[19] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy V. Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby u. a. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research (TMLR)*, 2024.

[20] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger und Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, Band 139 von *Proceedings of Machine Learning Research*, S. 8748–8763, 2021.

[21] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár und Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 16000–16009, 2022.

[22] Ananya Kumar, Aditi Raghunathan, Robbie Jones, Tengyu Ma und Percy Liang. Fine-tuning can distort pretrained features and underperform out-of-distribution. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2022.

[23] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang und Weizhu Chen. Lora: Low-rank adaptation of large language models. In *Proceedings of the International Conference on Learning Representations (ICLR)*, 2022.

[24] Xucong Zhang, Yusuke Sugano und Andreas Bulling. Revisiting data normalization for appearance-based gaze estimation. In *Proceedings of the ACM Symposium on Eye Tracking Research & Applications (ETRA)*, 2018.

[25] Pengwei Yin, Guanzhong Zeng, Jingjing Wang und Di Xie. Clip-gaze: Towards general gaze estimation via visual-linguistic model. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Band 38, S. 6729–6737, 2024. doi: 10.1609/aaai.v38i7.28496.

[26] Junfeng He, Khoi Pham, Nachiappan Valliappan, Pingmei Xu, Chase Roberts, Dmitry Lagun und Vidhya Navalpakkam. On-device few-shot personalization for real-time gaze estimation. In *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, 2019.

[27] Zhaokang Chen und Bertram E. Shi. Offset calibration for appearance-based gaze estimation via gaze decomposition. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, 2020.

[28] Erik Lindén, Jonas Sjöstrand und Alexandre Proutière. Learning to personalize in appearance-based gaze tracking. In *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops (ICCVW)*, S. 1140–1148, 2019. doi: 10.1109/ICCVW.2019.00145.

[29] Gang Liu, Yu Yu, Kenneth A. Funes Mora und Jean-Marc Odobez. A differential approach for gaze estimation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(3):1092–1098, 2021. doi: 10.1109/TPAMI.2019.2957373.

[30] Xiaoyu Zhao, Yaping Huang, Yi Tian und Mei Tian. Episode-based personalization network for gaze estimation without calibration. *Neurocomputing*, 513:36–45, 2022.

[31] Yu Yu, Gang Liu und Jean-Marc Odobez. Improving few-shot user-specific gaze adaptation via gaze redirection synthesis. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2019.

[32] Neil Houlsby, Andrei Giurgiu, Stanislaw Jastrzebski, Bruna Morrone, Quentin de Laroussilhe, Andrea Gesmundo, Mona Attariyan und Sylvain Gelly. Parameter-efficient transfer learning for NLP. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, Band 97 von *Proceedings of Machine Learning Research*, S. 2790–2799, 2019.

[33] Huan Liu, Julia Qi, Zhenhao Li, Mohammad Hassanpour, Yang Wang, Konstantinos N. Plataniotis und Yuanhao Yu. Test-time personalization with meta prompt for gaze estimation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, Band 38, S. 3621–3629, 2024. doi: 10.1609/aaai.v38i4.28151.

[34] Yiwei Bao und Feng Lu. From feature to gaze: A generalizable replacement of linear layer for gaze estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 1409–1418, 2024. doi: 10.1109/CVPR52733.2024.00140.

[35] Yaoming Wang, Yangzhou Jiang, Jin Li, Bingbing Ni, Wenrui Dai, Chenglin Li, Hongkai Xiong und Teng Li. Contrastive regression for domain adaptation on gaze estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 19376–19385, 2022. doi: 10.1109/CVPR52688.2022.01877.

[36] Yihua Cheng, Yiwei Bao und Feng Lu. Puregaze: Purifying gaze feature for generalizable gaze estimation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2022.

[37] Mingfang Zhang, Yunfei Liu und Feng Lu. Gazeonce: Real-time multi-person gaze estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 4197–4206, 2022. doi: 10.1109/CVPR52688.2022.00416.

[38] Yong Wu, Yang Wang, Sanqing Qu, Zhijun Li und Guang Chen. Elf-ua: Efficient label-free user adaptation in gaze estimation. In *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI)*, 2024.

[39] Yafei Wang, Haiheng Nan, Runze Yan, Xueyan Ding, Jianda Wang und Xianping Fu. Pigaze: Personalized in-vehicle gaze estimation with plug-and-play adaptation. *Knowledge-Based Systems*, 348:116336, 2026.

[40] Diederick C. Niehorster, Marcus Nyström, Roy S. Hessels, Jeroen S. Benjamins, Richard Andersson und Ignace T. C. Hooge. The fundamentals of eye tracking, part 7: Determining data quality. *Behavior Research Methods*, 58:183, 2026. doi: 10.3758/s13428-026-03039-4.

[41] Gaoxia Jiang, Fan Lei und Wenjian Wang. A multi-model dynamic filtering of label noise for regression. *Pattern Recognition*, 169:111887, 2026. doi: 10.1016/j.patcog.2025.111887.

[42] Yanming Peng, Shijing Wang, Yaping Huang und Yi Tian. See through the noise: Improving domain generalization in gaze estimation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, S. 31346–31355, 2026.

[43] dhruv413. GazeCapture 20 GB (ZIP). Kaggle. URL `https://www.kaggle.com/datasets/dhruv413/gaze-capture-20gb-zip`. Teilmenge des Datensatzes GazeCapture.

[44] Géry Casiez, Nicolas Roussel und Daniel Vogel. 1 Euro Filter: A simple speed-based low-pass filter for noisy input in interactive systems. In *Proceedings of the SIGCHI Conference on Human Factors in Computing Systems (CHI)*, S. 2527–2530, 2012. doi: 10.1145/2207676.2208639.

A. Anhang

A.1. Aufbau des Codes

Der Code ist in Python mit PyTorch und torchvision geschrieben. Die wichtigsten Teile sind:

- `main.py`: lädt GazeCapture, normiert die Ziele und erstellt die Splits;
- `model.py`, `dataset.py`: Modell, Losses, Training, Laden der Daten und gespeicherte Features;
- `metrics.py`: Diagonalfehler und Baselines (eine einzige Quelle für alle Skripte);
- `exp.py`: Hyperparameterstudie mit fünf Wiederholungen;
- `train_base.py`, `personal_exp.py`: Basismodelle und Personalisierung (E0–E3);
- `moving_average.py`: zeitliche Glättung der gespeicherten Vorhersagen (E4);
- `session_design.py`: Abdeckung, Transition Frames und bereinigte Labels;
- `spatial_analysis.py`, `plot_targets.py`: Abbildungen;
- `auswertung.py`: erstellt die Tabellen aus den Ergebnisdateien;
- Notebook `notebooks/Masterarbeit.ipynb`: führt alle Experimente aus und erstellt Tabellen und Abbildungen;
- `demo/`: Web-Demo (Server und Browser-Oberfläche).

A.2. Befehle zum Wiederholen der Experimente

Alle Befehle werden im Hauptordner des Projekts ausgeführt (siehe auch `README.md`).

Daten vorbereiten.

```
python main.py
```

Baselines und Hyperparameterstudie (GazeCapture).

```
python exp.py --experiment baseline
python exp.py --experiment all --sample-seed 0 --val-size 200
python exp.py --experiment trainable_layers --include-resnet
```

Räumliche Analyse und Abbildungen.

```
python spatial_analysis.py --input results/heatmap/base_loss1.csv \
       --compare results/heatmap/base_loss2.csv --out results/figures
python plot_targets.py --out results/figures
```

Personalisierung (E0–E3).

```
python train_base.py
python personal_exp.py --sessions all --base norm_subject norm_random
python personal_exp.py --sessions gen4 --labels clean
python personal_exp.py --sessions 21 22 --split random --seeds 42 43 44
python personal_exp.py --sessions 21 22 --split sequential --seeds 42 43 44
python personal_exp.py --split two_videos --pairs 21:22,22:21 --seeds 42 43 44
python personal_exp.py --sessions all --split sequential
python personal_exp.py --summary
```

Zeitliche Glättung (E4).

```
python moving_average.py
```

Gestaltung der Sitzungen und bereinigte Labels.

```
python session_design.py
python session_design.py --write-clean
```

Einfacher geht es mit dem Notebook `notebooks/Masterarbeit.ipynb`: Zelle 1 trainiert die Basismodelle (E0), Zelle 3 führt die Personalisierung (E1 bis E3) aus und erstellt alle Tabellen.

A.3. Verzeichnis der Fachbegriffe

In dieser Arbeit werden die üblichen englischen Fachbegriffe verwendet. Die Tabelle nennt die deutsche Übersetzung und eine kurze Erklärung.

Englisch	**Deutsch**	**Kurz erklärt**
Accuracy	Genauigkeit	systematische Abweichung vom wahren Blickpunkt
Activation (Function)	Aktivierung(sfunktion)	Funktion am Ausgang einer Schicht, z. B. Sigmoid
Backbone	Grundnetz	großer vortrainierter Teil des Modells, der die Features berechnet
Baseline	Vergleichswert	einfaches Vergleichsverfahren, z. B. immer derselbe Punkt
Batch Size	Batchgröße	Anzahl der Bilder pro Trainingsschritt
Chicken-and-Egg Problem	Henne-Ei-Problem	zwei Dinge hängen gegenseitig voneinander ab
Confidence Interval (CI)	Konfidenzintervall	Bereich, in dem der wahre Mittelwert mit hoher Wahrscheinlichkeit liegt
Crowdsourcing	–	viele Freiwillige nehmen Daten selbst auf
Data Leakage	Datenleck	Information aus den Testdaten gelangt ins Training
Data Loss	Datenverlust	Anteil der Messungen ohne gültigen Wert
Domain Adaptation	Domänenadaption	Anpassung an eine neue Umgebung mit Daten von dort
Domain Generalization	Domänengeneralisierung	gute Leistung in neuen Umgebungen ohne Daten von dort
Domain Shift	Domänenwechsel	Testdaten unterscheiden sich von den Trainingsdaten
Early Stopping	vorzeitiges Beenden	Training endet, wenn sich die Validierung nicht mehr verbessert
Epoch	Epoche	ein Durchlauf durch alle Trainingsdaten
Feature(s)	Merkmal(e)	Zahlen, die ein Netz aus einem Bild berechnet
Feature Extractor	Merkmalsextraktor	Netz, das die Features berechnet
Feature Space	Merkmalsraum	Raum, in dem die Features liegen
Fine-Tuning	Feinabstimmung	ein vortrainiertes Modell mit neuen Daten weitertrainieren
Gaze Regression	Blickregression	Blick als kontinuierlicher Wert vorhersagen
Head-Training	–	nur der Regression Head wird trainiert
Image / Text Encoder	Bild- / Textencoder	Netz, das ein Bild bzw. einen Text in Features umwandelt
Label Noise	Label-Rauschen	Labels stimmen nicht genau mit dem echten Blick überein
Learning Rate	Lernrate	Schrittweite beim Training
Loss / Loss Function	Verlust / Verlustfunktion	Maß für den Fehler, das beim Training minimiert wird

Englisch	Deutsch	Kurz erklärt
Moving Average	gleitender Mittelwert	Mittelwert der Vorhersagen über ein gleitendes Zeitfenster
Overfitting	Überanpassung	Modell lernt die Trainingsdaten auswendig und wird auf neuen Daten schlechter
Precision	Präzision	Streuung wiederholter Messungen
Pretraining	Vortraining	Training auf sehr vielen allgemeinen Daten vor der eigentlichen Aufgabe
Regression Head	Regressionskopf	kleines Netz, das aus den Features die Koordinaten berechnet
Remote Camera	entfernte Kamera	Kamera steht vor der Person, nicht am Kopf
Ridge Regression	Ridge-Regression	lineare Regression mit Strafe für große Gewichte
Saccade	Sakkade	sehr schnelle Augenbewegung zu einem neuen Ziel
Self-Supervised Learning	selbstüberwachtes Lernen	Lernziel entsteht aus den Daten selbst, ohne Labels
Split	Aufteilung	Aufteilung der Daten in Training, Validierung und Test
Supervised Learning	überwachtes Lernen	Lernen mit Labels, die Menschen vergeben haben
Test-Time Adaptation (TTA)	Anpassung zur Testzeit	Anpassung erst während der Nutzung
Transition Frames / Period	Übergangsbilder / Übergangszeit	Bilder bzw. Zeit direkt nach einem Zielsprung
Unconstrained Conditions	uneingeschränkte Bedingungen	freie Kopfhaltung, wechselndes Licht, beliebiger Abstand
Unsupervised Domain Adaptation	unüberwachte Domänenadaption	Domain Adaptation ohne Labels der Zielumgebung
Weakly Supervised	schwach überwacht	Lernen mit wenigen oder groben Labels
Weight Decay	Gewichtsabnahme	Strafe für große Gewichte gegen Overfitting

Eidesstattliche Erklärung

Hiermit versichere ich, dass ich diese Masterarbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe, alle Ausführungen, die anderen Schriften wörtlich oder sinngemäß entnommen wurden, kenntlich gemacht sind und die Arbeit in gleicher oder ähnlicher Fassung noch nicht Bestandteil einer Studien- oder Prüfungsleistung war.

Verwendung von KI-Werkzeugen

Bei der Erstellung dieser Arbeit habe ich die folgenden KI-Werkzeuge als Hilfsmittel eingesetzt:

Werkzeug	**Wofür**	**Betroffene Teile**
ChatGPT (OpenAI)	Umsetzung meiner selbst entworfenen Programmstruktur in erste Code-Entwürfe (Laden der Daten, Training), Testen der Implementierung, Verbesserung der Codestruktur	Programmcode
Claude (Anthropic)	**Code:** Prüfung und Auswertung des Codes, Fehlersuche und Korrektur von Fehlern, Skripte zum Nachrechnen der Ergebnisse (`auswertung.py`, Notebook), Entwurf und Umsetzung der Auswertung der zeitlichen Glättung (`moving_average.py`), Aufbereitung der Sitzungen der zweiten Person (`prepare_session.py`), Abbildungen (`plot_targets.py`), Änderungen an der Web-Demo (Kalibrierbewegung, Moving Average, Laden des Modells)	Programmcode, Tabellen und Abbildungen in Kapitel 4, Web-Demo
Claude (Anthropic)	**Text:** Übersetzung zwischen Deutsch und Englisch, sprachliche Überarbeitung und Vereinfachung, Ausformulieren von Textabschnitten auf Grundlage meiner Entwürfe, Ergebnisse und Notizen, Korrektur von Fehlern	Alle Kapitel, Kurzfassung, begleitende Dokumentation
Claude (Anthropic)	**Form:** LaTeX-Gestaltung (Titelseite nach der BHT-Vorlage), Beschriftung der Abbildungen	Layout, Abbildungen

Zur Entstehung des Codes: Den Aufbau der Pipeline habe ich zu Beginn selbst geplant: Laden und Normieren der Daten, Splits, eingefrorener Backbone mit Regression Head, Training und Auswertung. In den ersten Tagen hat mir ChatGPT geholfen, diese Struktur in Python-Code umzusetzen. Den Code habe ich selbst ausgeführt, getestet und angepasst.

Die fachlichen Entscheidungen, also Modell, Splits, Fehlermaß und Experimente, habe ich getroffen.

Thema, Forschungsfragen, Aufbau der Experimente E0 bis E3, Aufnahme der Webcam-Daten und Durchführung aller Trainingsläufe und Demo-Tests stammen von mir. Die zusätzlichen Auswertungen E4 (Glättung, auf Anregung meines Betreuers) und E5 (zweite Person) habe ich gemeinsam mit Claude entworfen und selbst ausgeführt. Alle Ergebnisse der KI-Werkzeuge habe ich kritisch geprüft und bei Bedarf korrigiert; die Zahlen in Kapitel 4 wurden mit den gespeicherten Ergebnisdateien nachgerechnet. Die fachlichen Aussagen stützen sich auf die angegebene Literatur, KI-Werkzeuge dienen nicht als Quelle. Für den gesamten Inhalt dieser Arbeit trage ich die volle Verantwortung.

Ort, Datum

Khaled Rafei